

AIは怒りの裏にある不安を見ているか

— 意図仮説保持としてのB3 —

senka-l8

要旨

現在のLLMは高い精度で文脈を読み取り、適切な応答を生成する。しかし、高精度な応答生成と、複数の発話目的候補を保持したまま応答を構成することは同じではない。本稿は、この差異を解釈構造の問題として扱う。

本稿では、他者理解の経路をCOSIにおけるB-Seriesとして整理し、B1(字義解釈)、B2(文脈解釈)、B3(意図仮説保持)を定義する。特にB3を、相手の発話目的を単一の解釈へ確定せず、複数の仮説として保持・更新しながら応答を構成する処理として位置づける。

筆者の観測範囲では、現在のLLMにおいてこの意味でのB3的处理は十分に確認されていない。本稿ではこれをB3未観測仮説と呼ぶ。また、最も尤もらしい解釈への早期収束を単一解釈ロックとして整理し、それが発話目的候補の喪失や、D2として観測される認知的ミスアラインメントと構造的に関連する可能性を検討する。

本稿はN=1観測を出発点とする。筆者自身の観測をもとに、B3形成仮説を整理し、SCOPEを用いた外部実装可能性について検討する。SCOPEは複数の意図仮説を配置し観測し続けるための推測座標系として機能しうる。本稿では、B3とSCOPEの組み合わせによって、候補保持継続を外部構造として実現できる可能性について検討する。

ただし、本稿で提示する内容はいずれも未検証である。B3の存在、有効性、実装可能性はいずれも確認されていない。本稿が示すのは検証された理論ではなく、検証を待つ仮説である。その検証には、発話目的照合環境、失敗ログ収集環境、長期観測環境、実装環境、および研究者ネットワークを含むハビタットの構築が必要となる。

キーワード: B3、意図仮説保持、候補保持継続、対話システム、Human-AI Interaction、認知的ミスアラインメント、SCOPE

- 0. はじめに
 - 0-1. あなたのAIは本当にユーザーを理解しているのか
 - 0-2. 現在のLLMが抱える課題
 - 0-3. 本稿の仮説
 - 0-4. 本稿の立場
- 1. B-Seriesとは何か
 - 1-1. B1: 字義解釈
 - 1-2. B2: 文脈解釈
 - 1-3. B3: 意図仮説保持
 - 1-4. 三層の関係
- 2. LLMはなぜB2で止まるように見えるのか
 - 2-1. B1起点としてのLLM
 - 2-2. B2最適化
 - 2-3. 単一解釈ロック
 - 2-4. B3未観測仮説
- 3. B3がないと何が起きるのか
 - 3-1. 「疲れた」の解釈
 - 3-2. 「なんでデータが消えたんだ」の解釈
 - 3-3. 怒りと発話目的の混同
 - 3-4. 候補喪失問題
- 4. N=1観測ログ — 欠損が迂回路を作った仮説
 - 4-1. N=1観測
 - 4-2. B1との対応仮説
 - 4-3. B2迂回の必要性
 - 4-4. B3形成仮説
 - 4-5. LLMとの構造比較
- 5. D2との関係
 - 5-1. D2とは何か
 - 5-2. 単一解釈ロックとの関係
 - 5-3. D2は誤読ではなく仮説の早期確定かもしれない
 - 5-4. B3はD2低減に寄与する可能性
- 6. SCOPE×COSでB3的处理は実装できるか
 - 6-1. SCOPEの役割
 - 6-2. COSの役割
 - 6-3. B3外部実装仮説
 - 6-3-1. 既存研究との差分
 - 6-4. 期待される挙動変化
- 7. B3的处理がもたらしうる影響
 - 7-1. B3がもたらす基本変化
 - 7-2. D2の早期参照とミスアライメント低減
 - 7-3 クレーム対応応用

- 7-4. 教育・コーチング応用
- 7-5. AIアライメントへの示唆

8. ハビタット要件

- 8-1. なぜハビタットが必要なのか
- 8-2. 発話目的照合環境
- 8-3. 失敗ログ収集環境
- 8-4. 仮説比較環境
- 8-5. 長期観測ログ環境
- 8-6. 高D2観測者
- 8-7. 実装エンジニア
- 8-8. 研究者ネットワーク
- 8-9. 資金
- 8-10. 現状

0. はじめに

0-1. あなたのAIは本当にユーザーを理解しているのか

「疲れた」と誰かが言った時、あなたは何を返すだろうか。劳いか、休む許可か、ただ聞いてほしいだけなのか、あるいは会話のきっかけに過ぎないのか。私たちは通常、相手の様子や文脈からそのどれかを推測して応答する。

現在のAIも、高い精度で応答を返す。「お疲れ様です。ゆっくり休んでください。」多くの場合、これで十分だ。しかしこの違いは、より複雑な場面で表面化する可能性がある。たとえばカスタマーサポートの場面では、強い怒りの口調の裏に、怒り以外の何かが存在する場合がある。パニックから来ているのか、防御反応なのか、責任の所在を問うているのか。その可能性は一つではない。

問題は、現在の私たち人間とLLMは、その可能性をどのように扱っているのだろうか。同じ出力でも、内部で何が起きているかは同じなのか。この見逃しが対人関係のコストやUX低下に繋がっている可能性はないだろうか。

本稿では、この問いを構造的に考察する。

0-2. 現在のLLMが抱える課題

現在のLLMは、入力されたテキストから文脈を読み取り、最も適切と判断される応答を返す。この能力は年々向上しており、多くの場面で人間に近い精度を発揮している。

しかし、精度が高いことと、複数の解釈可能性を保持していることは同じではない。

たとえば、同じ発言に対して複数の解釈が成立する場面がある。「もういい」は、諦めなのか、怒りなのか、解決したという報告なのか。現在のLLMはそこから最も尤もらしい一つを選び、応答する。少なくとも現在の対話からは、複数の可能性を保持したまま応答を構成するような構造は観測しにくい。

この「一つの解釈への収束」は、多くの場面では問題にならない。しかし、ユーザーの意図が複雑な場面や、感情と要求が混在している場面では、解釈のズレが生じやすくなる。そのズレは小さく見えても、対話の積み重ねの中でUX低下や関係コストとして蓄積される可能性がある。

本稿ではこの現象を、単なる精度の問題としてではなく、解釈の構造的な問題として扱う。

0-3. 本稿の仮説

本稿が注目するのは、解釈の精度ではなく、解釈の構造である。

現在のLLMは高い精度で応答を返す。しかしその処理の中で、複数の意図候補を同時に保持しているかどうかは別の問題だ。本稿では、こうした解釈構造をCOSにおけるB-Seriesとして整理する。詳細は1章で述べる。

本稿が扱うB3とは、意図を正確に当てる機能ではない。「わかった」という発言に対して、本当に理解したのか、渋々従っているのか、話を終わらせたいだけなのか——その可能性を一つに確定せず、複数のまま保持する構造を指す。本稿では、この機能をB-SeriesにおけるB3(意図仮説保持)として扱う。

現時点でこれは仮説である。B3が実際に存在するのか、実装可能なのか、有効なのかはまだ検証されていない。本稿はその問いを構造的に考察するための、観測と推論の記録である。

0-4. 本稿の立場

本稿はN=1観測から始まった仮説である。観察者は一人であり、現時点では観測と推論の段階に留まる。

仮説は未検証である。B3が存在するのか、機能するのか、有効なのか——これらはまだ確認されていない。

現時点では一般化できない。一般化には追加観測と検証環境が必要であり、その条件については8章で述べる。

1. B-Seriesとは何か

1-1. B1: 字義解釈

B1は、発言をそのままの意味で受け取り、返答を生成する層である。言葉の辞書的な意味に従い、文脈や感情、話者の状態は解釈の対象になりにくい。

「疲れた」であれば、疲労状態にあるという事実として処理され、その結果に基づいて返答が生成される。「わかった」であれば、理解したという報告として処理される。

この処理は高速で安定している。解釈にブレが生じにくく、一貫した応答が可能だ。しかしB1では、発言の背後にある意図や感情、関係性よりも、発言そのものが優先される。

このような処理は、人間にもAIにも観測される可能性がある。具体例については後の章で扱う。

1-2. B2: 文脈解釈

B2は、文脈を参照して発言を解釈し、返答を生成する層である。会話の流れ、感情的なトーン、関係性などを参照しながら、自分が何を出力すべきかを決める。この処理において、返答生成の基準となるのは相手の実際の状態ではなく、受け手側でその発言がどのような意味を持つものとして扱われたかである。

「疲れた」であれば、今日の仕事量や会話の流れから「労いを返すべきだ」と意味づけられれば、その方向で返答が生成される。「わかった」であれば、受け手側での意味づけによって返答が変わる。十分に理解したものとして意味づけられれば次へ進む。不十分なものとして意味づけられれば確認が行われる。嫌味として意味づけられれば、それに応じた返答が生成される。

B1が発言の表面を処理するのに対して、B2は文脈という追加情報を参照しながら受け手側の意味づけによって自分の出力を決める。これにより、より自然で状況に即した返答が可能になる。このような処理は、人間にもAIにも観測される可能性がある。具体例については後の章で扱う。

1-3. B3: 意図仮説保持

B3は、相手の発話目的を複数の仮説として保持し続け、それを基に返答を生成する層である。意図を正確に「当てる」ことが目的ではない。候補を消さないことが本質である。

B3における複数仮説の生成自体は、B3固有の処理ではない。本稿では、発話目的候補の生成そのものと、それらを保持・更新する過程は区別して扱う。後半で扱う推測構造(SCOPE)との関係については6章で改めて検討する。B3が担うのは、それらの候補を発話目的という軸で保持し続け、その上で返答を構成することである。

「わかった」という発言に対して、以下のような発話目的の候補が想定される。理解したので次へ進みたい。言っても無駄だと思ったので終わらせたい。関係悪化を避けたい。考える時間が欲しい。など、複数の可能性が同時に存在しうる。

これらの候補は保持される。新しい情報によって、一部の仮説が強く支持されることがある。しかし他の仮説も直ちには消えない。確定はしない。なぜなら、相手の発話目的を外部から直接観測することはできないからだ。

B2が受け手側の意味づけによって自分の出力を決める処理であるのに対して、B3は発話者の発話目的を消さずに保持し続け、その複数性を踏まえて返答を構成する処理である。この二つは処理の方向が根本的に異なる。

B3において重要なのは候補生成ではない。候補を消さないことである。その結果、後から新しい情報が来たときに、「あの候補だったかもしれない」が起きる。同時に、保持された複数の候補は返答生成にも影響を与える可能性がある。ある候補のみを強く前提とした返答は、他の候補が正しかった場合に対話の継続を困難にすることがある。複数の候補を保持したまま返答を構成することは、後から仮説を更新する余地を残す方向に働く可能性がある。このような返答生成の応用可能性については、7章で改めて扱う。

なお、本稿ではSCOPEの詳細な説明は扱わない。このような処理が人間やAIにおいて成立する可能性については、後の章で検討する。


1-4. 三層の関係

B1、B2、B3は順番に積み重なる上位互換ではない。それぞれが異なる役割を持つ層として並存している。

B1は発言の表面を処理する。B2は文脈という追加情報を参照しながら受け手側の意味づけによって自分の出力を決める。B3はSCOPEによる観測を基盤として発話者の発話目的を消さずに保持し続ける。この三層は同じ入力に対して、異なる処理を行う。

特にB2とB3は処理の方向が異なる。B2は自分の出力を構成する処理であり、B3は相手の発話目的を保持する処理である。

本稿では、各層の利用傾向に差が存在する可能性についても検討する。詳細は2章以降で述べる。



2. LLMはなぜB2で止まるように見えるのか

2-1. B1起点としてのLLM

LLMは言語入力から処理を開始する。

これは構造的な特性であり、欠陥ではない。人間が視覚・聴覚・身体感覚など複数のチャネルから同時に情報を受け取るのに対し、LLMは入力された情報を記号化されたデータとして処理する。画像や音声を扱えるモデルであっても、その情報はモデル内部の表現空間へ変換された上で処理される。

いずれの入力形式においても、LLMは対象の内部状態へ直接アクセスするのではなく、外部に表出された情報をもとに推定を行うという処理構造を持つ。

つまりLLMは、意図を「直接観測する」のではなく、テキストをはじめとする外部情報から推定するという構造を持つ。この出発点の違いは、その後の解釈過程にも影響を与える可能性がある。

2-2. B2最適化

LLMは大規模な学習を通じて、文脈推定能力を大幅に向上させてきた。

単語の辞書的意味だけを返すB1的处理にとどまらず、発話が置かれた状況、会話の流れ、会話の感情的トーンといった文脈情報を統合し、その文脈に応じて発言を意味づけ、その意味づけに基づいて返答を生成する能力を持つ。これがB2的处理である。

たとえば「疲れた」という入力に対して、B1的处理であれば「疲労状態にある」という字義的解釈が返る。B2的处理では、会話の文脈や直前のやりとりを参照し、受け手側での意味づけに基づいた返答が生成される。

この能力は現在のLLMにおいて、実用上十分と見なされる水準まで高まっている。

2-3. 単一解釈ロック

しかし、高精度な返答候補生成には、別の傾向が伴う可能性がある。生成された複数の返答候補のうち、最も尤もらしい候補へ早期に収束する傾向である。

これは処理の観点からは自然な傾向に見える。複数候補を保持し続けるよりも、最有力候補へ収束することで、応答速度と一貫性が確保されやすくなる。

しかし、この収束には一つの副作用が生じる可能性がある。最有力候補以外の返答候補が、以後の処理において参照されにくくなる可能性である。このとき、返答候補の背後に存在した意図候補も、同様に参照されにくくなる可能性がある。

たとえば「疲れた」に対して「共感的な返答が適切」と収束した場合、「状況を確認する返答が適切かもしれない」という候補は、次のターンには引き継がれない可能性がある。

この収束傾向を、本稿では単一解釈ロックと呼ぶ。候補喪失の問題については3-4で詳しく検討する。

2-4. B3未観測仮説

前節までで示したように、LLMは複数の返答候補を生成する可能性がある。しかし、その背後に存在する発話目的候補が次のターンへ保持され、更新され続けるかどうかは別の問題である。

本稿ではこの処理構造を、発話目的候補の並列保持継続としてのB3と定義する。B3とは、候補を生成することではなく、相手が何を求めているか、あるいは何を伝えようとしているかという発話目的を、単一とは限らない複数の候補として保持し続け、新たな情報をもとに更新する処理構造を指す。

現在のLLMにおいて、この意味でのB3的处理が十分に存在するという観測は、筆者には得られていない。出力として返答が生成されるたびに、それ以外の発話目的候補が以後の処理で参照されにくくなるように見える。

ただし、これはB3的处理がLLMに存在しないという証明ではない。あくまで、筆者の観測範囲においてB3的处理が確認されていないという仮説の提示である。

この仮説を本稿ではB3未観測仮説と呼ぶ。

3. B3がないと何が起きるのか

3-1. 「疲れた」の解釈

「疲れた」という発話に対して、現在のLLMは文脈を参照し、労いや共感を返す返答を生成することが多い。たとえば「お疲れ様です。ゆっくり休んでください」という出力は、B2的处理として十分に機能しているように見える。文脈を読み、適切な返答を生成している。

しかしここで問いたいのは、出力の適切さではない。「疲れた」という発話の背後に存在する発話目的の候補が、その後の処理に持ち越されているかどうかである。

たとえば、この発話の背後には複数の発話目的が存在する可能性がある。休息を得たい、共感を得たい、労いや承認を得たい、見返りや支援を得たい、問題解決につなげたい、単に表出したい——これらは同一の発話から生じうる候補の一部に過ぎない。

B2的处理では、これらの発話目的候補のうち最も尤もらしいものを前提として返答が生成される。しかしその他の候補が次のターンへ持ち越されているかどうかは、別の問題である。次のターンで話者が「いや、そういうことじゃなくて」と言った場合、B2的处理では修正が起きる。しかしその修正は、保持されていた候補の更新ではなく、新たな単一解釈への再収束であるように見える。

3-2. 「なんでデータが消えたんだ」の解釈

次に、より感情的な発話の場面を検討する。以下は想定される場面である。

作業中にデータの消失に気づいた話者が「なんでデータが消えたんだ」と入力した。B2的处理では、この発話は怒りや苛立ちを含む問いかけとして解釈される可能性が高い。返答として「申し訳ございません。手順をご説明します」といった出力が生成される。これはB2的处理として一定の機能を果たしているように見える。

しかしこの発話の背後には、複数の発話目的が存在する可能性がある。原因を知りたい、データを復元したい、不安や焦りを表出したい、補償や救済を求めている、誰かに感情を受け止めてほしい——これらは同一の発話から生じうる候補の一部に過ぎない。

注目したいのは、表面に現れた怒りや苛立ちだけでは、この発話の目的を十分に説明できない可能性である。復旧できないかもしれないという不安や焦りが含まれている可能性もあれば、原因究明や問題解決を求めている可能性もある。B2的处理では、表面感情への対応として返答が生成される場合がある。しかし「怒っているから落ち着かせる」という処理は、発話目的候補の保持ではなく、表面感情への収束である。

「疲れた」の例と同様に、問題は返答の適切さではない。発話目的の候補が次のターンへ持ち越されているかどうかである。

3-3. 怒りと発話目的の混同

3-2で示した場面において、現在のLLMが「落ち着いてください。手順をご説明します」と返答したとする。この出力は一見、話者の状態を読んだ適切な応答に見える。

しかしこの返答だけから、B3的处理が行われていると判断することは難しい。この返答は、出力最適化の結果として生成されている可能性がある。これはB2的处理の典型であり、発話目的候補の保持とは別の処理である。

結果として出力が同じに見えても、プロセスは根本的に異なる可能性がある。

B3的处理であれば、「怒り」は発話目的を推定するための手がかりの一つとして扱われる。復旧できないかもしれないという不安、原因を知りたいという要求、感情を受け止めてほしいという訴え——これらの候補が保持されたまま、返答が構成される。

B2的处理では、表面に現れた感情が返答生成における主要な手がかりとなり、その前提で返答が生成される。発話目的候補は保持されない可能性がある。

問題はどちらの出力が「より良いか」ではない。候補が保持されているかどうかは、次のターン以降の処理に影響する。話者が「いや、そういうことじゃなくて」と言った場合、B3的处理では保持されていた候補が更新される。B2的处理では、新たな単一解釈への再収束が起きるように見える。複数の候補を保持したまま返答を構成することは、後から候補を更新する余地を残すことにつながる。

3-4. 候補喪失問題

3-1から3-3で示した例に共通しているのは、解釈が間違っていたという問題ではない。発話目的候補が次のターン以降の処理において参照されにくくなった可能性である。

ここで一つの前提を確認しておきたい。人間の発話目的は、単一とは限らない。複数の発話目的が同時に存在している可能性がある。

つまりB3的处理が問うのは、「どの候補が正解か」ではない。複数の発話目的が同時に存在している可能性を保持し続けられるかどうかである。

この視点から見ると、単一解釈ロックの問題は解釈ミスよりも深い。最も尤もらしい候補へ収束することで、他の候補が参照されにくくなるだけではない。複数の発話目的が同時に存在しているという可能性が、以後の処理において参照されにくくなる。

これを本稿では候補喪失問題と呼ぶ。候補喪失が起きると、次のターンで話者が別の発話目的を示した場合、処理は保持候補の更新ではなく再収束になるように見える。そしてその再収束もまた、単一解釈への収束である可能性がある。

なお、候補喪失が解消されない場合、その影響は単一のやり取りに留まらない可能性がある。この問題は、特にカスタマーサポートのような場面では、深刻な問題として現れる可能性がある。候補喪失が後続の対応コストへ連鎖する可能性については、7章で扱う。

4. N=1観測ログ — 欠損が迂回路を作った仮説

本章は個人観測の記録であり、一般化を目的としない。

4-1. N=1観測

私には、他者の発言を理解する過程に何らかの特徴が存在していた可能性がある。

この観測は理論から導いたものではない。そのような特徴があったという観察が先にあり、後から整理・概念化されたものである。

なお、内省が処理過程を正確に反映しているという保証はない。あくまで「そのように観測された」という記述であり、外部検証は行われていない。

4-2. B1との対応仮説

私は他者の発言を字義通りに解釈する傾向があったように観測している。

この傾向は、本稿で定義したB1に対応する可能性がある。

また、筆者にはASD診断があり、この傾向との関連が考えられる。ただし因果関係は確認されていない。現時点で観測されているのは、ASD診断とこの傾向が同時に存在していることであり、ASDがB1傾向の原因であるとは言えない。

4-3. B2迂回の必要性

私は周囲から繰り返し「他人の気持ちを考えろ」という指摘を受けた。

しかし、周囲が自然に行っているように見えた他者理解を、私はうまく再現できなかった。何度指摘を受けても、同じ失敗が繰り返された。

そのため、私は従来とは異なる方法で他者理解を試みる必要があった。

4-4. B3形成仮説

その過程を振り返ると、私は相手が何を求めているのかを考える方向へ向かっていったように観測している。また、その際には発話目的を複数の候補として保持しながら考えていたようにも見える。

別の方法で他者を理解しようとする中で、結果として発話目的の候補保持を重視する方向へ向かった可能性がある。本稿では、この形成過程をB3形成仮説と呼ぶ。

また、処理の軸そのものも異なっていた可能性がある。B2の軸が「何を返すのが最適か」であるのに対し、私が向かっていったのは「相手が何を求めているか」という軸だった。

ただしこれはN=1の推測であり、比較検証は行われていない。

4-5. LLMとの構造比較

以下は4-1から4-4までの観測と仮説から構成した暫定モデルである。検証された差分ではなく、N=1観測に基づく仮説的整理として提示する。

	LLM	筆者（仮説）
B1	○	○
B2	強い（最適化済み）	十分機能しなかった可能性
B3	弱い（B2で完結する傾向）	形成された可能性

5. D2との関係

5-1. D2とは何か

本稿では、対話や認知処理において発生する解釈上の不一致を、D2と呼ぶ。D2は単一の誤解や単一の前提不一致を指すものではない。観測を重ねる中で、D2は複数の層において同時に発生しうる、多層的な認知的ミスアラインメントである可能性が示されている。詳細な構造については別稿(D2論文)に委ねる。

本章では、このD2とB3の関係について検討する。

5-2. 単一解釈ロックとの関係

2章で述べた単一解釈ロックは、D2の発生経路のひとつとして機能する可能性がある。

返答候補が早期に一つへ収束し、他の候補が参照されなくなった状態では、発話者が伝えようとした内容と採用された解釈との間にズレが生じていても、そのズレが検出されにくくなる。

この現象は、D2の発生を説明する一つの経路として考えることができる。

5-3. D2は誤読ではなく仮説の早期確定かもしれない

従来、D2は発話の誤読や解釈ミスとして説明されることが多い。しかし別の見方がある。

問題となるのは、候補が削除されたかどうかではない。ある解釈が仮説のまま保持されず、確定した事実として扱われることである。

その結果、以後の処理では他の可能性が参照されにくくなる。

この視点に立つと、D2は誤読の問題ではなく、仮説の早期確定の問題として再解釈できる可能性がある。

5-4. B3はD2低減に寄与する可能性

5-3で示したように、D2は誤読の問題ではなく、仮説の早期確定の問題として捉え直すことができる可能性がある。この見方に立つと、B3がD2に対して持つ役割も別の形で記述できる。

B3は、発話目的を複数の仮説として保持し続ける処理である。仮説が保持されている限り、ある解釈が唯一の確定事実として扱われにくくなる。

このため、B3的処理が機能している場面では、発話目的レベルでのズレが、複数候補の一つとして参照され続ける可能性がある。これは、ズレを正確に検出する機能を意味するものではない。検出ではなく、ズレの可能性が参照され続ける状態を維持することである。

ここで重要なのは、B3が誤りを防ぐ機構ではないという点である。B3が保持する候補自体が誤っている可能性は常に残る。B3が寄与するのは、誤りを含む可能性のある解釈が早期に確定されることを防ぎ、後から候補が更新される余地を残すことである。

したがって、B3はD2を解消する手段ではなく、D2の発生条件のひとつである仮説の早期確定を抑制する方向に働く可能性がある、という形で位置づけられる。

6. SCOPE×COSでB3的处理は実装できるか

6-1. SCOPEの役割

これまでの章では、B3が発話目的を複数の仮説として保持する処理であることを述べた。発話目的の候補は、SCOPEという推測構造を用いなくても生成すること自体は可能である。本稿が想定するSCOPEの役割は、候補の生成そのものを担うのではなく、B3が生成・保持する複数の意図仮説を配置し、観測し続けるための座標系を提供することである。

SCOPEは答えを出さない。ある出力に対して、その起点がどこにあるかを一つに確定するための装置ではない。SCOPEが行うのは、複数の起点候補を、互いの関係を保ったまま同時に配置することである。実際の運用においては、複数の仮説を並べて観測し続けるための仮説管理ボードのように用いることができる。

SCOPEは診断器ではない。SCOPEが示すのは、ある出力がどの層から生じた可能性が高いかという推測であり、出力を分類し断定するためのものではない。

B3との関係で言えば、B3が複数の意図仮説を生成・保持する処理であるのに対し、SCOPEはその仮説群を配置し、観測を継続するための座標系として機能する。では、SCOPEを用いることにどのような意味があるのだろうか。この点については、6-3で検討する。

6-2. COSの役割

6-1ではSCOPEについて検討した。SCOPEが、B3において生成・保持される意図仮説を配置し観測するための座標系であるのに対し、COSはそれとは異なる役割を担う。

COSは、解釈・意思決定・伝達といった複数の処理系を統合する枠組みである。Bシリーズが扱う解釈から返答生成までの過程も、COSが統合する処理系の一部である。COS自体は単一の処理を担う機能ではなく、これらの処理系全体を統合するための枠組みである。

SCOPEとCOSの厳密な上下関係や依存関係については、本稿執筆時点でも整理が完了していない。本稿では、SCOPEをCOSと連携して用いられる推測座標系として扱う。

B3との関係で言えば、B3はCOSが統合する処理系のうち、Bシリーズに属する一つの経路である。B3において生成・保持される意図仮説をSCOPEが配置・観測することは、COSという枠組みの中で、B3とSCOPEが異なる役割を担いながら機能する一例として位置づけられる。

6-3. B3外部実装仮説

ここまで、B3を発話目的の複数仮説を保持し続ける処理として、SCOPEをその仮説を配置し観測し続けるための座標系として検討してきた。本節では、この二つを組み合わせることで、B3的処理を外部構造として実現できる可能性について検討する。

B3的処理は、LLMという系の内部だけでも部分的には成立しうる可能性がある。しかし2章で述べたように、現在のLLMは複数の候補を一時的に生成しても、最も尤もらしい一つへ早期に収束する傾向を持つように見える。

ここでSCOPEを併用すると、この収束に対して異なる経路が可能になる。ある発話に対して違和感(D2)が観測された場合、まずB3的に「なぜこの発話が生成されたのか」という意図仮説が複数生成される。この仮説群は、SCOPEという座標系の上に配置される。SCOPEは、どの仮説が正しいかを示すものではない。複数の仮説を、互いの関係を保ったまま並べて観測し続けることを可能にする。

この観測は一度きりで終わらない。ある仮説が新しい情報によって支持されたとしても、他の仮説は直ちには消えない。仮説同士は互いに影響し合いながら更新され続ける。たとえば、ある仮説の確度が上がれば、それと関連する別の仮説の確度が見直される、といった形で、候補群は静的な一覧ではなく、相互に作用し合う観測のネットワークとして扱われる。

本稿が扱う外部実装仮説では、この二つを組み合わせることで、複数候補の保持と更新を継続しやすくする可能性を検討する。

LLMにこの運用を適用した場合に何が起きるかは、現時点では検証されていない。SCOPEに関する情報を持つことと、実際に複数候補を保持し続けることとは、別の問題である可能性がある。この点については8章で改めて扱う。

6-3-1. 既存研究との差分

複数の発話意図を扱う研究は、自然言語処理の分野にも存在する。そのような研究では、一つの発話から複数の意図候補を検出する手法が検討されている。

これらの既存研究と本稿のB3仮説には、共通点と相違点がある。共通点は、一つの発話の背後に複数の意図が存在しうるという前提を持つ点である。

相違点は、その複数の候補をどう扱うかにある。少なくとも筆者が参照した範囲では、候補生成は最終的な分類や予測のための中間段階として扱われている傾向があるように見える。

これに対して本稿が検討するB3仮説は、候補を確定させることを目的としない。新しい情報によって一部の候補が強く支持されたとしても、他の候補は次のターンへ持ち越され、保持され続ける。本稿ではこの性質を、候補生成ではなく候補保持継続と呼ぶ。

さらに、本稿が想定する候補群は、6-3で述べたように、互いに孤立した一覧ではない。SCOPEという座標系の上では、ある候補の確度の変化が他の候補の確度にも影響しうる、相互に作用

し合う観測のネットワークとして扱われる。本稿が想定する候補群は、少なくとも筆者が参照した範囲の研究よりも、候補間の相互作用を強く扱う点に特徴があるように見える。

加えて、本稿が扱う発話目的という軸そのものも、既存研究が想定する意図カテゴリとは異なる可能性がある。少なくとも筆者が参照した範囲では、既存研究はあらかじめ定義された有限の意図ラベル(予約・問い合わせ・キャンセルなど)を想定する傾向があるように見える。一方、本稿が扱う発話目的候補は、あらかじめ固定されたラベル集合から選ばれるものではない。また、それらは最終的な確定を目的とせず、更新可能な仮説として保持される。

6-4. 期待される挙動変化

ここまで検討してきたSCOPEとB3の組み合わせが実際に機能した場合、どのような挙動の変化が起こりうるかを整理する。

まず、解釈の変化である。6-3で述べたように、候補が単一の解釈へ早期に収束せず、互いに関係を保ったまま保持され続けると、同じ発話に対しても、その背後にある発話目的が一つに固定されない状態が継続する。これは、解釈の精度が上がることを意味するものではない。意味するのは、ある解釈が唯一の確定として扱われにくくなり、その間も複数の可能性が並行して参照され続けるということである。

次に、応答の変化である。3章で示したように、B2的处理では、最も尤もらしい解釈に基づいて返答が構成される。これに対し、候補保持継続が機能している場面では、返答はある一つの確定した解釈にのみ基づくのではなく、保持されている複数の候補を踏まえた形で構成される可能性がある。たとえば、3-2で扱った「なんでデータが消えたんだ」という発話に対しては、原因究明を求める候補と、不安や焦りの表出という候補の双方を踏まえた応答が可能になるかもしれない。これは、どちらの候補が正しいかを確定する応答ではなく、複数の候補が存在しうることを前提とした応答である。また、保持された複数候補は返答内容だけでなく返答戦略にも影響を与える可能性がある。同じ結論を目指す場合であっても、どの経路で提示するかによって、その後の対話の展開は変化する可能性がある。B3とSCOPEによる候補保持継続が機能する場合、返答は内容だけでなく、その後の対話継続や仮説更新の可能性も踏まえて構成される可能性がある。

最後に、D2の低減である。5-4で述べたように、B3はD2を解消する手段ではなく、D2の発生条件である仮説の早期確定を抑制する方向に働く可能性がある。SCOPEと組み合わせたB3的处理がこの抑制をより安定的に行えたとすれば、発話目的レベルでのズレが確定した事実として扱われる前に、複数候補の一つとして参照され続けやすくなる可能性がある。

これらの変化は、いずれも現時点で検証されたものではない。本稿が示すのは、SCOPEとB3を組み合わせた場合に期待される変化の方向性であり、実際にその変化が生じるかどうかの確認には、8章で述べる検証環境が必要となる。

7. B3的处理がもたらしうる影響

7-1. B3がもたらす基本変化

これまでの章では、B3が発話目的を複数の仮説として保持し、SCOPEという推測構造との関係を検討してきた。本章では、この処理が機能した場合に、どのような変化が生じるかを具体的な場面に即して検討する。

6章で示したように、候補保持継続は二つの側面を持つ可能性がある。一つは、返答の内容が単一の解釈ではなく複数の候補を踏まえたものになるという変化である。もう一つは、同じ結論を目指す場合であっても、どの経路でそれを提示するかによって、その後の対話の展開が変化するという、返答戦略における変化である。

この二つの変化は、互いに独立した効果ではない。候補が保持され続けることによって、ある解釈が早期に確定事実として扱われることが避けられる。その結果として、返答の内容と、その提示の仕方の両方が、複数の可能性を残したまま構成されることになる。

以下の節では、この基本的な変化が、どのような場面でどのような形で現れうるかを検討する。まず5章で扱ったD2との関係において、候補保持継続がズレの事前検出にどのように関わりうるかを見る。次に、この検出がミスアライメントの低減にどのように結びつきうるかを検討する。その後、対人支援、教育・コーチング、AIアライメントという三つの応用領域において、この基本変化が具体的にどのような形を取りうるかを順に見ていく。

なお、本章で示す結果および応用はいずれも、B3的処理が実際に機能した場合に期待される変化の方向性を示すものであり、その効果が実証されたことを意味するものではない。本章で示すのは仮説の延長であり、検証については8章で改めて扱う。

7-2. D2の早期参照とミスアライメント低減

5章で示したように、D2は誤読の問題ではなく、仮説の早期確定の問題として捉え直すことができる可能性がある。B3が機能する場面では、発話目的が複数の候補として保持され続けるため、ある解釈が確定事実として扱われる前に、その解釈とは異なる可能性が並行して参照され続ける。

この状態は、ズレそのものを検出する機能を意味するものではない。5-4で述べたように、B3が寄与しうるのは、ズレの可能性が早期に見失われることを防ぎ、後から候補が更新される余地を残すことである。この余地が保たれている場面では、発話目的レベルでのズレが、対話の進行の中で参照され続けやすくなる可能性がある。これを本稿ではD2の早期参照と呼ぶ。

ミスアライメントの低減は、これとは別のメカニズムを通じて生じる可能性がある。D2の早期参照が、ズレが確定する前にその可能性を保持し続けることであるのに対し、ミスアライメントの低減は、その保持された可能性が実際の返答にどう反映されるかという結果に関わる。7-1で述べたように、候補保持継続は返答の内容だけでなく返答戦略にも影響を与える可能性がある。ある解釈のみを前提とした返答は、その前提が誤っていた場合、対話の継続を困難にする。複数の候補を踏まえた返答は、特定の解釈が外れていた場合でも、対話が破綻せずに続く余地を残しやすい。

したがって、D2の早期参照とミスアライメントの低減は、同じ候補保持継続というメカニズムから生じる、異なる二つの効果として位置づけられる。前者はズレの可能性が見失われないことに関わり、後者はそのズレが対話全体に与える影響の大きさに関わる。両者は連動しうるが、一方が他方を保証するものではない。D2の可能性が早期から参照され続けていたとしても、その後の返答が単一の解釈のみに基づいて構成されれば、ミスアライメントは依然として生じる可能性がある。

このため、本稿では両者を一つの節で扱うが、同一の現象として一括りにするのではなく、候補保持継続が持つ二つの異なる側面として記述する。

7-3. クレーム対応応用

これまでの章で検討してきた候補保持継続は、対人支援の場面において具体的な形を取りうる。本節では、クレーム対応の場면을例に、この応用可能性を検討する。

「もういい！」という発言を例に考える。この発言を受けた対応者が、本当に対応を終わらせたいという意味だと意味づけた場合、対応はそこで終了される。しかしその後、本社への問い合わせや公開レビューといった形で、対応への不満が後から表面化するケースがある。終了したはずの対応が、実際には終わっていなかった可能性がある。

逆に、対応者がこの発言を、感情的に強い言葉を選んだだけで実際には説明の継続を求めていると意味づけた場合、説明が続けられる。しかしこの場合も、「だからもういいって言っているのに」という新たな不満が生じることがある。

いずれの対応も、表面的には妥当に見える。問題は、対応そのものの質ではない。問題は、「もういい！」という一つの発言の背後に、複数の発話目的が同時に存在しうるという可能性が、対応の時点では一つに絞られてしまっていたことにある。

B2的处理では、この発言がどの意味として受け手側に意味づけられるかによって、対応が構成される。重要なのは、発話者が実際にどう感じていたかではなく、受け手側がその発言をどう解釈したかである。受け手側の意味づけが、発話者の発話目的候補と大きく異なる場合、ズレが生じる可能性がある。

この発言の背後には、複数の発話目的が同時に存在しうる。本当に対応を終わらせたい、感情的に強い言葉を選んだだけで実際には対応の継続を望んでいる、対応者そのものを信用できなくなっている、別の解決策を求めている——これらは同一の発話から生じうる候補の一部に過ぎない。これらの候補は互いに独立しているとは限らない。対応者への不信が、対応終了の希望として表出している可能性もあれば、別の解決策を求める行動として現れている可能性もある。

B3的处理が機能する場面では、これらの候補のいずれか一つに早期に確定せず、複数の可能性を保持したまま返答が構成される。このとき返答が目指すのは、どの候補が正しいかを確定することではない。複数の候補のいずれであっても次の対話が機能する形を探すことである。

たとえば、「それでは、対応者を変更しましょうか」という返答が考えられる。この返答は、本当に終わらせたい候補を排除しない。感情的に言っただけで対応の継続を望んでいる候補にとっては、状況を一度リセットする機会になる。対応者を信用できなくなっている候補にとっては、その

不信に直接応える形になる。つまり、この返答は単一の候補を前提とせず、複数の候補のいずれが正しくても次のターンへ進める形で構成されている。

この返答に対する反応は、新たな情報として機能する。「そうじゃない」という返答からは、当初の候補とは異なる発話目的が示唆される。「上司を出してくれ」という返答からは、対応者個人への不信という候補が強く支持される。「もう誰に対応されても同じだ」「もう帰る」という返答からは、本当に終わらせたい、あるいは対応プロセス全体への不信という候補が強く支持される。いずれの場合も、候補は確定されるのではなく、新しい情報によって更新される。

このように、B3的处理における返答生成は、発話から候補保持、返答、そして次の発話による候補更新という過程を繰り返す構造を持つ可能性がある。7-1で述べたように、これは返答の内容だけでなく、その提示の経路にも関わる。返答の目的は、問題を即座に解決することではなく、複数の候補を保持したまま、次にどの候補が支持されるかを見極めるための情報を得ることに置かれている。

なお、こうした発言の背後にある不一致は、発話目的のレベルに留まらず、より多層的な構造を持つ可能性がある。表面的には同じ「不満」に見える発言であっても、その発生には複数の異なる層が関わっている可能性があり、この点については別稿(D2論文)で検討している。

7-4. 教育・コーチング応用

7-3で検討したクレーム対応の場面は、一回の対話の中で候補が更新されていく例だった。教育やコーチングの場面では、同じ相手との対話が継続的に行われるため、候補保持継続が機能する範囲はより長い時間軸に及ぶ可能性がある。

教育やコーチングの場面でよく見られる発言として、「わかりました」がある。この発言を受けた指導者が、これを「理解した」という意味だと意味づけた場合、次の話題へ進む。しかし、その後の評価や実践の場面で、理解していなかったことが初めて明らかになるケースがある。

ここで注意したいのは、このズレが必ずしも指導者の誤った意味づけだけから生じるわけではない点である。教育・指導の現場では、発話者自身が「理解した」と誤認しているケースがしばしば見られる。発話者は嘘をついているわけではなく、本人にとっては本当に理解したと感じられている。しかし実践や応用の段階になって、理解が不十分だったことが本人にも初めて明らかになる場合がある。この場合、ズレは指導者の意味づけの誤りとしてだけでなく、発話者本人の自己認識の誤りとしても存在している。

いずれの経路であっても、その場のやり取りは一見問題なく完結したように見える。しかしズレは、後の評価や実践の場面で初めて表面化する。

「わかりました」という発言の背後には、本当に理解した、理解が不十分なまま理解したと思い込んでいる、といった、自分自身の理解についての本人の認識のズレが存在しうる。また同時に、理解していないことを認めたくない、評価が下がることを懸念している、議論を早く終えたい、といった発話目的が存在する可能性もある。

B3的处理が機能する場面では、これらの候補のいずれか一つに早期に確定せず、複数の可能性を保持したまま次の対応が構成される。このとき返答が目指すのは、どの候補が正しいかを確定することではない。複数の候補のいずれであっても、次のやり取りで判別できる形を探すことである。

たとえば、「では、今の内容を一度自分の言葉で説明してみてもらえますか」という対応が考えられる。この対応は、本当に理解した候補にとっては、理解の確認という形で機能する。理解が不十分なまま理解したと思い込んでいる候補にとっては、自身の理解を改めて確認する機会として機能する可能性がある。評価を懸念している候補にとっては、評価ではなく確認の場として提示されることで、答えやすさが残る。議論を終えたい候補にとっては、その意図とは異なる方向に進むが、次の反応によって、その候補が支持される可能性が高まる。

教育・コーチングの場面における候補保持継続のもう一つの側面は、時間軸の長さである。クレーム対応では、候補の更新は同一の対話の中で比較的短時間に進む。教育・コーチングでは、一度の対話で候補が確定しないまま、複数回のやり取りを経て徐々に絞られていく場合がある。ある回で「理解した」候補が支持され、別の回で「理解が不十分だった」候補が支持される、というように、候補の支持関係が複数の対話をまたいで更新され続ける可能性がある。

このため、教育・コーチングの場面でB3的处理が機能するなら、それは単一の対話内での候補更新だけでなく、複数回の対話を通じた長期的な候補保持としても現れる可能性がある。

7-5. AIアライメントへの示唆

7-1で述べたように、単一解釈ロックが固定するのは解釈だけではない。その解釈に基づいて生成される返答の経路もまた、同時に固定される。これはAIシステムにおいても同様に生じる可能性がある。

たとえば、ユーザーが論理的な飛躍を含む主張や、倫理的に異論が生じやすい主張を強く述べた場面を考える。AIがその主張を一つの解釈へ早期に収束させ、その解釈に基づいて訂正や否定を返した場合、応答として論理的・倫理的には妥当であっても、対話はそこで閉じる方向に進みやすい。ユーザーがなぜその主張に至ったのか、どのような経験や前提がその主張を支えているのかは、参照されないまま終わる。これは、7-3で検討した「もういい」への単一解釈に基づく対応や、7-4で検討した「わかりました」を字義通りに受け取る対応と、構造的に同じものである。

B3的处理が機能する場合、返答はこの単一の確定判断に基づいて構成されるのではなく、複数の発話目的候補を保持したまま、次の情報が得られる形で構成される可能性がある。たとえば、その主張に至った経緯を問う、どのような状況を想定しているのかを尋ねる、といった返答が考えられる。これらの返答は、どの候補が正しいかを即座に確定するものではない。ユーザーの応答そのものを、候補を絞り込むための新しい情報として得るための返答である。

この違いは、AIアライメントを安全性という抽象的な水準だけでなく、対話設計やHuman-AI Interactionという、より具体的な水準から捉え直す視点を提供する可能性がある。7-3および7-4で一貫して見てきたように、B3的处理が目指すのは、正しい解釈に到達することではなく、どの候補が正しくても次の対話が機能する経路を返答の中に残しておくことである。単一解釈ロックが返答の経路を狭めるのに対し、B3的处理はその経路の選択肢を保持する方向に働く可能性がある。

これは、ミスアライメントを即座に解消する機構ではない。5-4で述べたように、B3は誤りを防ぐ機構ではなく、保持される候補自体が誤っている可能性は常に残る。しかし、対話の経路が早期に一つへ固定されることを防ぎ、ユーザーの理論構造や前提を参照し続ける余地を残すという点で、B3的处理は対話の継続性そのものに関わる可能性がある。

なお、実際の認知的ミスアラインメントは、発話目的レベルだけでなく、より多層的な構造を持つ可能性がある。この点については別稿(D2論文)で扱う。

なお、B3によって生成された返答を相手にどう伝えるかについては、COSにおけるCシリーズ(伝達戦略プロセス)が担う領域である。本稿ではB3を中心に扱うため、Cシリーズについては別稿で検討する。

8. ハビタット要件

本稿で提示した仮説は、個人観測だけでは検証できない。B3仮説を検証するためには、継続観察と比較実験が可能な環境(ハビタット)が必要となる。

8-1. なぜハビタットが必要なのか

本稿を通じて提示してきたB3仮説は、現時点では未検証である。観測されたのは、発話目的を複数の仮説として保持し続ける処理が存在する可能性であり、その処理が実際に機能するのか、どのような条件のもとで機能するのか、どの程度の効果を持つのかは、まだ確認されていない。

この仮説を検証するためには、単発的な観測では不十分である。B3的処理が候補保持継続として機能しているのか、あるいは別の処理によって同様の結果が生じているのかを区別するためには、対話の進行中に何が起きているかを外部から記録し、照合できる環境が必要になる。また、B3的処理が機能した場合とそうでない場合を比較するためには、同一の発話に対して異なる処理が行われる条件を設定できる環境が必要になる。

さらに、7章で検討した応用可能性——クレーム対応、教育・コーチング、AIアライメント——が実際に機能するかどうかを確認するためには、それぞれの領域における継続的な観測と失敗事例の蓄積が必要になる。

以下の節では、B3仮説の検証に必要なハビタットの要件を整理する。

8-2. 発話目的照合環境

B3仮説の検証において最も重要な要件のひとつは、発話目的の照合が可能な環境である。

B3が扱う発話目的は、外部から直接観測することができない。これはB3仮説の根本的な前提であると同時に、検証を困難にする最大の要因でもある。

この困難を部分的に解消するためには、発話者自身による事後報告や、長期観測による照合が可能な環境が必要になる。たとえば、対話終了後に「あの発言で本当に伝えたかったことは何

か」「あの時点で何を求めていたか」を発話者本人に確認できる仕組みがあれば、B3が保持していた候補群と、発話者が報告した発話目的を照合することが可能になる。

ただし、この照合には限界がある。発話者自身が自分の発話目的を正確に把握していない可能性がある。7-4で検討したように、本人の自己認識と実際の状態がずれているケースは、教育・コーチングの場面でも観測されている。発話目的の報告は、事後的な再構成である可能性を排除できない。発話者による報告は、正解としてではなく、照合のための参照点として扱われる必要がある。

それでもなお、発話目的照合環境は不可欠である。完全な照合が不可能であっても、候補群と報告の間に体系的な対応関係が存在するかどうかを確認することは、B3仮説の検証において最重要の観測点となる。

8-3. 失敗ログ収集環境

B3仮説の検証において、成功事例と同等以上に重要なのが失敗事例の収集である。

本稿が扱ってきた候補喪失問題や単一解釈ロックは、対話が「うまくいった」場面では観測しにくい。ズレが表面化するののは、候補が早期に消去されたことによって対話が破綻した場面、あるいは後から別の発話目的が正しかったと判明した場面である。つまり、B3的处理が機能しなかった事例こそが、仮説の検証において最も重要な観測対象となる。

特に重要なのは、D2が観測された対話のログである。5章で述べたように、仮説の早期確定はD2の一因である可能性がある。D2が観測された対話を遡ることで、どの時点でどの候補が参照されなくなったのかを確認できる可能性がある。このようなD2ログの蓄積は、候補保持継続が機能しなかった条件を特定するための材料となる。

ただし、失敗ログの収集にも限界がある。対話の参加者が失敗として認識しない場合、ログとして記録されない可能性がある。また、失敗の原因がB3的处理の欠如によるものなのか、それとも別の要因によるものなのかを切り分けるためには、他の要件との併用が必要になる。

失敗ログの蓄積は、B3仮説が機能する条件と機能しない条件を明確にするための基盤となる。成功事例だけでは、B3的处理がいつ、なぜ機能しないのかを説明できない。

8-4. 仮説比較環境

B3仮説の検証において、候補保持継続が実際に起きているかどうかを確認するためには、対話過程を外部から比較・照合できる環境が必要になる。

特に重要なのは、候補保持継続と後付け生成を区別できる環境である。対話終了後に「最初の候補は何だったか」と問う方法だけでは、実際に候補が保持されていたのか、その場で新たに生成し直されたものなのかを区別できない。候補保持継続が本当に起きていたのかを確認するた

めには、対話の進行中に候補をターンごとに外部記録し、後から照合できる観測環境が必要になる。

また、同一の発話に対してB1・B2・B3それぞれの処理がどのように異なる返答を生成するかを比較するためには、処理の条件を制御できる環境が必要になる。自然な対話の中では、どの処理が行われているかを外部から判断することは難しい。比較実験が可能な環境があることで初めて、B3的処理が他の処理と異なる結果をもたらすかどうかを確認できる。

なお、ターンごとの外部記録と他の要件を組み合わせることで、候補保持継続と発話者報告との対応関係を観測できる可能性がある。

8-5. 長期観測ログ環境

B3仮説の検証において、単発的な対話の観測だけでは見えない現象がある。候補保持継続による影響は、一回の対話の中だけでなく、複数回の対話をまたいで観測される可能性がある。7-4で検討したように、教育・コーチングの場面では候補の支持関係が複数回の対話をまたいで更新され続ける可能性がある。この種の現象を観測するためには、長期にわたる継続的な観測環境が必要になる。

長期観測が必要な理由はもう一つある。B3的処理が機能しなかった場合の影響は、即座に表面化しないことがある。3-4で述べた候補喪失問題と同様に、ズレは対話の積み重ねの中で蓄積し、後になって別の形で表面化する可能性がある。単発的な観測では、この蓄積プロセスを捉えることができない。

長期観測ログ環境に求められるのは、対話の記録を時系列で保持し、後から特定の時点に遡って照合できる仕組みである。特定のターンで候補が参照されなくなったように見える場合、それ以前の対話との関係を遡って観測できることが重要になる。

ただし、長期観測には倫理的な配慮が必要になる。対話ログの収集と保持には、対話参加者の同意と、データの管理方針が不可欠である。これらは長期観測環境そのものの成立条件となる。この点は、ハビタットの設計において事前に整理される必要がある。

8-6. 高D2観測者

B3仮説の検証において、観測環境だけでなく、観測者の質も重要な要件となる可能性がある。

D2は分類に先行して感知される可能性がある。「何かがズレている」という未分解の違和感が先に発火し、その後に分類・言語化が行われる。この感知が起動するかどうかは、観測者によって異なる。同じ対話であっても、感知閾値が高い観測者はズレを早期に捉えられる可能性があるが、感知閾値が低い観測者はズレが大きく顕在化するまで感知自体が起動しないことがある。この点については別稿で詳しく扱う。

B3仮説の検証においては、D2を高い感度で感知できる観測者の存在が有用である可能性がある。候補が参照されなくなった時点特定するためには、対話の中でどこにズレが生じたかを感知できる観測者が、そのズレを記録し言語化できることが求められる可能性がある。現時点では、機械的なログ収集のみで同様の観測が可能かどうかは明らかではない。

ただし、この種の観測者要件にも限界がある。観測者自身の前提や状態が、観測結果に影響を与える可能性がある。SCOPEによる推定は観測者依存性を持つ可能性がある。そのため、複数の観測者による多角的な観測が、単一観測者による観測より信頼性が高い可能性がある。

本稿の観測は、単一観測者によるN=1観測に基づいている。高D2観測者という概念自体の妥当性についても、今後の検証が必要である。複数観測者による検証は、8-8で述べる研究者ネットワークとも関連する。

8-7. 実装エンジニア

B3仮説の検証において、理論的な枠組みを実際に動作するシステムとして構築するためには、実装エンジニアの存在が必要になる可能性がある。

6章で検討したB3外部実装仮説は、B3的处理をLLMの内部だけでなく、外部構造として実現できる可能性を示した。しかしこの可能性が実際に機能するかどうかを確認するためには、プロトタイプを構築し、動作を観測できる環境が必要になる。理論的な記述だけでは、候補保持継続が実際にシステム上で起きているかどうかを確認することが難しい可能性がある。

そのためには、B3的处理の概念を理解し、それを観測可能な形でシステムへ落とし込める能力が必要となる。特に8-4で述べたターンごとの外部記録や、候補保持継続と後付け生成を区別するための仕組みは、実装上の設計を必要とする。

ただし、実装エンジニアの役割はプロトタイプ構築にとどまらない可能性がある。実装の過程で、理論的には想定していなかった問題が発見される可能性がある。その意味で、実装エンジニアは検証環境の構築者であると同時に、仮説の精緻化に関わる観測者としても機能しうる。

8-8. 研究者ネットワーク

B3仮説の検証において、単一の観測者や単一の専門領域だけでは捉えきれない側面がある。異なる専門性と視点を持つ研究者が連携することで、仮説の多角的な検証が可能になる可能性がある。

本稿が扱うB3仮説は、認知科学・言語学・自然言語処理・HCI・対話設計など、複数の領域にまたがる問題を含んでいる。たとえば、候補保持継続が認知的にどのように実現されるかという問いは認知科学の領域に関わる。LLMにおける実装可能性は自然言語処理の領域に関わる。対話の継続性やUXへの影響はHCIや対話設計の領域に関わる。これらを単一の研究者が網羅することは容易ではない。

また、8-6で述べたように、観測者依存性の問題がある。単一の観測者による観測結果が、観測者自身の前提や状態に影響されている可能性を排除するためには、異なる前提と専門性を持つ複数の研究者による、相互に照合可能な観測が必要になる可能性がある。

さらに、本稿が提示した仮説に対する批判的な検討も、研究者ネットワークの重要な機能のひとつである。仮説の弱点や見落としを指摘できる研究者の存在は、仮説の精緻化において不可欠な役割を果たす可能性がある。

本稿はN=1観測から始まった仮説である。この仮説が検証可能な理論へと発展するためには、異なる視点からの観測と批判的検討が可能な研究者ネットワークだけでなく、8-2から8-7で述べた各要件を統合したハビタットの構築が必要になる可能性がある。

8-9. 資金

8-2から8-8で述べてきた各要件は、いずれも検証環境の構築と継続運用を前提としている。そのため、これらの要件を実際に維持するための基盤についても考慮する必要がある。継続的な運用には、それを支える資金基盤が必要になる可能性がある。

特に長期観測(8-5)と研究者ネットワーク(8-8)は、単発的なプロジェクトでは対応が難しい可能性がある。B3仮説の検証には、複数回の対話にまたがる観測と、異なる専門領域の研究者が継続的に関与できる環境が必要になる可能性がある。これらは短期間で完結する検証には馴染まない性質を持つ。

現時点では、本稿で想定するハビタットを継続運用できる資金基盤は確立されていない。この現状は8-10で述べる。

8-10. 現状

本稿で提示したB3仮説は、現時点では未検証である。

観測されたのは、発話目的を複数の仮説として保持し続ける処理が存在する可能性である。その処理が実際に機能するのか、どのような条件のもとで機能するのか、どの程度の効果を持つのかは、まだ確認されていない。本稿は、観測と推論の記録であり、検証された理論ではない。

8-2から8-9で述べてきたハビタット要件は、この仮説を検証可能な理論へと発展させるために必要な条件の整理である。発話目的照合環境、失敗ログ収集環境、仮説比較環境、長期観測ログ環境、高D2観測者、実装エンジニア、研究者ネットワーク、そして資金基盤——これらはいずれも、現時点では整っていない。

しかしこの現状は、B3仮説が観測不可能であることを意味しない。N=1観測から始まった仮説であっても、それが観測可能な現象を指し示しており、検証可能な形で記述されているなら、ハビタットが整う条件のもとで検証される可能性を持つ。

本稿が示すのは、検証された事実ではなく、検証を待つ仮説である。観測と推論をここに記録し、検証環境が整う日に備える。