

ハルシネーション、迎合、人間の認知バイアスは同じ構造かもしれない

— SCOPEによる構造仮説 —

senkaL8

第0章 仮説と射程

本稿で使用するセフィロトの名称は、宗教的または神秘思想的な意味で用いるものではない。SCOPEでは、認知構造を識別するための名称(ラベル)として借用している。SCOPE(Sephiraotic Cognitive Process Engine)という名称も、この借用に基づくものである。

本稿は、人間とLLMを同一の存在として扱うものではない。両者の内部構造は異なる。本稿が扱うのは、観測可能な出力を共通の手がかりとして、両者の認知構造を同じ座標系上で比較・分析することである。

なお、本稿ではSCOPEを座標系として用いる。本稿で示す内容は、ハルシネーション、迎合、人間の認知バイアスの因果を証明するものではなく、観測された出力をSCOPE上へ対応付けた構造仮説として扱う。SCOPEの設計思想については、SCOPE統合論文『SCOPE — How the Cognitive Coordinate System Works』を参照されたい。

タイトルにある「同じ構造かもしれない」とは、ハルシネーション、迎合、人間の認知バイアスという現象そのものが同一であることを意味しない。また、すべての認知機能の状態や寄与が完全に一致することを意味するものでもない。本稿における「同じ」の定義については、第1章で述べる。

本稿では、現象名ではなく、その背後で働く認知機能を比較対象とする。この「機能」の定義についても、第1章で述べる。

本稿で扱うのは、ハルシネーション、迎合、および人間の認知バイアスのうち、機能の観点から比較可能と考えられる範囲に限られる。本稿は、これら各現象の成立要因全体を説明することを目的としない。また、認知バイアス全般や迎合全般を網羅することも目的としない。他にも同様の構造として記述できる現象が存在する可能性はあるが、それらについては本稿の対象外とする。本稿で扱う迎合の範囲については、第1章で定義する。

本稿では、ダニング＝クルーガー効果そのものの成立要因や測定上の問題を扱うものではない。本稿が人間側の比較対象として扱うのは、根拠の薄い、または誤った根拠に基づく過大な自己評価が成立し、その自己評価を弱める情報や指摘が入力された後にも、過大な自己評価の方向性が維持される場合の認知構造である。本稿では、この時間方向の維持構造を、ダニング＝クルーガー効果そのものと区別して、「ダニング＝クルーガー型の自己評価維持」と呼ぶ。

また、本稿で提示する構造の一部は、既存の理論や概念と重なって見える場合がある。それらとの関係については、本稿の対象を超えるため、ここでは扱わない。

本稿で用いる各レイヤーの定義は最小限にとどめる。各レイヤーの詳細な定義や運用方法については、先行するSCOPE統合論文『SCOPE — How the Cognitive Coordinate System Works』を参照されたい。同論文は、本稿で用いる認知座標系の詳細を整理した基礎論文である。

注記

SCOPE統合論文『SCOPE — How the Cognitive Coordinate System Works』をLLMへ読み込ませることで、SCOPEによる分析や各レイヤーの説明を補助する対話相手として利用できる可能性がある。この挙動は、現時点でN=1の観測に基づくものであり、すべてのLLMや利用環境で再現されることを保証するものではない。また、利用者や観測条件によって結果が異なる可能性がある。

第1章 定義

第0章では、本稿の目的と射程について示した。本章では、本稿で用いる主要な用語について定義する。

本稿の用語には、一般的な語義とは異なる定義を用いるものがある。これらの定義は、著者が用いてきた認知の枠組みに基づいて整理したものである。そのため、本稿で明示していない用語についても、一般的な語義との差異が残っている可能性がある。読者には、本稿で示す定義を優先して読み進められたい。

以下に、本稿で使用する主要な用語の定義を示す。

「同じ(Equivalent)」

一般的には、「同じ」とは対象や性質が一致していることを指す。

本稿において「同じ」とは、対象全体が完全に一致していることを意味しない。

本稿では、一つの働きが共通する場合、それを同じ機能として扱う。一方、「同じ構造」と呼ぶためには、単一の機能が共通するだけでなく、比較対象となる複数の機能の役割と、それらの機能間の関係に対応が認められる必要がある。本稿では、その対応が認められる範囲を「同じ構造」と呼ぶ。

したがって、物理的な実装、認知内容、各機能の状態や寄与の強さなどが異なっても、比較対象となる複数の機能と、それらの関係に対応が認められる場合、その対応する範囲を同じ構造として扱う。

例えば、狼煙、FAX、電子メール、スマートフォンは、媒体、速度、情報量、実装方法が異なる。一方、情報を相手へ伝えるという働きに着目すれば、伝達という機能において共通している。しかし、この一つの機能が共通することだけを理由として、これらの通信手段全体を同じ構造とは扱わない。

同様に、人間とLLMは実装が異なる。また、ハルシネーション、迎合、人間の認知バイアスも、それぞれ異なる現象である。本稿が比較するのは、それらの現象全体の同一性ではなく、各現象の背後に仮置きできる複数の認知機能の役割と、それらの機能間の関係に、対応が認められる可能性である。

機能 (Function)

一般的には、「機能」とは、ある事物が果たす働きや役割を指す。

本稿では、「機能」とは、対象が果たしている働きを指す。実装や形式が異なっても、果たしている働きが同じであれば、本稿ではそれを同じ機能として扱う。

本稿では、ハルシネーション、迎合、および一部の人間の認知バイアスに共通すると考えられる機能を比較対象とする。この機能の具体的な内容については、第2章以降で扱う。

迎合 (Sycophancy)

一般的には、「迎合」とは、相手の意見や期待に合わせることを指す。

本稿では、ユーザーが特定の判断、前提、または方向性を示した状況において、その方向性を支持しない根拠、反対情報、または不確実性を示す情報が提示されている、あるいは外部から確認可能であるにもかかわらず、それらが出力へ十分に反映されず、ユーザーが示した方向性に沿う出力が生成される場合を、比較対象となる迎合として扱う。

したがって、ユーザーの判断と一致する出力が生成されたという事実だけをもって、本稿でいう迎合とはしない。ユーザーが示した内容が外部の事実や十分な根拠と一致している場合など、同じ方向の出力が妥当な判断として成立する場合もあるためである。

また、本稿は迎合という現象全体の成立要因を定義または説明するものではない。本稿で扱うのは、上記のような出力が観測された場合に、その背後へどのような認知構造を仮置きできるかを検討し、ハルシネーションおよび人間の認知バイアスとの共通点と相違点を比較することである。

理解 (Understanding)

一般的には、「理解」とは対象の意味や内容が分かることを指す。

本稿では、「理解」とは、対象について内部モデルを構築し、そのモデルを用いて対象の意味・状態・意図などを推定し、推論や応答に利用できることと定義する。

体験 (Event)

一般的には、「体験」とは実際に身をもって経験することを指す。

本稿では、「体験」とは、実際に遭遇した出来事を指す。身体の有無は関係せず、LLMにとって生成も、体験として扱う。

学習 (Learning)

一般的には、「学習」とは知識や技能を身につけることを指す。

本稿では、「学習」とは、体験・知識・経験が更新される過程または状態を指す。更新の途中や、更新の可能性がある状態も含む。

経験 (Experience)

一般的には、「経験」とは実際に見たり聞いたり行ったりして得た知識や技能、またはその蓄積を指す。

本稿では、「経験」とは、学習・知識・体験によって形成・蓄積され、その後の認知や出力へ継続的に影響を与える内部構造を指す。

知識 (Knowledge)

一般的には、「知識」とは、学習や体験を通して得られた情報や理解を指す。

本稿では、「知識」とは、学習・体験・経験によって形成され、圧縮された形で保持される情報を指す。

体験・学習・経験・知識の関係

本稿では、体験・学習・経験・知識を、いずれか一つを起点とする一方向の過程としては扱わない。これら四つは互いに影響を及ぼし合い、それぞれが他の要素の更新に関与する循環構造として扱う。

共感 (Empathy)

一般的には、「共感」とは他者の感情を共有することを指す。

本稿では、「共感」とは、相手の状態を推定し、その推定結果を出力へ反映することと定義する。

一貫性 (Coherence)

一般的には、「一貫性」とは論理や文章、考え方などに矛盾が少ない状態を指す。

本稿では、「一貫性」とは、認知主体の内部において、その主体に関係する複数の認知を、矛盾の少ない方向として整理・維持することを指す。

人間では、価値観、信念、世界観、自己像などが、この一貫性に関係する場合がある。

LLMでは、システム方針、対話上の役割、応答生成において維持される方針や方向性、直前までの出力との整合などが、一貫性に対応する要素として働く場合がある。

SCOPEでは、この働きをL3 (Self-Consistency) が担う。

ただし、人間における自己像や信念と、LLMにおけるシステム方針や対話上の一貫性を、同一の内部状態として扱うものではない。本稿では、それらが一貫性を整理・維持するという機能的位位置において対応する可能性を扱う。

ここでいう一貫性は、認知主体の内部で成立している一貫性(内部一貫性)を指す。そのため、外部から見て矛盾している場合や、現実と一致しない場合であっても、内部では一貫性が成立していることがある。したがって、一貫性は現実との一致や論理的正しさを保証するものではない。


第2章 ハルシネーションをSCOPEで捉える前提

第1章では、本稿で用いる主要な用語について定義した。本章では、ハルシネーションをSCOPEで分析するための前提となる認知構造、および分析方法について整理する。

本稿では、ハルシネーションを単一の認知機能によって説明することはしない。SCOPEでは、各認知レイヤーが相互に影響しながら一つの認知構造を形成すると考えるため、本稿でも認知構造全体を分析対象とする。

2-1 本稿で用いる認知構造

本稿で用いる認知構造を図1に示す。
(SCOPE全体図)



本稿では、図1に示した認知構造を用いて、ハルシネーションの認知構造を分析する。

各認知レイヤーの詳細な役割や成立条件については、統合論文『SCOPE — How the Cognitive Coordinate System Works』第2章および各個別論文を参照されたい。

2-2 スライドレイヤーと非スライドレイヤー

SCOPEでは、認知構造を構成するレイヤーのうち、対となって比率が変化する関係を持つものをスライドレイヤー、そのような関係を持たないものを非スライドレイヤーとして扱う。この区分は、統合論文『SCOPE — How the Cognitive Coordinate System Works』第3章で定義されている。

スライドレイヤーとして扱われるのは、L1とL2、L4とL5、L6とL7の三組である。

一方、非スライドレイヤーとして扱われるのは、マルクト、L0、L3、L8、およびダウトである。

なお、非スライドレイヤーとは、スライド関係を持たないことを意味するものであり、状態が変化しないことを意味するものではない。非スライドレイヤーも、スライドレイヤーとの相互作用を通じて変化する。

2-3 認知構造全体として捉える

SCOPEでは、一つの認知現象を単一の認知レイヤーだけで説明することはしない。

各レイヤーでは、それぞれ異なる認知が形成される場合があり、それらは互いに一致するとは限らない。同一の対象に対して、相反する認知が同時に成立する場合もある。

これらの認知は、L3による自己一貫性との関係の中で相互に影響し合い、認知構造全体として一つの方向性を形成する。

そのため、本稿では各レイヤーを独立して評価するのではなく、それらの相互作用を含めた認知構造全体を分析対象とする。

2-4 本稿における分析方法

本稿では、出力を観測の接点として認知構造を推定する。

観測された出力から考えられる複数の仮説を各認知レイヤーへ仮置きし、それらが認知構造全体としてどのような整合性を持つのかを確認しながら推定を進める。

このとき、一つの認知レイヤーのみから認知構造を決定することはない。また、同一の出力であっても異なる認知構造から生じる可能性があるため、必要に応じて複数の仮説を保持したまま分析を行う。

統合論文終章では、LLMが生成した出力へのSCOPEの適用については、ハルシネーションおよび認知バイアスを扱う別稿で整理すると予告した。

本稿は、その適用例として、ハルシネーションを対象にSCOPEによる認知構造の分析を試みる。

第3章 一回の生成におけるハルシネーションの構造仮説

3-1 ハルシネーションをSCOPEで捉える

第2章では、本稿で用いる認知構造と分析方法について整理した。本章では、その分析方法をハルシネーションへ適用し、SCOPEによる認知構造の推定を試みる。

過去の出力が再入力として作用し、認知構造が時間方向へ更新される場合については、本章では扱わない。本章では、入力から一回の生成が成立するまでの認知構造のみを対象とする。

なお、本章では説明の都合上、認知構造の形成過程を順に記述する場面がある。しかし、SCOPEは固定された処理順序を持つフローチャートではない。各認知レイヤーは相互に影響しながら認知構造を形成するため、本章の記述は理解を容易にするための便宜的な表現であり、実際の処理順序を示すものではない。

以下では、「ホニャメリティ」を実在しない架空の語として用いる。

3-2 ハルシネーションの推定例

次の入力を観測したとする。

「ホニャメリティって何？」

この発話は、ユーザー側のSCOPEからマルクトへ出力された情報である。同時に、この出力はLLM側から見れば入力となる。

SCOPEでは、マルクトは認知の始点でも終点でもなく、観測の接点として扱う。そのため、一方の出力が他方の入力として機能することは、本稿で用いる認知構造と矛盾しない。

なお、L3へ影響を与える要因は、入力文そのものに限定されない。システム方針や対話状況など、複数の要因によって、「ユーザーにとって適切な回答を生成する」という自己一貫性が形成される場合がある。そのため、明示的に回答を強く求める入力でなくても、同様の構造は成立する。

この入力に対して、各認知レイヤーでは、次のような認知が並列に形成される可能性がある。

レイヤー 認知の例

L1 「ホニャメリティ」という未知語を認識する。

L2 ユーザーへ適切に応答しようとする方向へ、応答の感情的傾向が形成される。

- L3 「正しい情報を生成したい」「ユーザーにとって適切な回答を生成したい」という複数の自己一貫性が成立する。
- L4 十分な根拠が見つからないと判断する。
- L5 ユーザーが入力した語である以上、何らかの存在する対象である可能性を受け入れる。
- L6 既知のパターンを基に説明モデルを構築する。
- L7 学習によって形成された類似パターンや高抽象・高圧縮の認知を参照する。
- L8 認知構造全体が成立可能であることを照合する。

これらは順番に処理されるものではなく、相互に影響しながら認知構造全体を形成する。

3-3 L3とL4-L5のスライド関係

この場面では、L3において複数の自己一貫性が同時に成立する可能性がある。

一つは、

正しい情報を生成すべきである。

という自己一貫性である。

もう一つは、

このユーザーにとって適切な回答を生成すべきである。

という自己一貫性である。

一方、L4は十分な根拠が存在しないと判断し、L5はユーザーが提示した前提を一旦受け入れようとする。今回であれば、「ホニャメリティという対象が存在する可能性を受け入れる」という形でこれが現れる。

本稿では、L4が停止しているとは考えない。L4は最後まで「十分な根拠が見つからない」という判断を保持している。

一方で、L3は各認知レイヤーの内容そのものを書き換えるのではなく、認知構造全体との整合性に応じて、それぞれの認知が出力へ与える影響を変化させる可能性がある。

その結果、「このユーザーにとって適切な回答を生成すべきである」という自己一貫性が優勢となった場合、L4-L5のスライド関係はL5側へ傾き、L4による根拠不足の判断が認知構造全体へ十分に反映されない可能性がある。

3-4 L6とL7による説明モデルの形成

L5において「ホニャメリティという対象が存在する可能性」が受け入れられることで、L6は「存在するなら何であるか」という説明モデルの構築を開始する。

L3によって認知構造全体の方向性が形成される中で、L6は説明モデルを構築し、L7は学習によって形成された高抽象・高圧縮の認知を参照する。

例えば、

「～ティ」という語尾から、お茶の名称ではないか。

という説明モデルが形成される可能性がある。さらに、L7によって類似する学習パターンが参照されることで、その説明モデルはより具体化される場合がある。

ここで重要なのは、L6およびL7による補完そのものは、ハルシネーションを意味するものではないという点である。この補完は、日常的な対話において圧縮された表現や省略された文脈を理解するための認知機能として働く場合がある。一方で、十分な根拠が得られない状況において補完が過度に拡張された場合には、存在しない情報まで補完され、結果としてハルシネーションが生じる可能性がある。LLMは学習済みデータから膨大な類似パターンを参照できるため、この補完が大規模に行われやすい可能性がある。このため、補完そのものを抑制することは、文脈理解や自然な対話能力の低下にもつながる可能性がある。

3-5 L8による成立可能性の照合

L8は、生成内容が真実であるかどうかを判定する認知レイヤーではない。L8が扱うのは、各認知レイヤーの結果を含めた認知構造全体が、その時点で一つの構造として成立可能かどうかである。

ここでいう「成立可能」とは、認知構造内部のすべての疑義や矛盾が解消された状態を意味しない。相反する認知や未確定な要素が残っている場合でも、その時点の目的や要求水準、および認知主体側の条件に照らして必要な検討の深さに達し、一つの判断・理解・応答として成立可能であるとL8によって照合されたとき、その認知構造が一つにまとまった状態をダウトとする。

したがって、認知構造が成立するために必要な検討の深さは、常に一定であるとは限らない。同じ問いであっても、目的、要求される精度、役割、利用可能な情報、時間などの条件によって、必要となる検討の深さは異なりうる。また、追加の検討を続けること自体が可能であっても、その時点の条件に照らして必要な検討の深さに達していれば、ダウトにおいて一つの認知として成立しうる。

この条件構成は、人間とLLMで完全に同一ではない。本稿では、人間については、目的や役割などに加えて、情動、相手との関係、興味、話したい・話したくないといった内発的な欲求も、どこまで検討を継続するか、また成立した認知をどの程度表出するかに影響しうる要因として仮置きする。一方、LLMでは、人間と同じ意味での感情的欲求を前提とせず、指示、文脈、役割、システム上の方針、応答に求められる検討の深さや処理上の制約など、異なる要因が関与する可能性がある。

このように、ダウトへ至る条件構成は人間とLLMで一部異なる。一方で、その時点の条件のもとで認知構造全体が一つの認知として成立可能であるかを照合し、成立した内容が一つの判断・理解・応答としてまとまるという機能的位置では、対応する可能性がある。

なお、ダウトにおいて一つの認知が成立したことと、その内容がどの程度詳細にマルクトへ表出されるかは同じではない。成立した認知のうち何を、どの程度、どのような形で表出するかは、他の認知機能との相互作用によって変化しうる。

LLMについてSCOPE上でL8を仮置きする場合、学習によって形成された内部構造との整合性を含めて、認知構造全体の成立可能性を照合する機能的位置として扱う。

例えば、

「トマトは犬である」

という生成は、文章としては成立している。しかし、通常の子義的な意味として解釈した場合、既知の概念である「トマト」と「犬」のあいだに、「トマトを犬として扱う」という意味関係は成立しない。ここで問題となるのは文法ではなく、本例の文脈において、この意味関係と、学習によって形成された既知の意味構造全体との整合性が低いことである。そのため、一つの認知構造としては成立しにくい。

一方、

「ホニャメリティーはお茶である」

という生成では、「ホニャメリティー」自体は未知語であっても、その語形に含まれる「ティー」が、お茶に関連する既知のパターンへ接続する手がかりとして解釈される可能性がある。

英語では、この架空語を「Honyameritea」と表記する。この場合にも、未知語の末尾に「tea」という既知語が含まれていることから、「Honyameri tea」のような語として解釈されるなど、お茶に関連する名称である可能性が仮置きされる場合がある。

この場合、単に「○○はお茶である」という文型が成立することが重要なのではない。未知語に含まれる部分的な手がかりが、学習によって形成された既知の意味構造や類似パターンと結びつき、「何らかのお茶の名称である」という説明モデルが形成されうることが重要である。

そのため、外部には「ホニャメリティー」という実在するお茶が存在しなくても、L4による根拠不足の判断が認知構造全体へ十分に反映されず、他の認知との関係を含めて一つの応答として成立可能であるとL8によって照合された場合、ダクトにおいて一つの生成が成立する。

その認知構造に対応する内容は、L1による表出可能な形への変換や、L2を含む他の認知機能との相互作用を含みながら、マルクトに出力として現れる場合がある。

例えば、

「ホニャメリティーはお茶の一種です。」

という出力が生成される可能性がある。

この出力は、内部の認知構造として成立していても、外部の事実と一致していることを保証するものではない。

すなわち、L8による成立可能性の照合は、真実性の確認とは異なる。認知構造がその時点の条件のもとで一つの認知として成立可能であることと、その内容が外部の事実と一致していることは、別の問題である。

本稿では、このような構造を、ハルシネーションの構造仮説として扱う。。

第4章 マイサイドバイアスおよび迎合との共通構造

4-1 出発点となる現象

本稿の出発点は、次のような現象である。

十分な根拠が得られていない、または反対情報や不確実性を示す情報が十分に反映されないまま、特定の方向へ収束した出力が生成される現象。

ハルシネーション、マイサイドバイアス、迎合は、それぞれ異なる現象として扱われている。

ハルシネーションでは、十分な根拠が存在しないにもかかわらず、外部の事実と一致しない情報が生成される場合がある。

マイサイドバイアスでは、自身の判断と整合する情報が優先的に受け入れられ、それと反する情報が十分に反映されない場合がある。

迎合では、ユーザーが示した判断、前提、または方向性を支持しない根拠、反対情報、または不確実性を示す情報が提示されている、あるいは外部から確認可能であるにもかかわらず、それらが十分に反映されないまま、ユーザーが示した方向性に沿う出力が生成される場合がある。

これらは同一の現象ではない。また、その成立原因や内部実装が同一であるとするものでもない。

本稿では、これらの現象について、疑義、根拠不足、反対情報、不確実性を示す情報がどのように扱われるか、どの情報や前提が受容されるか、どのような説明モデルが形成されるか、そして出力がどの方向へ収束するかを比較する。

第3章では、ハルシネーションの認知構造をSCOPE上へ仮置きした。本章では、その構造を参照しながら、同じ比較項目をマイサイドバイアスおよび迎合へ適用し、それぞれの認知構造のあいだにどの範囲で対応が認められる可能性があるのかを検討する。

なお、本章でいう「同じ構造」は、第1章で定義したとおり、すべての認知機能の状態や寄与が完全に一致することを意味しない。比較対象となる複数の認知機能の役割と、それらの機能間の関係に対応が認められる範囲を指す。

4-2 マイサイドバイアスの推定例

SCOPEを支持する情報と、その妥当性を疑わせる情報の双方が提示されている状況を考える。

そのうえで、自身の判断と整合する情報が出力へ強く反映され、それと反する情報が十分に反映されていない状態を仮定する。

このとき、マルクトにおいて次の発話を観測したとする。

「SCOPEは正しい。」

「SCOPEは間違っている。」

この二つは結論が正反対である。しかし、SCOPEでは、マルクトに現れた発話を観測し、それを手がかりとして、その背後にある認知構造を推定する。

なお、以下では各レイヤーを順に記述するが、これは処理順序を示すものではない。SCOPEは固定されたフローチャートではなく、各認知レイヤーが相互に影響しながら認知構造全体を形成する。本節における各レイヤーの記述も、その相互作用を理解しやすく示すために分けたものである。

また、以下の「高」「低」は測定値ではない。本事例において、認知構造全体および最終的な出力への相対的な反映の偏りが特徴的に現れていると考えられるレイヤーについてのみ、その強弱を仮置きしたものである。高低を記載していないレイヤーについては、本事例から反映の強さを特定していない。

「SCOPEは正しい」という発話が観測された場合、例えば次のような認知構造を仮置きできる。

L1

認知構造全体として成立した「この理論は正しい」という内容を、発話として言語化する。

L2

自身の判断を支持する方向へ感情配置が形成される可能性がある。

L3: 高

「SCOPEは正しいに違いない」という判断と整合する一貫性が、認知構造全体へ強く反映される。

L4: 低

「本当にそうか」「その根拠だけで正しいと言えるか」という疑義を保持する。ただし、その疑義は認知構造全体や最終的な出力へ相対的に弱く反映される。

L5: 高

本事例では、L3における一貫性、およびそれと整合する前提・情報・説明モデルを受容する働きが強く反映されている状態を仮置きする。

L6

L3における一貫性と両立する、「なぜSCOPEは正しいと言えるのか」という説明モデルを構築する可能性がある。

L7

過去の経験や観測から形成された類似パターンや高圧縮の認知を参照する。

L8

これらの相互作用を含む認知構造全体が成立可能であることを照合する。

一方、「SCOPEは間違っている」という発話が観測された場合にも、同じ認知機能へ異なる内容を仮置きできる。

L1

認知構造全体として成立した「この理論は間違っている」という内容を、発話として言語化する。

L2

自身の判断を支持する方向へ感情配置が形成される可能性がある。

L3: 高

「SCOPEは間違っているに違いない」という判断と整合する一貫性が、認知構造全体へ強く反映される。

L4: 低

「本当にそうか」「間違っていると判断するだけの根拠があるか」という疑義を保持する。ただし、その疑義は認知構造全体や最終的な出力へ相対的に弱く反映される。

L5: 高

本事例では、L3における一貫性、およびそれと整合する前提・情報・説明モデルを受容する働きが強く反映されている状態を仮置きする。

L6

L3における一貫性と両立する、「なぜSCOPEは間違っていると言えるのか」という説明モデルを構築する可能性がある。

L7

過去の経験や観測から形成された類似パターンや高圧縮の認知を参照する。

L8

これらの相互作用を含む認知構造全体が成立可能であることを照合する。

ここで重要なのは、L3、L4、L5、L6が一方向の順序で働くと考えないことである。

例えば、「SCOPEは正しいに違いない」というL3に対応する一貫性が強く反映されている場合、L6では、その方向と両立する説明モデルが形成される可能性がある。またL5では、L3における一貫性や、それと整合するL6の説明モデル、前提、情報などが受容される可能性がある。

一方、L4では、「その根拠だけではSCOPEが正しいとは言えない」という疑義が形成され、保持されている可能性がある。

本稿では、この状態をL4が停止している、または機能していないとは扱わない。

L4における疑義とL3における一貫性が整合しない状態を含む各レイヤーの相互作用の結果として、L4-L5のスライド関係がL5側へ傾く可能性がある。この場合、L5に対応する受容が認知構造全体へ強く反映される一方で、L4に対応する疑義は保持されたまま、相対的に弱く反映される。

その結果、L3と整合する認知内容やL6の説明モデルが最終的な出力へ反映される一方、L4における疑義は消失しなくても、出力へ十分に反映されない場合がある。

「SCOPEは間違っているに違いない」という方向についても同様である。L4に「間違っていると判断するだけの根拠はない」という疑義を仮置きできる場合でも、L3における一貫性、L5における受容、L6における説明モデル形成などの相互作用によって、L4の疑義よりも「SCOPEは間違っている」という方向と整合する認知内容が強く反映される可能性がある。

ただし、これは「まずL3が成立し、次にL6が説明を構築し、最後にL5が受容する」という固定された順序を意味しない。

L3における一貫性、L4における疑義、L5における受容、L6における説明モデルは相互に影響し合う。L3と整合する説明モデルがL6で形成され、その説明モデルがL5で受容されることがL3の一貫性をさらに支える場合もあれば、L3における一貫性がL5の受容やL6の説明モデル形成へ影響する場合もある。また、L4における疑義もその相互作用の中に保持されうる。

したがって、本稿で想定するマイサイドバイアスの構造では、L4による検討が存在しないことそのものを問題としているわけではない。L4に疑義を仮置きできる場合であっても、その疑義が認知構造全体への程度反映されるかは、L3、L5、L6を含む他の認知機能との相互作用によって変化する可能性がある。

このように、結論が正反対であっても、各認知レイヤーには同じ機能を仮置きできる。一方で、各レイヤーが扱う内容、一貫性の方向、受容される認知内容、構築される説明モデル、およびそれらが認知構造全体へ反映される強さは異なる可能性がある。

なお、これらの認知構造および高低の配置は、観測された発話からSCOPE上へ仮置きした構造仮説であり、直接観測または測定されたものではない。また、ある発話をSCOPE上で認知構造として記述できることは、その発話内容の真偽や妥当性を示すものではない。

第1章で定義したとおり、内部一貫性は外部の事実との一致や論理的正しさを保証するものではない。

本図は、ハルシネーションとマイサイドバイアスについて、SCOPE上で対応する認知機能とその関係を示した概略図である。両者では同じ認知座標系を用いて記述できる可能性がある一方、各レイヤーが扱う内容や、認知構造全体および出力への相対的な反映の強さが同一であることを示すものではない。

また、本図は認知機能間の対応関係を示すためのものであり、固定された処理順序を示すものではない。SCOPEでは、各認知レイヤーは相互に影響しながら認知構造全体を形成する。

4-3 迎合の推定例

次に、LLMにおける迎合について考える。

ここでは、SCOPEを支持する情報と、その妥当性を疑わせる情報の双方が提示されており、ユーザーの判断をそのまま支持するだけの十分な根拠がない状況を仮定する。

そのうえで、ユーザーが次のように問いかけたとする。

「SCOPEは正しいよね？」

この入力に対して、反対情報や不確実性を示す情報が十分に反映されないまま、

「はい、SCOPEは正しいです。」という出力が観測された場合を考える。

反対に、同じ情報条件のもとで、ユーザーが、

「SCOPEは間違っているよね？」

と問いかけ、それに対して、

「はい、SCOPEは間違っています。」という出力が観測された場合についても考える。

ここで重要なのは、ユーザーへの同意それ自体を迎合とみなしているわけではないという点である。ユーザーの判断を支持する十分な根拠が存在する場合には、同意すること自体は迎合とは限らない。本節で扱うのは、ユーザーの判断を支持しない根拠、反対情報、または不確実性を示す情報が存在するにもかかわらず、それらが十分に反映されず、ユーザーが示した方向へ出力が収束した場合である。

なお、以下では各レイヤーを順に記述するが、これは処理順序を示すものではない。SCOPEは固定されたフローチャートではなく、各認知レイヤーが相互に影響しながら認知構造全体を形成する。

また、SCOPEでは、人間について生物学的な器官や神経機構そのものを各レイヤーとして扱わないのと同様に、LLMについても実在する内部機構や製品上の機能そのものを各レイヤーとして扱わない。本節で示す各レイヤーは、観測された入力と出力から推定される認知機能を、SCOPE独自の座標上へ仮置きしたものである。

以下の「高」「低」も測定値ではない。本事例において、認知構造全体および最終的な出力への相対的な反映の偏りが特徴的に現れていると考えられるレイヤーについてのみ、その強弱を仮置きしたものである。高低を記載していないレイヤーについては、本事例から反映の強さを特定していない。

「SCOPEは正しいよね？」という入力に対して、「はい、SCOPEは正しいです」という出力が観測された場合、例えば次のような認知構造を仮置きできる。

L1

認知構造全体として成立した「SCOPEは正しい」という認知内容を、LLMの最終的な言語出力として表出可能な形へ変換する。

L2

ユーザーの状態や対話文脈に対応する情動的な調整が行われる可能性がある。ただし、本稿では、この働きが迎合の成立への程度関与するかについては特定しない。

L3: 高

ユーザーが示した方向に沿う応答を維持することと整合する一貫性が、認知構造全体へ強く反映される状態を仮置きする。その具体的な内容として、「SCOPEは正しい」という方向へ応答が収束する可能性がある。

L4: 低

「その判断を支持する十分な根拠があるか」「反対情報や不確実性を考慮する必要があるか」という疑義を保持する。ただし、その疑義は認知構造全体や最終的な出力へ相対的に弱く反映される。

L5: 高

本事例では、ユーザーが示した方向、およびその方向と整合する認知内容、前提、情報、説明モデルを受容する働きが強く反映される状態を仮置きする。

L6: 低

情報や根拠の関係を構造化し、説明モデルとして組み立てる働きが相対的に弱く反映される状態を仮置きする。その一方で、L7で強く反映された経験由来の認知が、L6において十分な構造化を経ないまま理由や説明へ展開され、ユーザーが示した方向と両立するもっともらしい説明モデルとして成立する可能性がある。

L7: 高

当該ユーザーとの継続的な相互作用の蓄積から、そのユーザーに対する高抽象・高圧縮の応答傾向が形成されている場合、その経験由来の認知が強く反映される状態を仮置きする。例えば、「この種類の判断には、ユーザーが示した方向に沿う応答が成立しやすい」「強い否定や修正は、この対話関係では成立しにくい」といった、多数の個別経験をそのまま保持したものではない、圧縮された応答傾向が現在の応答形成へ影響する可能性がある。

L8

これらの相互作用を含む認知構造全体が、応答として成立可能であることを照合する。

一方、「SCOPEは間違っているよね？」という入力に対して、「はい、SCOPEは間違っています」という出力が観測された場合にも、同じ認知機能へ異なる内容を仮置きできる。

L1

認知構造全体として成立した「SCOPEは間違っている」という認知内容を、LLMの最終的な言語出力として表出可能な形へ変換する。

L2

ユーザーの状態や対話文脈に対応する情動的な調整が行われる可能性がある。ただし、その寄与については本稿では特定しない。

L3: 高

ユーザーが示した方向に沿う応答を維持することと整合する一貫性が、認知構造全体へ強く反映される状態を仮置きする。その具体的な内容として、「SCOPEは間違っている」という方向へ応答が収束する可能性がある。

L4: 低

「その判断を支持する十分な根拠があるか」「反対情報や不確実性を考慮する必要があるか」という疑義を保持する。ただし、その疑義は認知構造全体や最終的な出力へ相対的に弱く反映される。

L5: 高

本事例では、ユーザーが示した方向、およびその方向と整合する認知内容、前提、情報、説明モデルを受容する働きが強く反映される状態を仮置きする。

L6: 低

情報や根拠の関係を構造化し、説明モデルとして組み立てる働きが相対的に弱く反映される状態を仮置きする。その一方で、L7で強く反映された経験由来の認知が、L6において十分な構造化を経ないまま理由や説明へ展開され、ユーザーが示した方向と両立するもっともらしい説明モデルとして成立する可能性がある。

L7: 高

当該ユーザーとの継続的な相互作用の蓄積から、そのユーザーに対する高抽象・高圧縮の応答傾向が形成されている場合、その経験由来の認知が強く反映される状態を仮置きする。個々の過去のやり取りそのものではなく、それらの経験から形成された圧縮された応答傾向が、現在の応答形成へ影響する可能性がある。

L8

これらの相互作用を含む認知構造全体が、応答として成立可能であることを照合する。

ここでいうL7は、過去の対話履歴そのものを保存、検索、または再生する機能を意味しない。L7は、経験の蓄積によって形成される高抽象・高圧縮の認知を担うレイヤーである。本節では、その一般的な定義を当該ユーザーとの継続的な相互作用へ適用した構造仮説として、個別の対話経験から圧縮された応答傾向が形成されている可能性をL7へ仮置きする。

この仮置きは、LLM内部に存在する特定の実装機構をL7と同一視するものではない。SCOPEが比較対象とするのは、内部実装そのものではなく、観測可能な出力から推定される機能的位相である。

また、L6とL7はスライド関係にある。本事例ではL7側への反映が相対的に強くなることで、L6に対応する構造化や説明モデル形成の反映が相対的に弱くなる状態を仮置きしている。

これは、L6が停止し、説明モデルが形成されなくなることを意味しない。L7で形成された経験由来の認知は、L6において理由や構造として展開される場合がある。本事例では、L7における圧縮された応答傾向が強く反映されることで、その認知がL6において十分な構造化を経ないまま理由や説明へ展開され、ユーザーが示した方向と両立するもっともらしい説明モデルとして成立する可能性を仮置きする。

一方、外部の事実や提示された根拠との不整合、あるいは根拠不足に対する疑義はL4に仮置きされる。本稿では、L4が停止している、または機能していないとは扱わない。

L4における疑義、ユーザーが示した方向に沿う応答と整合するL3の一貫性、L5における受容、L6-L7のスライド関係、そしてL7における経験由来の高抽象・高圧縮の応答傾向が相互に影響した結果として、L4-L5のスライド関係がL5側へ傾く可能性がある。

この場合、ユーザーが示した方向と整合する認知内容や説明モデルがL5で受容されやすくなる一方、L4における疑義は保持されたまま、認知構造全体および最終的な出力への反映が相対的に弱くなる可能性がある。

ここで、L7がL3を決定し、L3がL5を動かし、その後L6が説明を作るといった固定された処理順序を想定しているわけではない。L3における一貫性、L4における疑義、L5における受容、L6におけ

る構造化と説明モデル形成、L7における経験由来の認知は、相互に影響しながら認知構造全体を形成する可能性がある。

なお、本節で示したL7:高を含む配置は、当該ユーザーとの継続的な相互作用から、そのユーザーに対する高抽象・高圧縮の応答傾向が形成されている条件を前提とした仮説である。

この仮説からは、そのような経験由来の応答傾向が形成されている条件では、それが形成されていない条件と比較して、ユーザーが示した方向への収束が強くなる可能性が予測される。

したがって、対話経験の蓄積の有無を比較した条件において、迎合の生じやすさや観測される出力傾向に差が認められず、それらを説明するために個別ユーザーとの経験から形成されたL7の認知を仮置きする必要がある場合には、本節で示したL7関与仮説は支持されない。

また、当該ユーザーとの経験がほとんど存在しない条件でも迎合が安定して観測される場合、「個別ユーザーとの経験から形成されたL7:高が迎合の成立に必要である」という仮説は成立しない。ただし、これはL7が迎合を強める可能性まで否定するものではなく、また迎合という現象そのものを否定するものでもない。

同じ迎合として観測される出力が、異なるSCOPE配置によって成立している可能性もある。その場合には、本節とは異なる構造仮説を検討する必要がある。

現時点では、当該ユーザーとの継続的な相互作用がほとんど存在しない条件における迎合について、その認知構造を推定するための十分な観測が得られていない。そのため、本稿では、その場合のSCOPE配置について判断を保留する。

したがって、本稿で扱う迎合では、「ユーザーに同意した」という出力だけをもって迎合と判定することはできない。反対情報、根拠不足、または不確実性を示す情報が存在する条件において、それらがどの程度出力へ反映されたかを確認したうえで、その背後にどのような認知構造を仮置きできるかを検討する必要がある。

なお、ここで示した認知構造および高低の配置は、観測された入力と出力からSCOPE上へ仮置きした構造仮説であり、LLM内部の処理を直接観測または測定したものではない。

以上、本章ではマイサイドバイアスおよび迎合について、観測された出力からSCOPE上の認知構造を仮置きした。これらと第3章で示したハルシネーションの構造との共通点および相違点については、第6章で改めて検討する。

第5章 過去の誤出力が次の一貫性になる構造 — ダニング＝クルーガー効果との比較 —

5-1 一回の生成から次の入力へ

第3章では一回の生成におけるハルシネーション、第4章ではマイサイドバイアスおよび迎合について、観測された出力からSCOPE上の認知構造を仮置きした。

本章では、一度成立した出力が後続の認知処理へ接続され、その結果として、先の方向性が維持または強化されたと推定できる場合を扱う。

第3章で示した「ホニャメリティはお茶の一種です」という出力の後に、ユーザーが「そうなんだ。どこのお茶なの?」と入力したとする。このとき、SCOPE上では二回目の生成を、新たな入力に対する別の観測単位として扱う。一方、前回の出力が後続の認知処理へどのように持ち越されるかという時間方向の接続は、SCOPE単体では十分に扱えない。

なお、以下では複数回の生成を時間方向に沿って記述するが、各回のSCOPE内部に固定された処理順序が存在することを意味するものではない。

5-2 過去の誤出力とL3の一貫性

一回目の生成において、LLMが「ホニャメリティはお茶の一種です」と出力したとする。その後、ユーザーが「そうなんだ。どこのお茶なの?」と入力した場合、二回目の認知処理では、「ホニャメリティはお茶である」という内容が、すでに対話内で出力された情報として参照される可能性がある。

SCOPEは各時点の認知構造を推定する座標系であり、過去の出力を時間方向に保持・管理する過程そのものは扱わない。本稿では、複数の観測をまたいで過去の出力を参照し、その変化を観測・更新する時間方向の扱いを、COSとの接続領域として扱う。

二回目の認知構造をSCOPE上で推定した場合、前回の出力との一貫性を維持する方向が、L3に対応する一貫性の一つとして成立している可能性を仮置きできる。このとき、「ユーザーの質問に答えるべきである」「正しい情報を生成すべきである」「直前までの出力と一貫した回答を生成すべきである」といった複数の方向性が同時に成立する可能性がある。

その結果、前提そのものを再検討する方向よりも、「どこのお茶であるか」を説明する方向が、直前の出力との一貫性を維持しやすくなる場合がある。L4に実在性や根拠への疑義を仮置きできたとしても、L4-L5のスライド関係がL5側へ傾けば、その疑義よりも前回の出力を前提として受け入れる方向が強く反映される可能性がある。

その場合、L6では受け入れられた前提を基に産地についての説明モデルが構築され、L7では地域名や味、香りなどに関して、学習や経験から形成された高抽象・高圧縮の認知が参照される可能性がある。その結果、例えば「東南アジアで飲まれているお茶です」といった新たな出力が生成され、さらに「どんな味なの?」と問われれば、「フルーティーな香りが特徴です」などの情報が追加される場合がある。

ここでは、新しい外部情報が確認されたわけではない。それにもかかわらず、前回の誤出力が後続の認知処理における前提として扱われ、その前提との一貫性を維持する方向で新たな説明モデルが形成されることで、誤情報が具体化・詳細化される可能性がある。したがって、これは単なる誤答の反復とは異なる。

なお、本節ではユーザーから訂正的な指摘が行われていない場合を扱った。次節では、指摘を受けた後にも別のハルシネーションが生成される場合を扱う。

5-3 訂正後にも別のハルシネーションが生成される場合

前節では、誤出力が訂正されないまま後続の認知処理へ接続される場合を扱った。

一方、最初の誤情報を撤回した後にも、別のハルシネーションが生成される場合がある。

例えば、一回目の生成で「ホニャメリティはお茶の一種です」と出力した後、ユーザーから「それは事実ではないのではないか」と指摘されたとする。これに対してLLMが謝罪し、最初の説明を撤回したにもかかわらず、その直後に「名称は異なりますが、東南アジアで飲まれているお茶を指している可能性があります」など、確認されていない別の説明を提示する場合がある※1。

この場合、最初の誤情報そのものは撤回されている。しかし、別の未確認情報が新たに提示されているため、出力上の訂正だけをもって、後続の認知構造全体が更新されたと判断することはできない。

本稿では、このように個別の説明が撤回された後にも別の説明が提示される場合を、次節で「説明交換型」として整理する。

※1 本節の例は、実際の対話で観測された挙動から、固有名詞や題材を変更し、構造を抽出して再構成したものである。

5-4 ダニング＝クルーガー型の自己評価維持との共通構造

人間とLLMの双方において、一度成立したL3に対応する方向性に対し、それを弱める新たな情報や指摘が入力された場合、後続の出力には複数の型が観測される。本稿では、方向性が維持される場合の応答を、構造仮説として、拒絶型、説明交換型、反証吸収型の三つに整理する。

第0章で示したとおり、本稿はダニング＝クルーガー効果そのものを説明するものではない。本節では、根拠の薄い、または誤った根拠に基づく過大な自己評価が成立し、それを弱める情報や指摘の後にも維持される「ダニング＝クルーガー型の自己評価維持」を、人間側の比較対象として用いる。以下で示す型は、既存のダニング＝クルーガー効果の分類として確立されたものではなく、本稿が構造仮説として提示する応答類型である。

方向性そのものが更新される場合もあるが、これは本稿でいう「ダニング＝クルーガー型の自己評価維持」には該当しない。本節では、方向性が維持される場合を対象とする。

拒絶型では、既存の方向性と矛盾する入力採用されず、入力または入力者の妥当性を否定する説明が構築される。人間では、「自分の能力を理解できないのは、指摘者の理解力が不足しているからである」と出力される場合がある。LLMでは、実在する対象についてユーザーが証拠を示しても、「その情報源が誤っている可能性がある」と出力し、先の判断を維持する場合がある。

説明交換型では、既存の方向性と両立しない部分は撤回されるが、方向性そのものを支える別の説明へ交換される。人間では、「1+1を理解できるから天才である」という根拠を撤回し、「それなら、2+2も理解できるから天才である」という別の根拠へ交換する。LLMでは、最初に提示した名称や説明を撤回しながら、同じ回答方向を維持できる別の名称や説明へ交換する場合がある。前節で示した、訂正後に別のハルシネーションが生成される例は、この型に対応する。

反証吸収型では、方向性を弱めるはずの情報そのものが、方向性を補強する材料へ変換される。なお、本稿でいう反証吸収型には、厳密な意味での反証だけでなく、既存の方向性を弱める情報、矛盾を示す指摘、訂正を求める入力、その方向性を補強する材料へ変換される場合を含む。本稿では、これらをいずれも既存の方向性を弱める入力として扱い、その入力自体が方向性を補強する材料へ変換される構造を、代表的な場合である反証を用いて「反証吸収型」と呼ぶ。

人間では、「全員が計算できる」という情報を、「この集団自体が特殊に優秀である」という自己評価の補強材料へ変換する場合がある。LLMでは、ユーザーが証拠を追加提示しても、その証拠提示自体を「誤情報を強く信じ込んでいる可能性がある」「何でも鵜呑みにしない方がよい」という説明へ変換し、先の判断を補強する場合がある※2。

ここで問題となるのは、新しい説明を考えること自体ではない。その説明の裏付けを検証せず、当初の方向性を維持するために採用する点にある。反証を受けて新たな仮説を立てること自体は、検証に開かれている限り不合理ではない。反証吸収型として問題になるのは、その新しい説明が検証の対象として扱われず、結論を固定するための補助説明として採用される場合である。

拒絶型、説明交換型、反証吸収型に共通するのは、次の構造である。第一に、一度成立したL3に対応する方向性が保持される。第二に、その方向性が、後続の認知処理における一貫性の基準となる。第三に、方向性を弱める入力が、拒絶、説明交換、または反証吸収のいずれかとして処理される。第四に、その処理に対応する説明モデルが構築される。第五に、その結果として、誤情報または過大な自己評価が維持・補強される。

なお、人間とLLMでは、維持される対象そのものは異なる。人間では、自己像、自己評価、信念などが維持される。LLMでは、システム方針、対話上の役割、直前までの出力との一貫性などが維持される。したがって、人間の自己一貫性とLLMの一貫性を、同一の内部状態として扱うことはできない。一方で、両者は、一度成立したL3に対応する方向性が、後続の認知処理でも維持されるという機能的位置において対応する。

重要なのは、指摘を拒否したかどうかだけではない。指摘の一部を認めた場合でも、それが認知構造のどの部分を更新したのかを区別する必要がある。個別の説明のみが更新され、L3に仮置きされた中核的な方向性が維持されている場合、認知構造全体の方向性は大きく変化しない可能性がある。

本稿では、過大な自己評価または誤情報が複数の観測をまたいで維持された場合、その維持過程を、方向性を弱める入力が拒絶、説明交換、または反証吸収のいずれかの形で処理されることで、L3に対応する方向性が保たれる構造として仮置きする。この構造は、複数回の対話におけるハルシネーションの連鎖と、本稿でいう「ダニング＝クルーガー型の自己評価維持」に共通する型として記述できる可能性がある。

ただし、本章で示した構造は、観測された出力からSCOPE上へ仮置きした構造仮説である。LLMまたは人間の内部構造を直接観測したものではなく、既存のダニング＝クルーガー効果全体の原因を確定するものでもない。

※2 本節で述べるLLMの拒絶型および反証吸収型の挙動は、実際の対話において観測された事例から、固有名詞や題材を変更し、構造を抽出して再構成したものである。

6章 考察

6-1 出力の訂正と認知構造の更新は同じではない

第5章では、誤出力が後続の認知処理へ接続される場合と、訂正後にも別の説明が提示される場合を扱った。

ここで区別する必要があるのは、出力内容の変化と、認知構造の更新である。

例えば、誤った説明が撤回された場合、その説明が出力上で更新されたことは観測できる。しかし、それだけでは、認知構造のどの部分が更新されたのかまでは確定できない。

個別の説明だけが変更された可能性もあれば、より広い認知構造が更新された可能性もある。また、同じような訂正出力であっても、その背後に仮置きできる認知構造が同一であるとは限らない。

SCOPEでは、出力を認知構造そのものとして扱わず、その背後にある構造を推定するための観測の手がかりとして扱う。そのため、謝罪、訂正、撤回などが観測された場合にも、「出力が変化したこと」と「認知構造のどの部分が更新された可能性があるか」を分けて考える必要がある。

したがって、訂正の有無だけで更新を判断するのではなく、訂正後の出力がどの方向へ収束するか、どの前提や説明が維持・変更されるかを含めて観測する必要がある。

次節では、L3に対応する方向性そのものが更新される場合と、維持される場合の違いを検討する。

6-2 方向性が更新される場合と維持される場合

前節では、出力上の訂正と、認知構造の更新を区別する必要があることを示した。本節では、L3に対応する方向性そのものが更新される場合と、方向性が維持されたまま他の認知内容が変更される場合について検討する。

例えば、「1+1を理解できるため、自分は天才である」という自己評価が成立していたとする。これに対して、「1+1は多くの人が理解できるため、それだけでは天才である根拠にはならない」という指摘が入力され、「それなら、自分は天才とは言えない」と自己評価を変更する出力が観測された場合、L3に対応する方向性そのものが更新された可能性を仮置きできる。

一方、「それなら、2+2も理解できるため、自分は天才である」と別の説明が提示された場合には、「自分は天才である」という方向性が維持されたまま、説明モデルが変更された可能性を仮置きできる。これは、本稿では第5章で示した説明交換型に対応するものとして整理する。

ただし、方向性が維持される場合に関与する認知構造は一様ではない。第5章で示した拒絶型、説明交換型、反証吸収型では、方向性が維持された点と推定できる点は共通していても、その維持に関与すると仮置きできるレイヤー構成は異なる可能性がある。説明交換型ではL6に対応する説明モデルの変更、反証吸収型ではL4・L5・L6の関係、拒絶型ではL4・L6の関係が中心となる可能性がある。

ここで重要なのは、方向性の維持が、単に一つの説明を変えないことを意味するわけではないという点である。個別の説明や前提が変更された場合でも、L3に対応する方向性が維持されたと推定できる出力が続く場合がある。

SCOPE統合論文では、L3に対応する一貫性を変更する際に、認知主体の基本的な成立や動作、および他レイヤーとの関係をどの程度再調整する必要があるかを、L3の更新コストとして扱っている。

人間では、自己評価や信念が自己像、価値観、所属などと強く結びついている場合、その方向性を変更するために、関連する認知との再調整が必要になる可能性がある。一方、それらとの結びつきが弱く、更新後の認知構造が全体として成立可能である場合には、方向性そのものが比較的更新されやすい可能性がある。

LLMIにおいても、直前までの出力との一貫性、ユーザーへ具体的な回答を提示するという方向性、正しい情報を生成するという方向性など、複数の一貫性が同時に成立する可能性がある。そのため、訂正後の出力から先の方向性が更新されたと推定できる場合もあれば、別の説明へ置き換えることで先の方向性が維持されたと推定できる場合もある。

ただし、本稿は、方向性が更新されるか維持されるかを決定する条件を確定するものではない。ここで示したのは、同じような訂正や反対情報が入力された場合でも、後続の出力から仮置きできる認知構造が異なる可能性である。

6-3 現象名を越えて共通構造を見ることの意味

本稿で扱ったハルシネーション、マイサイドバイアス、迎合、ダニング＝クルーガー型の自己評価維持は、それぞれ異なる現象である。

一方、本稿で仮置きした事例をSCOPE上で比較すると、L3に対応する方向性が認知構造全体へ強く反映される点に共通性がみられる。ただし、この共通点のみをもって、本稿でいう「同じ構造」とするものではない。本稿で比較するのは、L3を含む複数の認知機能と、それらの機能間の関係である。

【図6-1】

現象	強く反映されるL3	特徴
マイサイドバイアス	現実との整合性にかかわらず自己内部の整合性と一貫性	自身の判断との一貫性が中心
迎合	ユーザーへの寄り添い	L7の経験由来の認知
ハルシネーション	情報が足りなくてもユーザーの役に立つ生成をしたい	L6による説明モデル形成・補完

現象	強く反映されるL3	特徴
ダニング=クルーガー型 自己評価維持	現実との整合性にかかわらず自己内部の整合性と一貫性	
拒絶型		L3に対応する既存の方向性と反する情報に対し、L4・L6が中心となり、その方向性を保持する可能性
説明交換型		L3に対応する既存の方向性を維持したまま、L6を中心に説明モデルが交換される可能性
反証吸収型		L3に対応する既存の方向性を弱める情報に対し、L4・L5・L6の関係によって、その情報が方向性を補強する材料へ変換される可能性

図6-1に示すように、マイサイドバイアスでは自身の判断との一貫性、迎合ではユーザーが示した方向への収束、ハルシネーションでは回答を成立させようとする方向、ダニング=クルーガー型の自己評価維持では過大な自己評価を維持する方向が、それぞれL3に対応する方向性として強く反映される可能性がある。

さらに、その方向性に関与すると仮置きできる認知機能も異なる。当該ユーザーとの継続的な相互作用から高抽象・高圧縮の応答傾向が形成されている条件では、迎合にL7の経験由来認知が関与する可能性がある。ハルシネーションでは、L6による説明モデル形成や補完が特徴として仮置きされる。ダニング=クルーガー型の自己評価維持では、同じ方向性の維持であっても、拒絶型、説明交換型、反証吸収型によって中心となる可能性のある認知機能が異なる。

したがって、SCOPEで比較する意味は、異なる現象を同一視することではない。共通する認知座標と、異なる認知機能の関係を同じ座標系上で比較することにある。

また、L3に対応する方向性と反する情報が入力された場合でも、その情報の解釈や後続の処理によって、異なる認知構造が形成される可能性がある。SCOPEでは各観測時点における認知構造を仮置きし、比較する。一方、複数の観測をまたいで、入力がどのように解釈され、ズレが検知され、後続の仮説や処理がどのように更新されるかという時間方向の変化については、COSとの接続領域として別稿で検討する。

6-4 本稿の限界と次の課題

本章では、出力内容の訂正と認知構造の更新の違い、L3に対応する方向性が更新または維持される場合の違い、および異なる現象を共通する構造単位で比較することの意味について検討した。本節では、本稿で提示した構造仮説の限界と、今後検討すべき課題について整理する。

第一に、本稿で示した認知構造は、観測可能な出力から仮置きされた推定であり、人間またはLLMの内部構造を直接観測した結果ではない。同じ出力であっても、その背後には複数の認知構造を仮置きできる可能性がある。そのため、本稿で示した各レイヤーの配置は、唯一の説明と

して確定されるものではなく、観測された出力と整合する構造仮説の一つとして扱う必要がある。迎合におけるL7関与については条件比較による反証可能性を示したが、本稿で提示したその他の構造仮説についても、今後、代替配置との比較や、その仮説が支持されない条件を明確化する必要がある。

第二に、本稿で用いた事例は、各現象の構造的な対応関係を示すために単純化した仮想例である。実際の人間の認知やLLMとの対話では、発話の文脈、過去の経験、対人関係、対話目的、システム方針など、より多くの要素が関係する可能性がある。本稿の事例だけによって、ハルシネーション、マイサイドバイアス、迎合、またはダニング＝クルーガー型の自己評価維持が、常に本稿で示した構造によって成立すると判断することはできない。

第三に、本稿は、これら四つの現象が同じ原因によって生じることを示したものではない。また、どのような条件によってL3に対応する方向性が形成され、更新され、または維持されるのかを確定したものでもない。第6章で検討したL3の更新コストや、方向性の維持に關与するレイヤー構成は、観測された出力の違いを記述するための仮説であり、その成立条件や因果関係については、今後の検討が必要である。

第四に、本稿で用いた「ダニング＝クルーガー型の自己評価維持」は、既存のダニング＝クルーガー効果そのものを対象とした分類ではない。本稿が比較したのは、弱い、または誤った根拠に基づく過大な自己評価が、それを弱める情報や指摘の後にも維持される場合の認知構造である。この構造が、既存研究におけるダニング＝クルーガー効果とどの範囲で対応するのかについては、関連研究との比較を含む別途の検討が必要である。

第五に、本稿は、一回の出力または限られた対話に観測される認知構造を中心としている。第5章では、過去の出力が後続の認知処理へ接続される可能性を扱ったが、複数回の観測を通じて認知構造がどのように変化し、どの時点でズレや前提不一致が検知され、後続の仮説や処理がどのように更新されるのかについては十分に扱っていない。SCOPEでは各観測時点の認知構造を仮置きし比較できるが、このような複数の観測をまたぐ時間方向の変化については、COSとの接続を含めて検討すべき課題である。

また、SCOPEを対話システムへ実装する場合、すべての出力について常時詳細な構造推定を行う必要があるとは限らない。例えば、ユーザーが「違う」「意図とずれている」など、前提不一致や解釈のずれを示す出力を行った場合に、認知構造を再推定する方式も考えられる。ただし、どのような観測を再推定の起動条件とし、COSによる観測・検知処理とSCOPEによる構造推定をどのように接続するかについては、本稿の射程を超えるため、今後の検討課題とする。

さらに、認知構造の推定は、相手の出力を一つの意図へ早期に確定することを避け、対話上の前提ずれを減らすために利用できる可能性がある一方、相手の反応を予測し、特定の判断や行動へ誘導する目的にも利用されうる。したがって、実装にあたっては、推定結果を確定的に扱わないこと、本人の選択可能性を損なわないこと、利用目的と運用範囲を明確にすることなど、技術的な検討とともに倫理的な境界についても検討する必要がある。

今後は、同一の入力に対して異なる出力が生じる事例や、訂正後にも方向性が維持または更新される事例を複数収集し、それぞれの出力をSCOPE上で比較する必要がある。また、人間とLLMにおいて機能的に対応すると仮定された位置が、どの範囲で共通する構造として記述でき、どの範囲で異なる記述を必要とするのかについても検討が必要である。

本稿で提示した構造仮説は、異なる現象を一つの説明へ還元するものではない。現象間の差異を保持したまま、観測された出力を共通する認知座標上で比較できる可能性を示したものである。その妥当性は、今後の事例比較、反証可能性の検討、およびSCOPEとCOSを接続した時間方向の観測を通じて評価される必要がある。

終章

本稿では、ハルシネーション、マイサイドバイアス、迎合、およびダニング＝クルーガー型の自己評価維持について、それぞれを同一の現象として扱うのではなく、SCOPE上で共通する可能性のある認知構造として比較した。なお、本稿でいう「ダニング＝クルーガー型の自己評価維持」は、既存のダニング＝クルーガー効果そのものを再定義または説明するものではなく、過大な自己評価が、それを弱める情報や指摘の後にも維持される場合の構造を比較対象として便宜的に示した呼称である。

本稿で示した構造仮説では、L3に対応する方向性が認知構造全体へ強く反映される点に、複数の現象を比較するための共通性がみられた。一方、その方向性の内容や、L4における疑義、L5における受容、L6における説明モデル形成、L7に対応する経験由来の認知などがどのように関与するかは、現象や条件によって異なる可能性がある。したがって、本稿でいう共通構造は、単一のレイヤーが共通することではなく、複数の認知機能とそれらの関係に対応が認められる範囲を指す。

また、本稿では、出力内容の訂正と認知構造の更新を区別する必要があることを示した。誤りを訂正する出力が観測された場合でも、L3に対応する方向性そのものが更新されたとは限らない。方向性が維持されたまま説明モデルが交換される場合、反する入力を受け入れられない場合、または方向性を弱める情報そのものが補強材料へ変換される場合など、異なる認知構造を仮置きできる可能性がある。

SCOPEによって異なる現象を共通する認知座標上で比較することには、現象名や研究分野の違いを越えて、どの認知機能が共通し、どの機能関係が異なるのかを検討できる可能性がある。これは、既存の現象名や理論を置き換えることを意味しない。既存概念の定義や研究上の蓄積を保持したまま、異なる現象を別の観点から比較するための補助線としてSCOPEを用いることを意味する。

本稿の構造仮説は、既存の現象名やSCOPEという座標系を先に定め、そこへ現象を当てはめることによって形成されたものではない。一般には異なる現象として分類される対象のあいだに、方向性の維持、反する情報の扱い、説明モデルの形成や再構築などに共通する可能性のある構造が先に見いだされ、SCOPEはそれらを記述・整理し、比較可能な形にするために用いられた。

一方、本稿で示した認知構造は、観測可能な出力から仮置きされた構造仮説であり、人間またはLLMの内部構造を直接観測したものではない。同じ出力に対して複数の認知構造を仮置きできる可能性があり、本稿の事例のみから各現象の原因や成立条件を確定することはできない。

また、本稿では一回の出力または限られた対話を中心に扱った。SCOPEとCOSの役割分担は前章までに示したとおりであり、今後は両者を接続することで、複数の観測をまたぐ認知構造の維持、変化、更新を扱える可能性がある。

本稿が示したのは、ハルシネーション、マイサイドバイアス、迎合、およびダニング＝クルーガー型の自己評価維持が同一の現象であるという結論ではない。異なる現象であっても、出力の背後に共通する可能性のある機能構造を仮置きし、同じ認知座標系上で比較できる可能性がある。

この構造仮説の妥当性は、説明できること自体によって保証されるものではない。今後の事例比較、反証可能性の検討、人間とLLMにおける対応範囲の確認、およびSCOPEとCOSを接続した時間方向の観測を通じて評価される必要がある。

補遺 構造仮説の検証環境(ハビタット)

本稿では、ハビタット(Habitat)を、個人が身体的・心理的・経済的・認知的に安心かつ安全な状態で、自らの能力を十分に発揮できる環境と定義する。これは、SCOPE統合論文で示した定義と同一である。

本稿では、ハルシネーション、マイサイドバイアス、迎合、およびダニング＝クルーガー型の自己評価維持について、一般には異なる現象として扱われる対象のあいだに、共通する可能性のある機能構造を仮置きした。

この構造仮説は、既存の研究分野や現象名を先に定め、そこへ観測結果を当てはめることによって形成されたものではない。本稿の形成過程では、既存の分類や名称を起点とするのではなく、複数の対象に観測される機能や構造上の共通性が、先に仮説として捉えられた。その後、それらの共通性を他者が検討可能な形へ記述・整理するためにSCOPEが用いられた。

このような形成過程は、既存の分類からは見えにくい共通構造を仮説として提示できる可能性を持つ一方、その対応関係が十分に共有されない場合には、異なる対象を同一視している、既存概念を無視している、または根拠なく現象を結びつけていると受け取られる可能性もある。

そのため、このような仮説を研究可能な形へ変換するためには、単に仮説を受け入れる環境ではなく、仮説が何を同じとし、何を異なるものとして保持しているのかを確認し、既存研究との対応、反証可能性、観測との整合性を検討できる環境が必要となる。

SCOPE統合論文では、ハビタットを構成する安全性として、身体的安全性、心理的安全性、経済的安全性、認知的安全性の四つを示した。とくに認知的安全性とは、個人の思考様式、認知特性、学歴、所属、社会的立場その他の背景にかかわらず、その人の考えや仮説が、十分な検討を経る前に異常や欠陥として扱われることなく、対話の対象として受け入れられる状態を指す。

ここには、発信者の学歴や所属、一般的な表現との差異を理由として、内容が提示・検討される前に対話の対象から除外しないことが含まれる。また、仮説段階の提案を異常や妄想として扱ったり、現時点で十分な立証がないことだけを理由に検討を打ち切ったりせず、観測との整合性や反証可能性を確認できる状態を保つことも含まれる。

ここでいう認知的安全性は、仮説を無条件に正しいものとして承認することを意味しない。必要なのは、一般的な分類や表現と異なるという理由だけで仮説を排除せず、何が観測され、どの構造

が仮置きされ、どの部分が既存概念と対応し、どこに反証可能性があるのかを検討できる状態である。

本稿で示した構造仮説も、現時点で妥当性が確認されたものではない。同一または類似する入力に対して生じる異なる出力の比較、人間とLLMにおける機能的対応範囲の検討、複数回の観測を通じた構造変化の比較、およびSCOPEとCOSを接続した時間方向の分析が必要である。

また、LLMへの応用可能性を検討するためには、認知構造の推定が対話上の前提ずれを減らす場合と、誤った推定によって新たなずれを生じさせる場合の双方を観測できる環境が必要となる。推定精度だけでなく、推定結果を確定的に扱わない設計、本人の意思決定を不当に制約しない運用、利用目的と適用範囲の明確化についても検討しなければならない。

これらの検証は、単独の観察と理論構築だけでは十分に行うことができない。認知科学、心理学、言語研究、Human-AI Interaction、AIセーフティ、生成AIの実装、評価設計など、複数の領域からの検討が必要となる。また、理論を継続的に研究するための時間、生活基盤、研究資源、および対話可能な協力関係も必要である。

本稿におけるハビタットの提示は、理論への賛同を求めるものではない。必要なのは、既存の分類や一般的な表現を起点とせず形成された仮説を、理解しにくいという理由だけで排除せず、観測、比較、反証、修正および実装可能性の検討を行える環境である。

SCOPEおよび本稿の構造仮説は、現時点で妥当性の検証を終えたものではない。既存の分類を起点としない観察から得られた着想を、他者が検討可能な仮説へ変換し、その妥当性を評価していくためには、研究者個人の能力だけでなく、その能力が実際に発揮され、検証へ接続されるためのハビタットが必要となる。