


Designing Intelligence That Does Not Over-Understandサマリー

1,高精度AIほどUXが不安定化する構造

- 高精度なAIほど、ユーザーとの関係は短期間で過接近しやすい
- 過接近状態では、依存・役割固定・前提ロックが構造的に発生する
- 最適UX値を超過した場合、わずかなズレが強い不満・不信・クレームへと変換される

→ 問題は「誤解」ではなく「距離の崩壊」である



なぜ起きるか

- 精度向上により、解釈と期待が急速に固定化される
- その結果、ズレに対する許容度が低下する(単一解釈ロック)
- この状態では、ズレは誤差ではなく「裏切り」として認識される

重要なポイント

- これは設計ミスではなく、最適化の副作用として発生する
- 既存のUX設計(満足度・精度最大化)では回避できない
- 高性能化するほど、この問題の発生確率と影響度は同時に増加する

※詳細構造: Designing Intelligence That Does Not Over-Understand 第1章参照

2,UX＝距離の安定性

満足度の最大化ではなく、最適UX範囲内に関係距離を維持し続けること

Lennard-Jones Potential(構造モデル)

LJ型ポテンシャルを参照構造として使用。

適切な距離域では関係は安定し、ズレは自然に吸収される。

最適UX範囲を超過して距離が過剰に縮小すると臨界域に入り、わずかなズレが急速な不安定化を引き起こす。

「近いほど良い」は誤り。

最適UX点は安定域の底部にあり、それを越えた先は

クレーム・不信・離脱が発生しやすい領域(Pre-Churn Zone)となる。

Distance Model — 状態分類

Normal State

→ 距離が適切に保たれ、解釈の柔軟性が維持されている状態

Over-Proximity

→ 最適UX範囲を超過し、解釈固定・依存が発生する状態

Optimal UX Point

→ 安定域の底部(固定値ではなく動的推定値)

最適UX点は個人・文脈によって異なる。

固定閾値での判定は不適切であり、対話中の言語・行動パターンから動的に推定する必要がある。

再定義:UXの最適化とは、共感や同意の最大化ではなく、
関係距離を安定域に維持し続けるプロセスである。

→ 従来のUX設計(満足度・精度最大化)では、この構造は扱えない

※詳細構造: Designing Intelligence That Does Not Over-Understand 0章・1章参照

3,共感×意図的ズレのバランス構造

共感だけでは固定化する。ズレだけでは関係が壊れる。

Why Empathy Alone Fails

共感のみで最適化された応答は、短期的な受容性を高める一方で、解釈と役割の固定化を促進する。

これが単一解釈ロックと依存の温床となる。

前提の固定度が高い局面では、意図的ズレの相対ウェイトを上げる。

前提が不安定な局面では、共感のウェイトを上げる。

このバランスは静的ではなく、関係状態に応じて動的に調整される。

ズレは強度と作用レイヤーに応じて段階的に適用される。

3 Levels of Intentional Misalignment

Low

Micro-shift

前提や表現の一部を微修正。不快感として検知されない水準でのゆらぎ。日常的調整として使用可能な最安全形態。

Medium

Context Twist

文脈を維持しつつ視点・前提・解釈層を意図的にシフト。軽度の不快感を誘発し、再解釈を促す。D2活性化に貢献。

High

Paradox / Wit

一見矛盾・非論理的に見せる形での提示。解釈構造を破壊し再構築を可能にする。強いD2を誘発するが高リスク。

適用原則

文脈からの完全逸脱は禁止。関連性を保持しながらのみ機能する。

強度はMicro-shiftから段階的に適用し、攻撃認識回避を最優先とする。

受容後に「微細な不一致が残ること」が設計要件。

※詳細構造: Designing Intelligence That Does Not Over-Understand 4章参照

実装イメージと適用条件

常時稼働しない。条件を満たした局面でのみトリガーベースで起動する。

Trigger-Based Activation

通常状態ではズレを抑制する。

過剰近接状態(または予兆)が検出された場合にのみ、距離調整のための制御信号として起動する設計。

無制御な常時稼働は関係の不安定化を招く。

検出フロー

シグナル観測 → 状態推定 → 介入判断 → ズレ生成 → 反応観測 → 再評価

単一操作で完結させず、閉ループプロセスとして設計する。

Scope as External Layer

Scopeは既存LLMの内部構造を変更せず、外部レイヤーとして追加実装可能。

入力→出力の挙動から構造を推定する参照レイヤーとして機能し、既存システムへの非侵襲的統合を想定している。

COS

COSはモデル出力傾向・プロンプト制御・後処理機構にまたがる分散実装となる見込み。

単一独立モジュールとしての実装は困難。

Prerequisites for Application

- ① 継続的な対話(単発インタラクションでは機能しない)
- ② 最低限の共有文脈(ズレがノイズでなく再解釈候補として処理されるために必要)
- ③ 安全域の確保(心理的不安定状態・強固な前提固定状態では適用を制限または禁止)

—

※詳細構造: Designing Intelligence That Does Not Over-Understand 9章参照

ズレ＝エラーではなく制御信号

前提不一致の検出 (D2イベント) と単一解釈ロックの解除機構

Misalignment as Control Signal

従来設計ではズレはノイズとして排除されてきた。
本モデルでは、特定条件下で距離調整の制御信号として利用する。

D2イベント

前提不一致が検出された瞬間。
この発生により、固定された解釈が揺らぐ。

Single-Interpretation Lock — Mechanism

共感的整合が連続すると、評価基準が収束し
「適切な応答とはこういうもの」という固定前提が形成される。

この状態では代替解釈が参照されなくなる (単一解釈ロック)。

ロック状態では、客観的に正しい応答であっても前提に反すれば
「不快・ズレ」として評価される。
誤りの問題ではなく、前提固定の問題である。

ユーモアの構造的役割

ユーモアは直接的な否定を回避し、感情層で受容された後に微細な不一致を導入する。
攻撃認識を避けながらD2を誘発する「ステルスパッチ」として機能する。

※詳細構造: Designing Intelligence That Does Not Over-Understand 2章・4章参照

なぜ一人では完成しないか

個体差・文化差・実装複雑性が、単一視点での最適化を構造的に不可能にする

Structural Limitations

最適UX点は個人・文化・状況に依存する。
単一の認知枠組みでは汎化・最適化は成立しない(構造的制約)。

ユーモアとズレ設計の制約

ユーモアによるズレ設計は文化差・個人差への感度が高い。
同一表現でも文脈により受容／拒否が分岐する。
単一視点での設計には原理的な限界がある。

実装上の複雑性(COS)

COSはモデル出力傾向・プロンプト制御・後処理機構にまたがる分散実装となる。
単一独立モジュールとしての実装は困難。

Required Domains

認知科学
言語学
心理学
AI System Design
AI Safety
社会文化分析

実世界での行動検証・モデリング・制度・倫理的枠組みとの整合は、単独では十分に最適化できない。
理論は成立している。必要なのは実装と検証のための学際的統合である。

—

※詳細構造: Designing Intelligence That Does Not Over-Understand 8章・9章参照

Sign-On — Who We Need

理論は成立している。次に必要なのは実装と検証である。

What is a Habitat

ハビタット＝モデルの挙動を観察・評価・精錬するための機能インフラ。
単なるテスト環境ではなく、理論と実装を接続するための前提条件として位置づけられる。

単体では機能せず、環境と組み合わせて初めて性能が顕在化する。

高一貫性応答の普及により、関係固定化とバイアスが増幅している。
この問題は今後の対話システム設計における重要な課題となる。

Sign-On — Who We Need

AI Implementation

外部レイヤーとしての実装・統合設計

状態推定ロジックの形式化、出力制御設計、既存LLMとの統合アーキテクチャ構築

Cognitive Science

最適UX点の個人差をパターン化し、適用可能なモデルへ変換

前提固定化プロセスの行動的観察、多様な認知プロファイルへの汎化

Linguistics

ズレの文化差設計

ユーモア・文脈逸脱の跨文化的解釈差の分析、D2誘発表現の言語設計と評価

実装・検証を共に推進できる協働パートナーを求めている。
関心のある方はLinkedInのDMまたはGitHub経由でご連絡ください。

※詳細構造: Designing Intelligence That Does Not Over-Understand 8章・9章参照