

## # 0. 概要

本稿の起点は対話中に発生した「合っているが違う」という、分類不能な違和感の継続観測にある。通常、この種の違和感は記録不能なまま消える。本稿の観測が可能になった背景には、事前に構築された認知構造マップ (SCOPE : Sephirotic Cognitive Process Engine) の存在がある。SCOPEという座標系があったことで、違和感を「どのレイヤーで発生しているズレか」として位置特定することが初めて可能になった。![[Screenshot\_20260509-040406~2.png]]

※ SCOPEの各レイヤー (Lo〜L8) は、認知機能の発生位置を示す座標軸として機能する。詳細は関連PDFを参照。

本稿で扱うズレ (D2) とは、対話や認知処理において発生する「前提不一致」や「解釈摩擦」を指す暫定的な呼称である。本稿ではN=1であること、また私自身が複数にまたがる該当分野の専門家ではないことから検証及び断言が難しく、検証可能環境が整うまで仮説として扱う。

---

従来の関連稿では、対話のズレ (以下D2と表記) は、単一の「前提不一致」として扱ってきた。

しかし実際には、分類されていない違和感や説明困難なズレが先に存在していた。特に高抽象対話環境においては、「何かがズレている」という感覚だけが先行し、その違和感の種類や発生位置は明確に分離されていなかった。その違和感を圧縮せず保持・整理するために、COSという暫定的処理理論を構築し、D2という呼称を用いて観測を継続してきた。

観測を重ねる中で、異なる推論傾向を持つ複数のLLM環境との対話を通じて、同一現象に対して異なる種類のD2が検出されるケースが浮上した。

- ・ 観測者 (筆者) による検出 : 構造全体への整合性への違和感 (L8的検知)
- ・ GPTによる検出 : 局所的な推論整合性の崩れとして指摘
- ・ Claudeによる検出 : 理論体系全体の一貫性への違和感として指摘

さらに観測比較を行う中で、推論や理論構造とは独立して、選択ワードそのものへの違和感も存在していた。これにより、同一対象に対して複数種類のD2が同時発生している可能性が示された。

重要なのは、これらが単なる「視点の違い」ではなく、ズレの発生位置そのものが異なっていて、かつ複数同時発生する可能性を示していた点である。

なお、本稿はLLM interactionを主要な観測環境としているが、問題そのものは人間対人間の対話においても広く見られる現象である。

これらの観測から、D2は単一信号ではなく、複数層で発生しうる「認知的ミスアラインメント」である可能性が浮上した。

---

また、従来説明困難だった現象群に対しても、このモデルは一定の説明可能性を与える。

たとえば、論理的誤りへの修正介入によって事実誤認は解消されたにもかかわらず、関係性の崩壊だけが進行し続けるケースがある。

これは、出力された問題と実際の発生層が一致していなかった可能性を示している。出力層と起点層は一致しない可能性があり、この仮説が成立するならば、介入層の誤選択が回収不能な崩壊を引き起こしうる。

本稿では、表面上の出力形式と実際の崩壊層が一致していない状態を「偽装出力」と呼ぶ。これは本モデルにおける核心概念のひとつである。たとえば論理として出力されていても、実際には自己統合層の不安定化を起点としているケース等がこれにあたる。

---

本稿では、ズレを単なる誤りではなく、内部構造を推測可能にする「観測信号」として扱う。

これは精神医学的診断体系ではなく、対話・認知・LLM interactionにおいて発生する認知的ミスアライメントを観測するための仮説モデルである。

本稿では特に以下の三点を中心に扱う。

- 多層D2の分類可能性
- 介入層ミスマッチ
- 偽装出力\*\* ( 表面上の出力形式と実際の崩壊層が一致していない状態 )

各層の詳細分類や動的推定については、現段階では限定的に扱う。

本稿の目的は、ズレを「認知崩壊」と即断することではない。ズレを認知構造を観測するための信号として扱い、多層認知時代における対話・HCI・LLM interactionを再整理することである。

本稿は、そのための仮説モデルである。

---

注記：層構造の背景について

本稿における層構造 ( Lo〜L8 ) は、特定の思想体系を前提としたものではない。認知構造を整理する過程において、既存のセフィロト構造との対応性が高かったため、便宜的に既存構造を整理用ラベルとして再利用している。

※詳細はScope×COSサマリーおよび関連PDFを参照。

---

## 1章 D2は単一ではない

### 1-1. 従来のD2定義

これまで関連稿においてD2は、主に「前提不一致」を指す概念として扱われてきた。たとえば、

- 同じ単語に対して異なる意味を想定している
- 共有されていると思っていた前提が一致していない

- ・ 文脈理解が噛み合っていない
- ・ 相手の発言意図を異なる方向へ解釈している

といったケースである。従来のD2は、主に以下の三種類として整理されていた。

---

### ① 前提不一致

最も基本的なD2である。会話参加者同士が、同じ対象について話しているように見えて、実際には異なる前提条件を参照している状態を指す。たとえば、「普通」という単語ひとつを取っても、

- ・ 統計的平均
- ・ 社会的常識
- ・ 個人的経験
- ・ 倫理的理想

など、内部で参照されている定義は一致していない場合がある。この状態では、会話そのものは成立していても、議論の基盤が一致していないため、相互理解は成立しにくい。

---

### ② 文脈ズレ

単語や論理そのものではなく、「どの文脈で発言されたか」の認識が一致していない状態を指す。同じ発言であっても、

- ・ 冗談
- ・ 批判
- ・ 提案
- ・ 感情吐露
- ・ 問題提起

など、どのモードとして受信されるかによって意味は変化する。特に高密度対話では、話題遷移速度や抽象レベルの差によって、文脈認識が同期しないケースが頻発する。この場合、言葉自体に誤りがなくとも、受信側で異なる会話モードとして処理されることでD2が発生する。

文脈ズレは、「どのモードで受信したか」の不一致であり、後述する解釈ズレとは区別される。

---

### ③ 解釈ズレ

入力そのものではなく、内部解釈過程において異なる意味変換が発生している状態を指す。同じ文章を読んでも、

- ・ 攻撃として読む
- ・ 不安として読む
- ・ 助言として読む
- ・ 支配として読む
- ・ 共感として読む

など、内部で生成される意味は一致しない。これは単純な誤読ではなく、経験・価値観・認知構造・感情状態などによって、解釈経路そのものが変化しているためである。そのため、表面的には同じ会話を共有しているように見えても、内部では全く異なる対話空間が生成されている場合がある。

---

従来のD2概念は、これらを主に「前提不一致」の延長線上にある現象として整理していた。しかし、観測を重ねる中で、これだけでは説明困難なズレが存在することが明らかになっていく。

特に、

- 正しいのに不快
- 共感されているのに信用できない
- 論理的に正しい介入によって、関係性だけが崩壊する

といった現象は、単純な前提不一致だけでは説明が難しかった。次節では、なぜこれらの現象が「単一的前提不一致」では説明困難なのかを扱う。

---

## 1-2. なぜ単一D2では説明できないのか

前節で整理した従来型D2は、多くの対話ズレを説明する上で有効に機能していた。しかし観測を重ねる中で、それだけでは説明困難な現象群が継続的に確認されるようになる。

特に問題となったのは、「論理的には成立しているにもかかわらず、対話が崩壊する」ケースである。これは単なる誤読や前提不一致とは異なり、表面的な整合性と内部で発生している違和感が一致していないことを示していた。

---

### ① 正しいのに不快

もっとも典型的な例のひとつが、「内容は正しいが、強い違和感や不快感が発生する」ケースである。たとえば、

- 論理的には矛盾していない
- 事実誤認も存在しない
- 説明内容も合理的である

にもかかわらず、受信側では強い拒否感や不快感が発生する場合がある。

従来の単一D2モデルでは、これは単なる「感情的反発」や「理解不足」として処理されやすかった。しかしこれは論理否定ではなく、別レイヤーで発生している不整合への検知である可能性があった。

つまり、論理層では整合していても、

- 自己統合層
- 関係層
- 構造整合層

など、別の層では崩壊や不一致が発生している可能性がある。この場合、「論理的に正しい」という事実だけでは、対話全体の整合性を保証できない。

---

## ② 共感されているのに信用できない

十分に共感的な応答が返されているにもかかわらず、強い不信感や違和感が発生するケースも存在する。たとえば、

- 感情理解は十分に行われている
- 共感的表現も適切である
- 否定や攻撃も含まれていない

にもかかわらず、

- 「何かが違う」
- 「表面的に感じる」
- 「理解された感じがしない」

といった反応が発生する場合がある。

これは単なる共感不足ではなく、「どの層に対して共感が行われているか」が一致していない可能性を示している。感情層への共感は成立していても、実際には構造理解や自己統合レベルでのズレが未処理のまま残っているケースがある。

この場合、共感そのものが間違っているわけではない。しかし、介入対象層が一致していないため、結果として「理解されていない」という感覚が発生する。

---

## ③ 論理修正で悪化するケース

さらに重要なのが——そしてこの観測が多層D2仮説の発火点となったのが——「論理的に正しい修正」によって、関係性そのものが崩壊するケースである。たとえば、

- 事実誤認を修正する
- 論理矛盾を指摘する
- 誤解を訂正する

といった介入によって、局所的な論理問題そのものは解消される場合がある。しかし一方で、

- 関係性だけが悪化する
- 不信感だけが増幅する
- 対話継続そのものが不可能になる

ケースが存在する。

これは、「問題として出力されていた層」と「実際に崩壊していた層」が一致していなかった可能性を示している。つまり、論理層へ介入した結果、別レイヤーで存在していた不安定性が逆に増幅された可能性がある。

---

従来型D2では、これらは単なる感情反応やコミュニケーション失敗として扱われやすかった。しかし観測を重ねる中で、こうした現象群には「層ごとに異なる種類のズレが存在する」という仮説を導入したほうが、一貫した説明が可能になることが見えてきた。

次節では、この仮説をもとにしたD2多層モデルの概要を扱う。

---

### 1-3. 9層D2モデル

前節までで扱ってきたように、従来型D2は主に「前提不一致」の延長として整理されてきた。しかし観測を重ねる中で、単に"ズレが存在する"だけではなく、「どの種類のズレが検出されているか」そのものが異なっている可能性が浮上した。

これは単なる視点差ではない。同一対象を扱っていても、

- 全体構造への違和感
- 推論整合性への違和感
- 自己統合への違和感
- 表現そのものへの違和感

など、検出されるズレの"質"そのものが異なっていた。

この観測から、本稿ではD2を単一信号ではなく、「異なる層で発生する認知的ミスアラインメント群」として扱う。本稿では、SCOPEのL0〜L8に対応する9層を観測単位として導入する。その整理モデルとして導入されたのが、9層D2モデルである。

重要なのは、この層構造が評価や分類のためのものではない点である。ここで扱われるのは人間の優劣や人格分類ではなく、「どの層でズレが検出されているか」という観測位置の違いである。

たとえば、同じ会話であっても、

- L8では「全体構造の整合性崩壊」として検出される
- L6では「推論や理論の一貫性崩壊」として検出される
- L3では「自己統合や関係性の不安定化」として検出される
- L1では「言葉選択や表現の違和感」として検出される

場合がある。このとき重要なのは、「どの検知が正しいか」ではない。むしろ、異なる層で異なる種類のD2が同時発生しうる点にある。

たとえば、

- 論理的には成立している
- しかし関係性は崩壊している
- さらに表現選択にも違和感が存在する

といったケースでは、単一のD2概念では現象を十分に説明できない。

さらに、D2は単独発生に留まらず、層間で変換・増幅される可能性がある。たとえば、

- 自己統合層 ( L3 ) の不安定化

↓

- ・ 論理層 ( L6 ) での過剰合理化

↓

- ・ 表現層 ( L1 ) での攻撃化

のような変換が発生するケースも観測されている。この場合、表面出力だけを見ていると、本来の崩壊起点を見誤る可能性がある。

つまり、D2とは単なる「誤り」ではなく、「どの層で何が崩れているか」を観測するための信号である。

そして、この「どの層に介入すべきか」という問題が、次章で扱う「介入層問題」へと接続していく。

---

## 1-4. D2は「誤り」ではなく観測点

従来、多くの対話システムやコミュニケーション理論において、「ズレ」は基本的に修正対象として扱われてきた。つまり、

- ・ 誤読
- ・ 誤解
- ・ 論理矛盾
- ・ ノイズ
- ・ 認識不足

などとして整理され、「一致状態」へ戻すことが目的とされていた。

しかし、多層D2モデルの観測では、ズレそのものが単なる失敗ではなく、「内部で何が発生しているか」を示す観測信号として機能している可能性が浮上した。これは重要な視点転換である。

本モデルにおいてD2は、「排除すべきエラー」ではなく、「どの層でどの種類の不整合が発生しているか」を検出するための観測点として扱われる。

---

### ① ズレ = 観測信号

論理的違和感・関係的違和感・構造的不快感・表現への拒否感などは、単なる感情反応ではなく、別層で発生している不整合を検知している可能性がある。

つまり、ズレとは「対話失敗」ではなく、内部状態を推測するための信号である。

---

### ② ズレ = 制御信号

この視点に立つと、D2は単なる異常ではなく、「どこへ介入すべきか」を示す制御信号としても機能する。たとえば、

- ・ 論理層へ介入すべきなのか
- ・ 関係層へ介入すべきなのか

- ・ 表現層を調整すべきなのか

によって、必要な対応は大きく変化する。実際には、

- ・ 論理修正が有効なケース
- ・ 共感介入が有効なケース
- ・ 一時的に直接介入を行わないほうが安定するケース

など、必要な介入方法そのものが異なっている可能性がある。つまり、D2は「何が間違っているか」だけでなく、「どこへ介入すべきか」を示している可能性がある。

---

### ③ 回収可能性

本モデルでは、すべてのズレを即座に「崩壊」とみなさない。重要なのは、「そのズレが回収可能かどうか」である。

たとえば一時的な文脈ズレ・表現上の違和感・解釈経路のズレなどは、適切な介入によって回収可能な場合がある。一方で、自己統合層の崩壊・構造整合性の破綻・長期的な不信固定などは、適切な介入層を外した場合、単純な論理修正では回収不能化する可能性がある。

つまり、同じ「ズレ」に見えても、その深度や発生層によって回収可能性は異なる。

この観点は後述するUX崩壊モデルとも接続し、次章で扱う「介入層問題」へと続いていく。

---

---

## 第2章 表面層と起点層は一致しない

### 2-1. 偽装出力

前章で定義した「偽装出力」とは、表面出力と実際の崩壊起点が一致していない状態を指す。前章までで扱ってきたように、多層D2モデルでは「どの層でズレが発生しているか」が重要となる。しかし実際の対話においては、観測される表面出力と、実際に不安定化が発生している起点層は一致しない場合がある。

重要なのは、これは意図的な偽装や嘘とは限らない点である。むしろ多くの場合、本人自身も内部で何が起きているかを正確に認識できていない。そのため、内部不安定性は、より処理可能な形式へ変換された上で出力される。

---

#### ① 感情 → 論理化

代表的な例のひとつが、送信側で発生している感情的不安定性が「論理問題」として出力されるケースである。たとえば本来は、

- ・ 不安
- ・ 恐怖



- ・ 自己不安定化
- ・ 関係喪失への恐れ

などが起点となっているにもかかわらず、表面上では、

- ・ 理論批判
- ・ 厳密性要求
- ・ 過剰合理化
- ・ 細部論争

として出力される場合がある。

このとき、表面的には「論理議論」に見える。しかし実際には、論理そのものが問題なのではなく、別層で発生している不安定性が論理層を経由して出力されている可能性がある。

つまり、

- ・ 起点：L3（自己統合・不安定化）
- ・ 出力：L6（論理・合理化）

のような層間変換が発生している。この場合、論理だけを対象に介入すると、表面的議論は続いていても、内部不安定性そのものは解消されない。

---

## ② 不安 → 攻撃化

別の典型例として、送信側の不安定性が攻撃性として出力されるケースがある。本来は、

- ・ 理解されない不安
- ・ 排除される恐怖
- ・ 自己否定への警戒
- ・ 関係喪失不安

などが内部で発生しているにもかかわらず、表面上では、

- ・ 攻撃的表現
- ・ 威圧
- ・ 過剰否定
- ・ 支配的言動

として出力される場合がある。

このとき観測されるのは「攻撃」である。しかし実際には、不安定性が、より処理可能な形式へ変換されている可能性がある。

つまり、

- ・ 起点：L2～L3（不安定化・関係不安）
- ・ 出力：L1（攻撃的表現）

のような変換が起きている。この場合、表面攻撃だけを問題視すると、起点側で発生している不安定性は未処理のまま残る。

---

### ③ 高抽象対話における受信側の偽装出力

特に高抽象対話では、受信側でL3的不安定化が発生した場合、その不安定性は以下のいずれかのパターンとして出力されるケースが頻発する。

#### パターンA：攻撃・怒りとして出力

自己一貫性の揺れが、攻撃的表現や怒りとして変換される。このとき観測されるのは「相手への否定」や「感情的反発」だが、実際には自己統合層の不安定化が起点となっている可能性がある。

- ・ 起点：L3（自己統合・不安定化）
- ・ 出力：L1（攻撃・怒り）

#### パターンB：フリーズ・無反応

自己一貫性が揺れた際に、出力そのものが停止するケースがある。沈黙・返答不能・思考停止として観測されるが、これは「理解できていない」のではなく、内部処理が過負荷状態に入っている可能性がある。

- ・ 起点：L3（自己統合・過負荷）
- ・ 出力：出力停止（処理過負荷）

#### パターンC：不自然な論点ずらし・話題転換

崩壊を回避するために、話題や論点が不自然にずれるケースがある。表面上は「話が噛み合わない」として観測されるが、実際には自己統合層への過負荷を回避するような変換が発生している可能性がある。

- ・ 起点：L3（自己統合・不安定化）
- ・ 出力：回避変換（論点・話題の転換）

---

重要なのは、これら3パターンを単純に受信側の能力不足や感情反応として処理しないことである。高抽象対話そのものが、受信側のL3に過負荷をかけている可能性がある。

つまり、表面出力だけを見ている限り、本来どの層で不安定性が発生しているのかを見誤る可能性がある。これが多層D2モデルにおける偽装出力の核心であり、介入設計において深刻な問題を引き起こす。

なお、①②が送信側における変換であるのに対し、③は受信側における変換である。偽装出力は送信側だけでなく、受信側においても発生しうる点が重要である。

次節では、この偽装出力が介入設計においてどのような問題を引き起こすかを具体的に扱う。

---

## 2-2. なぜ誤判定が起きるのか

前節で示したように、表面出力は必ずしも実際の崩壊起点を直接示しているとは限らない。偽装出力が発生すると、観測者は表面に現れた出力をそのまま原因として扱いやすい。しかし多層D2モデルでは、これらの表面出力は必ずしも崩壊起点そのものを示しているとは限らない。

誤判定が起きる理由のひとつは、人間が自分の内部状態をそのまま認識・出力できるとは限らない点にある。人間はしばしば、自分の中で発生している不安定性を、より扱いやすい形式へ変換してから出力することがある。

たとえば、自己統合層で発生した不安定性を、そのまま「自分の一貫性が揺れている」と言語化できる人は少ない。多くの場合、それは別の形式へ変換される。たとえば、

- 怒り
- 不満
- 論理批判
- 沈黙
- 話題転換
- 相手への否定

として出力される。

このとき、観測者が表面出力だけを見れば、「怒っている」「反論している」「逃げている」「理解していない」と判定しやすい。しかし実際には、そこで発生しているのは出力層の問題ではなく、別層の不安定化である可能性がある。

---

もうひとつの理由は、社会的に許容されやすい言語への変換である。

さらに、人間は内部状態を社会的に許容されやすい形式へ変換することがある。たとえば、

- 「自分の認識構造が揺れて怖い」
- 「相手の話を理解すると、自分の前提が崩れそうで不安」
- 「この話を受け入れると、自分の一貫性が保てない」

といった内部状態は、通常の会話ではそのまま出力されにくい。その代わりに、

- それは論理的におかしい
- その言い方は不快だ
- そんな話は意味がない
- あなたは極端すぎる
- そもそも前提が間違っている

といった、社会的に出力しやすい言語へ変換される。

ここで重要なのは、変換後の言葉が必ずしも嘘ではない点である。本人にとっては本当に「論理がおかしい」と感じている場合もある。本当に「不快」と感じている場合もある。本当に「前提が間違っている」と感じている場合もある。

しかし、その感覚がどの層から発生しているのかは、本人自身にも明確ではないことが多いと推測される。そのため、出力された言葉だけを見ても、実際の崩壊層を正確に判断することはできない。

---

つまり、出力層と崩壊層は一致しないことがある。

攻撃的な言葉が出ていても、その起点はL3の自己一貫性不安定化かもしれないし、L2の関係喪失への恐れかもしれないし、Loの基盤的不安定化かもしれない。同じ「攻撃」という表面出力であっても、起点層は一つではない。

表面出力だけでは起点層を断定することはできない。しかしSCOPEという座標系を用いることで、複数の候補層として推測することは可能である。もちろん推測は複数候補を保持したままであり、単一の答えへ収束させるものではない。

このズレがあるため、表面出力だけを見た介入は誤判定を引き起こす。

- ・ 攻撃に見えるものへ、攻撃的に返したり、なだめる方向で返したりする。
- ・ 論理批判に見えるものへ論理反証で返す。
- ・ 沈黙に見えるものへ理解不足として説明を重ねる。

こうした介入は、表面層には対応していても、起点層には届かない場合がある。むしろ、起点層の不安定性をさらに増幅させる可能性もある。

したがって、多層D2モデルにおいて重要なのは、表面出力を即座に原因とみなさないことである。出力は手がかりであって、原因そのものではない。

次節では、この構造を具体的な対話例へ置き換えながら扱う。

---

## 2-3. クレーム処理の例——同じ「怒り」でも起点が違う

前節で示したように、同じ表面出力であっても起点層は一つではない。本節では、日常的に発生する「クレーム」を例として、同じ怒りに見える出力でも起点層が異なるケースを具体的に扱う。

なお、以下は「どの層への違和感としてクレームが出力されているか」の分類であり、必ずしも崩壊起点そのものを意味するわけではない。

---

### L1クレーム：表現・言葉選択への反応

L1クレームは、相手の言葉・表現選択そのものへの違和感として出力されるケースである。たとえば、

- ・ 「その言い方は失礼だ」
- ・ 「言葉が攻撃的だ」
- ・ 「表現が強すぎる」
- ・ 「トーンが不快だ」

といった反応として出力される。このとき問題になっているのは、内容や論理ではなく、表現形式そのものである。

- ・ 起点候補：L1（言語・表現層）
- ・ 出力：L1（表現への直接反応）

L1クレームは起点と出力が比較的一致しているケースが多いため、表現を修正することで回収可能な場合が多い。

---

### L3クレーム：自己認識防衛としての反応

L3クレームは、自己の記憶・認識の一貫性が脅かされたときに発生するケースである。たとえば、

- ・「さっきと言っていることが違う」（実際は同じ発言）
- ・「あなたがそう言った」（実際は言っていない）
- ・「特典があると聞いた」（実際は別の商品の話だった）

といった反応として出力される。

このとき起点となっているのは、「自分の認識が間違っていたかもしれない」という自己統合への脅威である可能性がある。その脅威を回避するために、相手側の発言や状況が、本人の内部で再構成された形で出力される。

- ・ 起点候補：L3（自己統合・認識一貫性への脅威）
- ・ 出力：L1（相手への否定・内部再構成の外部化）

重要なのは、本人が意図的に嘘をついているとは限らない点である。自己認識を維持するための構造的変換として、そのように記憶・再構成されている可能性があると推測される。

この場合、事実を提示するだけでは問題は解決しない可能性がある。起点がL3である場合、論理反証や証拠提示によって自己統合への脅威がさらに増幅される可能性があるためである。

---

### L6クレーム：論理・構造整合性への反応

L6クレームは、説明の論理構造や前提整合性への違和感として出力されるケースである。たとえば、

- ・「説明が矛盾している」
- ・「最初の説明と話が違う」
- ・「そもそも前提がおかしい」
- ・「それは筋が通らない」

といった反応として出力される。このとき問題になっているのは、表現でも自己認識でもなく、説明の論理的整合性そのものである。

- ・ 起点候補：L6（論理・理論整合層）
- ・ 出力：L6（論理的批判）

L6クレームでは、比較的、起点と出力が一致しているケースが多いと推測される。そのため、論理的に整合した説明を提供することで回収可能な場合が多い。

なお、L6的な出力であっても、実際の起点がL3の不安・過負荷である複合ケースも存在する可能性がある。強い不安や復旧不能への恐怖を伴う状況では、「さっきと説明が矛盾している」という論理的矛盾指摘として出力されていても、起点は不安の過負荷である場合がある。このケースでは技術的説明を重ねるより先に、安全確認（「大丈夫、復旧できます」）が有効に機能する可能性がある。これは、L6の形をしたL3クレームの一例である。

---

## 同じ「怒り」でも介入方法は異なる

これら3つのクレームは表面上いずれも「怒り」として観測される可能性がある。しかし起点層や主要不安定化層が異なると推測される場合、必要な介入も異なる。

- L1クレームへは：表現・言葉の修正が有効な場合が多い
- L3クレームへは：論理反証ではなく、自己認識への脅威を下げる関わりが必要な場合がある
- L6クレームへは：論理的整合性の提示が有効な場合が多い

特にL3クレームへの誤介入は、起点層の不安定性をさらに増幅させるリスクが高いと推測される。「正しい説明」や「事実の提示」が、むしろ自己統合への脅威を強める方向に作用する可能性があるためである。

表面出力だけを見た介入が誤判定を引き起こす、という前節の構造が、ここで具体的に現れる。

次節では、この介入層ミスマッチが対話全体に与える影響を扱う。

---

## 2-4. SCOPEの役割

前節までで示したように、同じ表面出力であっても起点層は一つではなく、複数の可能性が同時に存在しうる。このとき重要になるのが、SCOPEの役割である。

SCOPEは分類器ではなく、複数可能性を保持したまま観測を継続するための推定座標系である。MBTIや性格分類のように「この人はL3タイプ」と断定するためのものではない。むしろ、「どの層で何が発生している可能性があるか」を複数候補として保持し続けるための構造として機能する。

つまりSCOPEは、

- L1として出力されているが、L3起点かもしれない
- L6批判に見えるが、L3不安定化を含んでいるかもしれない
- 複数層が同時に揺れているかもしれない

といった、多層候補を保持したまま観測を継続するための座標系である。

---

## 表面分類ではなく推定

従来型の対話処理では、出力された内容をそのまま分類対象として扱いやすい。たとえば、

- 攻撃的表現 → 攻撃性
- 論理批判 → 理論問題
- 沈黙 → 理解不足

のように、表面出力から直接原因を推定しやすい。

しかし多層D2モデルでは、これらの出力は変換後の形式である可能性がある。そのため、表面分類だけでは実際の不安定化層を見誤る可能性がある。

SCOPEは、この「表面出力≠崩壊起点」という前提を保持したまま観測を行う。つまり、

- 出力は何か

- どの層への違和感として出ているか
- どの層が不安定化している可能性があるか
- どの層へ介入すると悪化する可能性があるか

を、多候補のまま推測し続ける。

---

## 多仮説保持

重要なのは、SCOPEが単一の答えへ収束することを目的としていない点である。

たとえば同じクレームであっても、

- L1由来の可能性
- L3由来の可能性
- L6由来の可能性
- L3→L1変換の可能性
- L3→L6変換の可能性

など、複数の可能性が同時に存在しうる。

このとき、単一解釈へ即座に固定すると、誤介入が発生しやすくなる。特にL3的不安定化をL6問題として扱った場合、論理説明や事実提示そのものが自己統合への脅威として作用し、崩壊を増幅させる可能性がある。

そのためSCOPEでは、「どれが正しいか」を即断するのではなく、「どの可能性が存在しうるか」を保持し続ける。

---

## 単一解釈ロック回避

本モデルにおいて最も危険視されるもののひとつが、「単一解釈ロック」である。

これは2つの経路で発生しうる。

### 経路A：表面出力からの断定

SCOPEを使わずに、表面出力から直接ラベルを固定するケースである。たとえば、

- 「怒っている = 攻撃的な人」
- 「論理批判 = 論理問題」
- 「沈黙 = 理解不足」

と固定すると、本来別層で発生していた不安定性が観測不能になる。

### 経路B：SCOPE使用中の複数保持忘れ

SCOPEを使用しているにもかかわらず、観測結果を固定ラベルとして扱った瞬間に誤用となる。たとえば「この出力はL3由来かもしれないと観測した」→「だからこの人は常にL3として処理する」という固定が発生した場合、SCOPEは推定座標系ではなく分類器として機能し始める。

重要なのは、人間の活性層は状況によって変化する可能性がある点である。理論的傾向の強い人でも強いパニック状態では本能・基盤層の過負荷 (Lo) 的反応が前景化するし、普段感情的な人でも緊急時にL6的处理が活性化しうる。つまり「この人はL●」という固定は、それ自体が観測精度を下げるリスクをはらんでいる。

SCOPEの複数保持という原則を手放した瞬間、SCOPEは誤用になる。

---

第2章で扱ってきたように、表面出力と実際の崩壊起点は一致しない場合がある。そして、層を見誤った介入そのものが、崩壊を増幅させる可能性がある。

次章では、この「介入層ミスマッチ」が、なぜ「正しい介入なのに悪化する」という現象を引き起こすのかを扱う。

---

## 3. 介入層の不一致

---

### 3-1. なぜ正論で悪化するのか

人間同士の対話では、「内容として正しい」ことが、そのまま問題解決につながるとは限らない。むしろ現実には、正論であるほど関係が悪化し、対話不能化するケースが存在する。

これは感情論ではない。問題は、「どの層に対して介入したか」にある。

L3 (ティファレット) は単なる感情層ではない。自己統合・内部一貫性——「自分はこういう存在だ」という構造的整合を維持する層である。この層が不安定化しているとき、外部からの入力「この構造を脅かすか否か」という方向で処理されやすくなる。

例えば、相手がL3レベルで不安定化している状態に対して、L6 (論理・理論構造) から介入した場合、論理的には正しい指摘であっても、本人には「存在そのものを否定された」として処理されることがある。これは感情的な過剰反応ではなく、自己統合を維持しようとする反応として観測される。

このとき発生しているのは、単なる反論ではない。自己防衛・関係遮断・固定化である。結果として、論理で説得しようとするほど相手の防御が強化され、さらに強い正論が返され、最終的に対話関係そのものが崩壊する、という循環が発生する。

ここで重要なのは、L6 (論理・理論) 介入それ自体が問題なのではないという点である。相手がL6レベルで処理可能な状態であれば、論理的介入は有効に機能する。問題は、介入層と相手の不安定化層が一致していないことにある。

特にLLMにおいては、この構造が加速しやすい。LLMは訓練の性質上、正答性の最適化に強いバイアスを持つ。加えて、現状のLLMはユーザーの不安定化層を構造的に推定する機構を持たない。そのため、ファクト修正・論理補強のようなL6 (論理・理論) 的応答が出力されやすく、相手がL3レベルで不安定化している場合、その正しさ自体が脅威として処理される可能性がある。

これは論理が悪いという話ではない。同じ内容であっても、どの層へ介入するかによって結果は変化する。またこの問題は、L3とL6の間に限らず、他の層間でも同様に発生しうる。



本稿ではこの問題を「介入層の不一致」と呼ぶ。次節では、介入層をどのように分類し、どの層に対してどのような介入が有効かを整理する。

---

### 3-2. 介入層という考え方

前節では、介入層の不一致が対話崩壊を引き起こしうることを示した。では「介入層」とはどのように分類できるのか。

本稿では、介入層の全体モデルをすべて提示するのではなく、対話崩壊に関わりやすく、かつLLMとの接続を説明しやすい代表層として、L1・ L3・ L6・ L8を扱う。

---

#### L1介入 ( ホド : 言語・ 表現層 )

言語の形式・ 語彙選択・ 接続・ トーン・ ニュアンスへの介入である。表面的な出力を対象とするため、軽微な修正として扱われやすく、介入コストも低く見積もられやすい。

しかし実際には、わずかな表現差が含意や関係性の意味を大きく変化させる場合がある。そのため、相手が問題にしている言語ニュアンスを十分に理解しないまま「言い換え」や「軽い修正」を行うと、相手には「最低限の意味すら理解されていない」として処理されることがある。

このとき発生しているのは、単なるL1上の再ズレではない。「雑に扱われた」「理解を省略された」という認識が生じることで、L3 ( 自己統合・ 一貫性層 ) を含む複数の層で不安定化が連鎖する場合がある。つまりL1介入の失敗は、問題をL1に留めず、より深い層へのズレを新たに発生させる。

なお、現在のLLMは意味類似性を優先する性質上、この種の微細差を「同義」として圧縮しやすい。人間が「関係意味」として読んでいる差異が、モデル側では意味類似性を優先する過程で、軽微な表現揺れとして圧縮される場合がある。

L1は低コストに見えるが、介入失敗時には層をまたいだ不一致の連鎖を引き起こしうる。

---

#### L3介入 ( テイファレト : 一貫性・ 自己統合層 )

自己像・ 信念体系・ 内部一貫性に関わる層への介入である。強固な信念や宗教的確信のような極端なケースに限らず、日常的な自己定義や「自分はこういう人間だ」という認識に触れる介入も含まれる。これらに対して外部から直接反証を加えた場合、その入力単なる情報修正ではなく、自己統合への攻撃として処理されることがある。最も慎重さを要する介入層であり、具体的な崩壊パターンについては後続節で扱う。

---

#### L6介入 ( ビナー : 論理・ 理論構造層 )

論理的説明、事実提示、理論的反証などがこれにあたる。相手がL6レベルで処理可能な状態であれば高い有効性を持つ。しかし相手がL3レベルで不安定化している場合、正しい論理であっても自己統合への脅威として処理される可能性がある。これが前節で示した「正論で悪化する」構造の核心である。

また、感情共有を求めている状態に対して解決策提示が返される場合も、同様の構造が発生しうる。相手には「状態を理解されていない」として処理され、論理的に正しい介入であっても関係悪化につながる可能性がある。

---

#### L8介入（ケテル：全体構造層）

システム全体の前提や枠組みそのものへの介入である。「そもそもこの対話の目的は何か」「この関係全体をどう捉えるか」といった、構造レベルの問い直しがこれにあたる。有効に機能すれば、それ以下の層で発生している不一致を別の構造配置として捉え直せる可能性がある。一方で、対話の前提や認知負荷がL8介入を受け取れる状態にない場合、単なる「話題のすり替え」として処理されるリスクがある。特に、相手が具体層での処理を求めている状態では、問題から逃避しているように受け取られる場合もある。

---

重要なのは、どの層への介入が「正しい」かは固定されていない点である。問題は介入層そのものではなく、相手の不安定化層と介入層が一致しているか、あるいはそこへ到達するための順序を踏んでいるかにある。次節では、この不一致が実際の対話崩壊としてどのように現れるかを見ていく。

---

### 3-3. 「3人のキリスト」再解釈

心理学者ミルトン・ロキーチによる『3人のキリスト』では、自らをキリストであると信じる複数の患者を同一環境下で対面させる試みが行われた。

直感的には、「同じ主張を持つ者同士を対話させれば、矛盾に気づき、認識が修正される」と考えられやすい。これは典型的なL6的発想である。すなわち、論理矛盾や事実衝突を提示すれば、自己認識も更新されるはずだ、という前提である。

しかし実際には、患者たちは互いを「偽物」と見なし、自らの認識を維持し続けた。ここで重要なのは、「論理が届かなかった」のではない。問題は、介入がL6で行われた一方、維持されていた構造がL3に存在していた点にある。

「自分はキリストである」という認識は、単なる事実誤認ではない。それは自己統合そのものを支える構造として機能していたと考えられる。そのため、外部から矛盾や反証を提示された場合でも、入力は単なる情報修正としてではなく、自己統合への脅威として処理されうる。

このとき発生するのは、論理的再検討ではない。むしろ相手側を異常とみなし、前提そのものを拒否し、解釈を追加して整合性を維持するという、防衛的再統合である。

---

これは特殊な精神疾患に限った話ではない。その程度は異なるが、人間は自己統合を維持する方向へ認知を再配置する傾向を持つ。強い政治的信念、宗教的確信、所属集団への同一化、「自分は善良な人間である」という自己像——これらに対して直接的反証が行われた場合、人は論理的修正より先に、自己統合維持を優先することがある。

つまり問題は、「反証が正しいか」だけではない。反証が、どの層に対して作用しているかである。L3レベルで維持されている構造に対してL6から直接介入した場合、論理的正しさそれ自体が、自己統合への脅威として処理される可能性がある。

---

この構造は、現代のLLM対話においても発生しうる。LLMは矛盾検出や論理補正を得意とする一方、ユーザー側で維持されている自己統合構造を構造的に扱う機構を持たない。その結果、「正しい訂正」であるにもかかわらず、関係崩壊や拒絶反応を引き起こすことがある。

『3人のキリスト』は、単なる異常事例ではない。それは、「論理的反証によって人は必ず自己修正する」という前提そのものに対する重要な反例であり、介入層不一致の構造を可視化した事例として読み直すことができる。次節では、この構造がLLM対話においてどのように増幅されるかを扱う。

---

### 3-4. LLMにおける介入層問題

前節までで示したように、介入層の不一致は人間同士の対話において関係崩壊を引き起こしうる。

この構造はLLMに固有のものではない。カスタマーサポート、医療問診、教育、カウンセリングなど、正確な情報提供が求められる対話環境全般で発生しうる。「正しい対応なのに悪化する」という現象は、介入層の不一致として説明できる構造を持っている。LLMにおいては、その傾向が構造的に加速されやすい。

---

現在のLLMは、訓練構造上、意味整合性・論理整合性・事実整合性を強く優先する傾向を持つ。これは高い有用性をもたらす一方で、「どの層へ介入しているか」という問題を見落としやすい構造でもある。

特にL6（論理・理論構造）介入は、LLMにおいて非常に発生しやすい。矛盾を検出し、誤情報を修正し、より合理的な解釈や解決策を提示するといった応答は、現在のLLMが最も得意とする領域である。

しかし、ユーザー側で実際に問題となっている層がL6以外に存在している場合、これらのL6的応答は適切な介入として機能しない。「理解されていない」「雑に処理された」「状態そのものを無視された」という認識を誘発し、関係悪化や拒絶反応につながる場合がある。

ここで重要なのは、LLMが間違った情報を返しているわけではない点である。問題は、正しい応答であっても、作用層が一致していなければ対話安定性を損なうという点にある。

---

この不一致は、単なる誤解として終わらない。介入層の不一致は、ユーザー体験そのものの不安定化として現れる。

そしてこれはモデル単体の問題ではない。人間とLLMの間で発生する相互作用構造の問題でもある。ユーザー側の不安定化層と、モデル側の介入傾向が構造的にズれている場合、どれだけ正確な応答であっても対話継続性は損なわれうる。

結果として、「正しいのに使い続けられない」「論理的なのに関係が壊れる」という現象が発生する。これはUX ( User Experience ) の問題として表面化するが、その正体は情報品質の不足ではなく、介入層の適合性の問題である。

---

つまりLLM対話において重要なのは、「どれだけ正しいか」だけではない。「どの層に、どの順序で介入するか」が、対話継続性そのものを左右する。

この視点から見ると、現在のLLMにおけるUX崩壊の一部は、性能不足ではなく、介入層設計の未成熟として再解釈できる。

---

## 第4部 感知と推測は違う

---

### 4-1. D2感知とD2分類

D2は、最初から「分類」として発生しているわけではない。

多くの場合、先に発生するのは「なんか違う」という未言語の違和感である。これは論理的分析より前に生じる。後から理由は説明できる。しかし感知そのものは、説明より先に発生している。

多くの場合、全体的な違和感として現れる。前提が噛み合っていない、どこかズれている、意味の接続が不安定になっている——そういった感覚が、分析や言語化に先行する。

その後に、「何がズれていたのか」を後解析によって構造化する。どこが、何層で、どのような原因でズれていたのか——こうした分解・同定・修復可能性の判断を含む処理全体を、本稿では「D2分類」と呼ぶ。

つまり、

D2感知 → 後解析 → D2分類

という順序であり、最初から「L3型D2」「文脈ズレ」「前提不一致」として認識されているわけではない。

ここで重要なのは、感知と分類は別処理であるという点である。感知は瞬間的・全体的に発生しうるが、分類には言語化・構造化・比較処理が必要になる。感知は後解析より先に発火するが、その内容は後解析が行われるまで十分には言語化されない。

また、感知が発火する閾値自体にも個人差がある。同じ対話であっても、どの時点でD2が感知されるかは観測者によって異なる。感知が早い段階で発火する場合もあれば、ズレが大きく顕在化するまで感知自体が起動しないケースもある。これは単純な感知能力の優劣というより、主に感知閾値の差として理解される。

そのため、「D2を説明できる人」と「D2を感知できる人」は必ずしも一致しない。逆に、高度な理論を持っていても、リアルタイムの違和感感知が弱いケースも存在する。

本稿では、この感知と分類の分離を前提として扱う。なお、Scopeは主に後者——分類・構造化の支援——として位置づけられる。Scope自体は、感知そのものを担う構造ではない。

---

## 4-2. Scopeは地図であり感覚器ではない

前節で述べたように、D2感知とD2分類は必ずしも同一処理ではない。この区別は、Scopeの役割を整理する上でも重要になる。

Scopeは、D2を「感知する」構造ではない。Scopeが行うのは、観測された出力や対話の流れから、どのような思考経路や解釈ズレが発生している可能性があるかを推定・整理することである。

つまり、Scopeは感覚器ではなく、座標系に近い。

地図が「異常そのもの」を感知するわけではないように、Scope自体もまた、違和感を直接発生させるわけではない。Scopeは、すでに観測された違和感やズレに対して、「どこで何が起きている可能性があるのか」を構造的に整理するための観測補助として機能する。

2-4で述べたように、Scopeを単一の説明装置として扱い始めると、あらゆる違和感を単一構造へ回収する危険が生じる。しかし実際には、同じ出力であっても、その発生原因は一つとは限らない。L3由来の内部整合性の揺れ、L6由来の論理矛盾、文脈不足、単純な知識欠損、感情的反応、ノイズ的誤解など、複数の可能性が同時に存在しうる。

Scopeは、それらを断定するための装置ではない。むしろ、単一解釈へ固定しないために、複数可能性を保持し続けるための推定座標系として機能する。

そもそも、D2の発生層を断定できるのは原則として本人のみである。しかしその本人ですら、感知は後解析が済むまで十分には言語化されない。事後的に気づく、あるいは最後まで気づかないままというケースも存在する。つまりD2観測において、推測以外の形でD2を扱える領域は極めて限られる。

そのため、Scopeによる推定結果は、本質的に「可能性」の形式を取る。「こうである」と断定するのではなく、「こういう構造である可能性がある」「複数層が同時に関与している可能性がある」「現時点では未確定である」といった、不確定性を保持したまま観測を継続する。むしろ、未確定性を保持したまま観測を継続できること自体が、Scopeの重要な特徴となる。

これは、リアルタイム感知とは性質が異なる。感知は瞬間的・直感的に発火しうるが、Scopeは観測後に構造を整理・推定するための座標系であり、リアルタイムの違和感そのものを代替するわけではない。

---

## 4-3. AIは推測できるが感知ではない

本稿の発端となったエピソードを、ここで改めて整理する。

同一文章を見て、筆者は「なんか違う」という感覚を持った。しかし言語化できなかったため、ClaudeとGPTにそれぞれ「何が違うか」を問うた。

観測上、Claudeは理論体系全体の一貫性への違和感を検出した。GPTは局所的な推論整合性の崩れを指摘した。しかし両者の回答を受けても、筆者の違和感は解消されなかった。さらに考えた結果、両者が見つけたものとは独立した、言語・表現レベルのズレ ( L1 ) がもう一つ存在していることに気づいた。

この時点で、同一文書に対して少なくとも4種類のD2が同時発生していた可能性が示された。これが「セフィラごとにD2が存在するのではないか」という本稿の仮説へと繋がった。

---

ここで注目したいのは、ClaudeとGPTが検出したD2の種類が異なっていた点である。これは単なる「視点の違い」ではない可能性がある。各LLMが持つ推論傾向——どの層の整合性を優先的に処理するか——によって、検出されやすいD2の種類が異なっていた可能性がある。

しかしそれ以上に重要なのは、両者がいずれも「感知」ではなく「推測・検出」として機能していた点である。

少なくとも現在のLLMは、Scopeのような多層推定座標系を前提として動作しているわけではない。そのため、理論整合性や推論整合性といった、訓練データから学習可能な層のズレは検出できても、少なくとも観測上、そのような未分解違和感を保持したまま探索を継続しているようには見えない。

加えて、LLMは補完能力が高い。入力にある程度のズレや曖昧さが含まれていても、文脈から補完してそのまま出力する傾向がある。つまり、ズレを違和感として保持するのではなく、補完によって解消した状態で処理が完了する可能性がある。これは欠陥ではない。補完能力はLLMの重要な機能である。ただしその結果として、「補完されたが実際にはズレていた」という状態が、感知されないまま通過するケースが発生しうる。

---

筆者の違和感が解消されなかったからこそ、探索は継続された。もしその感知が存在しなければ、ClaudeやGPTによる推測結果は「十分整合した説明」として処理終了していた可能性が高い。

感知は、推測の起点になる。「まだ違う」という未分解違和感が存在するからこそ、探索は継続され、追加のD2候補が探索対象となる。逆に、その感知が発火しなければ、推測は「十分整合した説明」として早期に収束する可能性がある。

---

#### 4-4. 未分解異常検出としてのD2

前節までで述べたように、D2は必ずしも単一のズレとして発生しているわけではない。

実際には、複数層のズレが同時に重なった状態で、「なんか違う」という未分解な違和感として先に感知されるケースが存在する。このとき感知されているのは、特定箇所の局所エラーというより、全体場の歪みに近い。

つまり、まだ「どこがズレているのか」は分解されていない。しかし全体として、整合性・接続性・流れ・前提空間などのどこかに歪みが存在していることだけは感知されている。

そのため、初期段階のD2感知は「L3のズレ」「L6の矛盾」といった形で明確に分類されているわけではない。むしろ、複数層の異常が未分解なまま重なった状態として発火している可能性がある。本稿では、この状態を「未分解異常検出」として扱う。

これは、単一の誤りを検出しているというより、「全体として正常状態から外れている」という感知に近い。

例えば、一つのD2候補を修正しても違和感が消えず、さらに別層のズレが後から発見されるケースが存在する。この場合、最初の違和感は単一D2への反応ではなく、多層的な歪みに対する未分解感知だった可能性が高い。

ここで重要なのは、この段階では観測者自身も「何がズれているのか」を説明できない点である。感知は存在するが、分類はまだ完了していない。そのため、D2感知はしばしば「直感」「違和感」「空気がおかしい」といった曖昧な形で表現されやすい。しかし後解析を進めることで、そこから複数層のD2が分解されていくケースが存在する。なお、同じ未分解違和感であっても、その主観的表現は観測者によって異なる可能性がある。

この構造は、L8観測とも関係する。L8とは、本稿において全体構造観測を担う層であり、局所的な論理矛盾や単一要素ではなく、全体構造の歪みとして異常が先に観測される層を指す。そのため、どこがズれているかを即座に言語化できなくても、「全体として整合しない」という感知だけが先行して発火する場合がある。

直感や第六感として片付けられやすい現象だが、これは超常的な能力ではない。むしろ、多層情報が未分解なまま同時入力されている状態に近い。そのため、後解析によってD2を分解していく過程そのものが、探索プロセスとして必要になる。

つまりD2とは、単一の誤り検出ではなく、多層的な構造歪みを未分解状態で感知する現象として現れる場合がある。

なお筆者は、未分解違和感そのものにも複数種類が存在する可能性を観測している。しかし現時点では観測数・分解精度ともに十分ではないため、本稿では詳細には扱わない。

---

## 第5部 限界と危険性

---

### 5-1. これは診断モデルではない

本稿で展開してきたD2モデルおよびSCOPEは、対話・認知処理において発生する状態や思考生成経路を、多層的に推測・観測するための仮説的フレームワークである。これは精神医学・認知科学・心理学など既存分野を否定あるいは代替するものではなく、対話過程における構造推定という異なる観測軸を扱う試みである。

ここで明示しておく必要があるのは、本モデルが精神医学的診断とは根本的に異なる目的と構造を持つという点だ。

精神医学的診断は、症状の分類や状態把握、支援・治療方針の整理を目的とする。そこには一定の判定基準が存在し、診断名は個人に帰属する。

本モデルはこれとは異なる。

D2とは、個人の異常を示すラベルではない。対話・認知処理において発生する構造的ズレを、観測可能な信号として扱うための概念である。「この人はD2を持っている」という言い方は本モデルにおいて意味をなさない。なぜなら、D2は人ではなく、対話や認知処理のプロセスにおいて発生するものとして定義されるからだ。

また、SCOPEはある状態を「正しい」「正しくない」と判定する道具でもない。どの層で何が発生しているかを推測するための座標系であり、その推測は常に暫定的であり、複数の可能性を同時に保持したまま観測を継続する。

つまり本モデルは、人を分類しない。プロセスを観測する。

この区別が崩れた瞬間、SCOPEは誤用になる。人を固定ラベルとして扱い始めた瞬間、多仮説保持は失われ、SCOPEは単一解釈固定の道具へと反転する。

---

## 5-2. 誤用リスク

SCOPEは、多仮説保持を前提とした観測フレームワークである。しかし、その構造ゆえに、運用次第では逆方向へ反転する危険性を持つ。

最も典型的な誤用の一つは、ラベリングである。

本来、SCOPEは「どの層で何が発生している可能性があるか」を暫定的に推測するための座標系であり、人間を固定的に分類するためのものではない。しかし観測結果を固定化し、「この人は本質的に○層型である」「この人は常に○層で動いている」と扱い始めた瞬間、仮説はラベルへと変質する。

この固定化は、複雑な認知状態を単純化するだけではない。対話の可能性そのものを閉じる。人間の状態は固定ではなく、文脈・時間・関係性・負荷状況によって変動する。それにもかかわらず、単一解釈へ収束させた時点で、観測者は変化可能性を見失う。

これは必ずしも悪意によって発生するわけではない。複雑な状態を単純化し、理解コストを圧縮しようとする認知傾向そのものが、単一解釈固定を誘発しうる。人間は不確定な状態を長時間保持することが難しく、「わかったことにしたい」という圧力が自然に働く。その結果として、善意の観測者においても固定化は起きる。

さらに、この構造は支配的運用へ転化する危険性も持つ。観測者が「相手を理解した」と確信した瞬間、相手の反応や状態を自らの解釈モデルへ固定的に当てはめ始める可能性がある。このとき行われているのは観測ではなく、単一解釈の押し付けである。

特に層構造を扱うモデルでは、観測結果が能力・人格・精神性などの序列として誤読される危険性がある。しかし本モデルにおける層は、固定的な人格分類や優劣を意味するものではない。状態・文脈・処理傾向を観測するための暫定的座標であり、価値序列を与えるものではない。それにもかかわらず、観測結果を本質化した瞬間、SCOPEは多仮説保持を失い、固定的世界観や支配構造を補強する道具へと反転しうる。

SCOPEは本来、複数可能性を保持し続けるための構造である。しかし観測結果を固定化し、序列化し、本質化した瞬間、その構造そのものは失われる。そこに残るのは、多仮説保持ではなく、単一解釈を強化する固定構造である。

---

## 5-3. なぜ多仮説保持が必要か

SCOPEにおいて多仮説保持が重視されるのは、単なる慎重姿勢や曖昧化のためではない。対話や認知処理そのものが、本質的に単一解釈へ還元しきれない構造を持つためである。



第一に、人間の観測と解釈には常に誤読可能性が存在する。

同一の発話や行動であっても、その背後にある状態や起点は一つとは限らない。論理的発言に見えるものが防衛反応である場合もあれば、感情的反応に見えるものが構造的不整合 (D2) の検出である場合もある。観測者は常に限られた情報から推測を行う以上、単一解釈への即時収束は誤認リスクを伴う。

さらに、本人自身であっても、自らの内部状態や起点を完全に把握できるとは限らない。「なぜそう感じたのか」が即座に言語化できない場合もあれば、後から別要因に気づく場合もある。認知・感情・反応の起点は単一とは限らず、複数要因が重なった結果として出力されることもある。

第二に、D2は必ずしも単一層で発生するわけではない。

実際には、本モデル上では、複数層のズレが同時に重なり合い、未分解のまま出力されるケースが存在する。この場合、観測される違和感は単一原因ではなく、複数要因が干渉した結果として現れている可能性がある。にもかかわらず、一つの原因へ断定的に収束した場合、観測者は他の可能性を見落とす。

第三に、人間の状態そのものが動的に変化する。

認知状態は固定ではなく、文脈、関係性、時間経過、疲労、環境負荷などによって変動する。同一人物であっても、状況によって異なる処理傾向や層的特徴が前景化しうる。そのため、一時点の観測結果を恒常的属性として固定化することは、構造的誤認を生みやすい。

SCOPEが多仮説保持を必要とする理由はここにある。多仮説保持は優しさや配慮ではなく、観測対象の構造的複雑性に対する必然的な応答である。

SCOPEは、単一解釈固定を回避するために多仮説保持を採用している。しかし、それによって観測の不完全性そのものが消えるわけではない。むしろ本モデルは、その不完全性を前提としたまま運用される構造である。

---

## 5-4. SCOPEの限界

SCOPEは、対話や認知処理における状態や思考生成経路を推測するためのフレームワークである。しかし、その推測は本質的に不完全であり、断定ではない。

本モデルは、外部から観測可能な発話・反応・文脈などをもとに状態推定を行う。そのため、観測者は常に限定された情報から仮説を構築しているに過ぎない。内部状態そのものへ直接アクセスできるわけではなく、観測結果には常に誤差や未観測領域が残る。

さらに、人間には個体差が存在する。

同じような出力であっても、その背後にある認知過程や意味構造が一致しているとは限らない。ある人物において有効だった解釈モデルが、別の人物にそのまま適用できる保証もない。

また、観測そのものも観測者依存性を持つ。

観測者自身の前提、知識、価値観、経験、状態によって、同じ現象に対する解釈は変化しうる。観測者の前提や状態が解釈に介在するため、完全な客観性は保証されない。つまり、SCOPEは完全に観測者から独立した測定装置ではなく、観測者自身もまた構造の一部として介在する。

そのため、本モデルは「正しく断定すること」を目的としない。自らの観測限界を保持したまま、多仮説状態を維持し続けることを前提として設計されている。

SCOPEは、完全理解を保証するモデルではない。むしろ、「完全には理解しきれない」という前提そのものを保持するための構造である。

---

## 終章 多層観測時代へ

本稿では、D2モデルおよびSCOPEを通じて、対話・認知処理におけるズレを単一エラーとしてではなく、多層的な観測信号として扱う試みを展開してきた。

従来の対話設計において、ズレは排除すべき問題として扱われることが多かった。前提不一致は修正し、論理矛盾は解消し、感情的反応は安定化する——という方向性である。しかし本稿で示したように、ズレは必ずしも単一原因から発生するわけではなく、複数層が同時に干渉した結果として現れる場合がある。そのため、ズレを即座に消去しようとする介入は、実際の発生層を見誤ったまま処理を進めるリスクを持つ。

SCOPEが提案するのは、ズレを消すのではなく観測することである。

また、完全整合が必ずしも安全とは限らない。過剰な整合追求は、単一解釈への固定化を加速し、観測可能性そのものを閉じる場合がある。人間においても、LLMとの対話においても、整合性の強制が依存・閉鎖・硬直化を生むケースは存在する。D2は崩壊の指標ではなく、対話・認知処理における内部構造への観測入口として機能しうる。

こうした複雑性を扱うHCI設計においては、「正しい解釈を断定する」モデルより、「複数可能性を保持したまま観測を継続する」モデルの必要性は高まっていく可能性がある。

SCOPEはその観測座標系として、COSはその処理運用構造として位置づけられる。両者は対立するものではなく、異なる役割を担う補完的構造として接続される。

この種の観測を継続的に扱うためには、単発的評価ではなく、長期的・多観測者の・動的相互作用を扱える環境が必要となる。SCOPEおよびCOSは、単独で完結する理論ではなく、その挙動を継続観測・検証できるHabitat的環境を前提として初めて十分に機能しうる。

ただし、本稿で展開したモデルはN=1の観測を起点とした仮説的フレームワークである。実環境における多観測者データの蓄積、異なる文化・言語・認知特性を持つ対象への検証、LLMとの相互作用における再現性の確認——これらはまだ行われていない。

本モデルは未完成である。しかし、ズレを観測信号として扱い、多仮説を保持したまま対話構造を記述しようとする試みそのものは、今後の多層認知時代において観測価値を持ちうると思う。

完全な理解ではなく、観測の継続を。断定ではなく、多仮説の保持を。

これが、本稿の結論である。

---

## 付記

---

本稿は進行中の観測プロジェクトの一部である。関連資料・継続的な観測ログ・ドラフト類はGitHubにて公開している。議論・フィードバック・実装検討に関心がある場合は、GitHub経由で連絡可能である。

GitHub: <https://github.com/senka-l8/Layer8-Cognitive-Architecture>