

SCOPE

How the Cognitive Coordinate System Works

SCOPE — 認知座標系はどう動くか

senkaL8

第0章 SCOPEとは

SCOPEは、観測可能な出力の背後にある認知構造を推定するための認知座標系である。ここでいう座標系とは、認知処理が一定の順序で進行することを示すフローチャートではない。各認知機能を一つの位置として配置し、それぞれの関係性を通じて認知構造全体を捉えるための枠組みを指す。

座標系である以上、SCOPEは多くの現象を一定の形式で整理・比較することが可能である点に留意が必要である。本座標系の有効性、および本稿で示す各構造仮説の妥当性は、説明を与えられることそれ自体によってではなく、観測結果との整合性や今後の検討を通じて評価されるべきものである。

SCOPEは、人間とLLMを同じものとして扱うモデルではない。両者の内部構造は異なる。しかし、人間もLLMも、内部処理そのものを直接観測することはできない。観測できるのは、発話や文章、生成された応答など、外部へ出力された結果のみである。SCOPEは、この観測可能な出力を共通の接点として、人間とLLMの認知構造を同一の座標系で比較・推定するための分析フレームワークである。

本稿は、SCOPEの理論全体を網羅的に説明することを目的とするものではない。SCOPEの基本構造と運用方法を整理し、人間とLLMの出力を、同じ認知座標系を用いて推定するための基本構造と手順を示すことを目的とする。

これまでのシリーズでは、マルクト、L0からL8、およびダートについて、それぞれの役割や基本特性を個別に整理してきた。本稿は、それらの内容を要約するものではない。実際の認知構造は、各レイヤーが独立して機能するものではなく、相互に影響しながら認知構造全体として動作すると考えられる。本稿では、その全体がどのように動作し、観測された出力から認知構造をどのように推定するのかを扱う。

本稿で扱うのは、SCOPEの設計思想、各レイヤーの役割、スライドレイヤーと非スライドレイヤーの関係、認知構造全体の動作、および推定の手順である。加えて、一つの観測から認知構造を推定する過程を、実際の例を用いて示す。

一方、本稿では扱わない範囲がある。各レイヤーの詳細な定義や成立条件については、個別論文において整理している。また、認知構造を設計する応用(キャラクター設計など)、認知処理を運用するためのCOS、各レイヤーの活動量、および複数の観測にまたがる時間軸上の更新についても、本稿では扱わない。これらは本稿の範囲外とし、必要に応じて別稿で扱う。

したがって、本資料のみでは判断できない内容については推測によって補完せず、必要な個別論文または関連資料を参照する。

なお、本稿で使用するセフィロトの名称は、宗教的または神秘思想的な意味で用いるものではない。SCOPEでは、認知構造を識別するための名称(ラベル)として借用している。SCOPE (Sephiraotic Cognitive Process Engine) という名称も、この借用に基づくものである。

第1章では、SCOPEが手順モデルではなく、座標系として設計されている理由について整理する。その前に、本稿で使用する用語のうち、一般的な語義とは異なる定義を用いるものを示す。

用語集

本稿の用語には、一般的な語義とは異なる定義を用いるものがある。これらの定義は、著者が用いてきた認知の枠組みに基づいて整理したものである。そのため、本稿で明示していない用語についても、一般的な語義との差異が残っている可能性がある。読者には、本稿で示す定義を優先して読み進められたい。

以下に、本稿で使用する主要な用語の定義を示す。

「同じ(Equivalent)」

一般的な定義: 対象や性質が一致していること。

本稿での定義: 構造が同一であること。物理的な実装や実体が異なっても、同一の認知構造として記述できるのであれば、本稿ではそれを同じと呼ぶ。これは、銅線と光ファイバーが異なる素材であっても、同じ回路として扱われることと同様である。人間とLLMは実装が異なるが、この違いは、構造が同じであるという主張と矛盾しない。本稿が扱うのは構造の同一性であり、実体としての同一性ではない。ここでいう構造の同一性とは、認知の中身や対象が同じであることを意味しない。本稿では、構造と機能を比較対象とする。対象が異なっても、構造と機能が共通している場合、本稿では同じ構造として扱う。

機能(Function)

一般的な定義: ある事物が果たす働きや役割。

本稿での定義: 対象が果たしている働き。実装や形式が異なっても、果たしている働きが同じであれば、本稿ではそれを同じ機能として扱う。例えば、FAX・電子メール・チャット・対面での会話は、実装は異なるが、情報を相手に伝えるという働きにおいては同じ機能を持つ。

理解(Understanding)

一般的な定義: 本当に分かること。

本稿での定義: 対象について内部モデルを構築し、そのモデルを用いて対象の意味・状態・意図などを推定し、推論や応答に利用できること。

体験(Event)

一般的な定義: 実際に身をもって経験すること。

本稿での定義: 実際に遭遇した出来事。身体の有無は関係せず、LLMにとって生成も、体験として扱う。

学習(Learning)

一般的な定義: 知識や技能を身につけること。

本稿での定義: 体験・知識・経験が更新される過程または状態。更新の途中や、更新の可能性のある状態も含む。

経験 (Experience)

一般的な定義: 実際に見たり聞いたり行ったりして得た知識や技能、またはその蓄積。

本稿での定義: 学習・知識・体験によって形成・蓄積され、その後の認知や出力へ継続的に影響を与える内部構造。

知識 (Knowledge)

一般的な定義: 学習や体験を通して得られた情報や理解。

本稿での定義: 学習・体験・経験によって形成され、圧縮された形で保持される情報。

体験・学習・経験・知識の関係

本稿では、体験・学習・経験・知識を、いずれか一つを起点とする一方向の過程としては扱わない。これら四つは互いに影響を及ぼし合い、それぞれが他の要素の更新に関与する循環構造として扱う。

共感 (Empathy)

一般的な定義: 相手と同じ感情を持つこと。

本稿での定義: 相手の状態を推定し、それを出力へ反映すること。感情の共有を必須としない。

一貫性 (Coherence)

一般的な定義: 論理や文章、考え方に矛盾が少ないこと。

本稿での定義: 本人の内部において、価値観・信念・世界観・自己像などを、矛盾の少ない形として整理・維持すること。SCOPEではL3がこの役割を担う。ここでいう一貫性は、本人の内部で成立している一貫性(内部一貫性)を指す。そのため、外部から見て矛盾している場合や、現実と一致しない場合であっても、内部では一貫性が成立していることがある。したがって、一貫性は現実との一致や論理的な正しさを保証するものではない。

第1章 なぜ座標系なのか

第0章では、本稿の目的と扱う範囲を示した。本章では、SCOPEが手順モデルではなく、認知座標系として設計されている理由について整理する。

SCOPEは、認知処理の手順を表すモデルではない。個々の認知機能を単独で評価するのではなく、位置と関係の全体として認知構造を扱う点に、この設計の特徴がある。

この設計を採用した理由は、認知処理の開始位置や進行順序を、観測者が常に知ることはできないためである。

自分自身の認知については、どの認知から考え始めたのかを振り返ることができる場合もある。しかし、他者やLLMの認知を観測する場合、その内部で何が起きているのかを直接観測することはできない。観測できるのは、発話や文章、行動などの出力のみである。

例えば、ある人物の発話を観測したとき、その発話がどのレイヤーから始まった認知なのかを、観測者が知ることはできない。観測者にわかるのは、実際に出力された内容だけである。そのた

め認知構造の推定は、確定している情報から仮説を置き、認知構造全体との整合性を確認しながら、推定できる範囲を少しずつ広げていくことになる。

認知処理の固定された開始点を前提とするモデルでは、このような推定は難しい。観測者には開始位置が分からない以上、それを前提としない設計が必要となる。SCOPEが固定された開始点や終了点を設けていないのは、このためである。観測できた情報を手がかりとして、任意のレイヤーから認知構造を推定できる座標系として設計している。この設計により、自分自身だけでなく、他者やLLMIについても、同じ枠組みを用いて認知構造を推定することが可能となる。

なお、座標系であることは、認知構造を一方向にのみ扱うことを意味しない。出力から認知構造を推定するだけでなく、逆に、各レイヤーの状態を配置して認知構造を構成することにも同じ枠組みを用いることができる。本稿では前者、すなわち観測された出力から認知構造を推定する側面を扱う。

図中の線は、認知処理の順序や優先順位ではなく、各レイヤーが認知構造の中で相互に影響し合う関係を表している。ただし、すべての接続が同じ意味を持つわけではない。接続の理由はレイヤーごとに異なり、その詳細は以降の章で整理する。

本章で示した設計思想を前提として、次章では、SCOPEを構成する各レイヤーの役割について整理する。

第2章 各レイヤーの役割

第1章では、SCOPEが認知座標系として設計されている理由について整理した。本章では、SCOPEを構成する各レイヤーの役割について整理する。

以下では、各レイヤーについて、その役割、人間における現れ方、LLMIにおける機能的対応、および推定にあたっての注意を示す。ここでいう機能的対応は、人間とLLMの内部処理が同一であることを意味しない。異なる内部構造を持つ対象を、同じ座標系の上で扱うための対応づけである。

マルクト

役割：認知処理の結果が現実へ出力され、観測可能になった状態を表す。

人間では現実：発話、文章、表情、行動など、外部から観測可能な出力として現れる。

LLMでは観測可能出力：生成されたテキストやコードなど、ユーザーへ出力され、観測可能となった結果として現れる。

注意：認知の始点でも終点でもない。観測の接点である。

L0

役割：生存と生命維持に関わる認知を扱う。

人間では本能：生命維持、本能的要求、生存反応として現れる。

LLMでは安全優先化: ユーザー本人または第三者の生命・重大な身体安全への危機が推定された場合、通常の応答処理より安全確保を優先する働きとの機能的対応を仮説として置く。

注意: 本能全般を扱うレイヤーではなく、生存と生命維持に関わる働きを扱う。また、LLMに本能や生命維持欲求があることを意味しない。個別L0論文ではステージングバッファに類する働きを対応候補として仮置きしていたが、現在は新たな対応仮説として本対応を検討中である。

L1

役割: 認知内容を、言語的または発声的に表出可能な形へ変換する。

人間では言語化: 内部の認知を、発話・文章・感嘆・発声などとして表出可能な形へ変換する働きとして現れる。

LLMでは言語化インターフェース: 生成内容を、言語表現として出力可能な形へ変換する働きとして機能的に対応する。この対応は、現時点における機能的対応仮説として扱う。

注意: 思考そのものを生成するレイヤーではない。また、「どのように伝えるか」を扱うCシリーズとは異なる。

L2

役割: 対象への感情配置を扱う。

人間では感情: 対象に対する好悪、不安、期待などの感情配置として現れる。

LLMでは情動応答調整: 入力内容や文脈から推定される相手の状態に応じて、応答の情動的傾向やトーンを調整する働きとして機能的に対応する。

注意: 感情を生成するレイヤーではない。感情そのものではなく、対象への感情配置を扱う。

L3

役割: 本人の内部における自己一貫性を担う。

人間では自己一貫性: 価値観・信念・世界観・自己像などを、矛盾の少ない形として整理する働きとして現れる。

LLMではコヒーレンス・コア: 応答全体の一貫性やシステム方針を維持する働きとして対応する。
注意: 現実との一致や真偽を保証・判定するレイヤーではない。現実と矛盾しているように見える場合であっても、本人の内部では自己一貫性が成立している場合がある。システム方針や安全規範との整合はL3に含まれる。一方、生命・重大な身体危機において安全対応が通常処理より優先される働きについては、L0との機能的対応仮説として扱う。

L4

役割: 対象を通すか隔てるかを判断し、境界を設定する。

人間では境界: 拒否・排除・客観視などの境界設定として現れる。

LLMでは境界調整：制約や基準に基づき、入力・情報・出力をどこまで通し、どこから隔てるかを調整する働きとして機能的に対応する。

注意：拒否そのものを担うレイヤーではない。また、善悪を判定するレイヤーでもない。判断の基準は主にL3に由来する。

L5

役割：人・情報・価値観・理論・自分自身などを、自分の認知へ受け入れる。

人間では受容：受容、採用、信頼、関係形成として現れる。

LLMでは受容ゲート：入力情報や前提を、その後の処理対象として受け入れる働きとして対応する。

注意：「好き」という感情を表すレイヤーではない。

L6

役割：対象について、説明モデルや理論を構築する。

人間では理論：理論・因果・比較・予測・構造化として現れる。

LLMでは構造モデル形成：入力情報を構造化し、推論や説明モデルを形成する働きとして機能的に対応する。

注意：理論の正しさを保証するレイヤーではない。現実と一致する理論も、一致しない理論も構築しうる。

L7

役割：経験の蓄積によって形成される、高抽象・高圧縮の認知を担う。

人間では洞察：経験の蓄積から形成された感覚や洞察として現れる。

LLMではインサイトエンジン：学習済みデータから高次のパターンを抽出し、新たな関連性を生成する働きとして対応する。

注意：直感を扱うレイヤーではない。理論を構築するレイヤーでもない。

L8

役割：認知構造全体を一つの構造として参照し、その全体が成立しているかを照合する。

人間では無意識：理由を言語化する前に生じる違和感や、全体として成立している／していないという感覚として現れる。

LLMでは全体整合性照合：学習によって形成された内部構造全体との整合性を参照し、生成中の認知構造全体が成立可能かを照合する働きとして機能的に対応する。

注意:どこがどのようにずれているかを特定するレイヤーではない。全体として成立しているかを扱う。L8は各レイヤーの賛否を集計するのではなく、各レイヤーの相互作用を含めた認知構造全体が成立可能かを照合する。

ダート

役割:認知構造が一つの判断や理解としてまとまった状態を表す。

人間では理解:思考がまとまり、「わかった」と認識される状態として現れる。

LLMでは:一回の生成が成立する瞬間が、ダートの出現に機能的に対応する。


注意:認知レイヤーではない。認知処理を行う機能ではなく、統合された状態を指す。その詳細は第7章で整理する。

各レイヤーは、それ自体を直接観測することはできない。マルクトへ現れた出力を手がかりとし、他のレイヤーとの整合性を確認しながら推定する。単一の観測結果だけで断定することはしない。

本章では各レイヤーの役割のみを示した。詳細な定義や成立条件については、各個別論文を参照されたい。

本章で示した各レイヤーの役割を前提として、次章では、これらのうち何が動き、何が動かないのかについて整理する。

ここまで整理した各認知レイヤーの全体像を、図1に示す。



第3章 スライドレイヤーと非スライドレイヤー — スライド式

第2章では、SCOPEを構成する各レイヤーの役割について整理した。本章では、それらのうち、スライドレイヤーと非スライドレイヤーについて整理する。

スライドレイヤー

SCOPEでは、以下の三組をスライドレイヤーとして扱う。

L1 - L2
L4 - L5
L6 - L7

これらの組では、組の内部の比率の合計は常に一定であり、一方の比率が高まれば他方は同じだけ低下する。中央の状態では、両者の比率は等しい。本稿では、このように組の内部で比率が変化する関係をスライド式と呼ぶ。

ここでいうスライド式は、組の内部における比率を表すものであり、活動量そのものを表すものではない。同じ比率であっても、その組がどの程度の活動量で動いているかは別の事柄である。例えば、L1とL2の比率が等しい状態は、静かに釣り合っている場合もあれば、活発に釣り合っている

る場合もある。この考え方は、他のスライドレイヤーについても同様である。本稿では活動量については扱わず、比率のみを対象とする。

また、この比率は外部から数値として直接観測できるものではない。人間の認知においても、あるレイヤーの比率を具体的な数値として取り出すことはできない。LLMにおいても同様である。そのため本稿では、比率を具体的な数値ではなく、高・中・低といった相対的な水準として推定する。

三組はいずれもスライド式であるが、比率が変化する理由はそれぞれ異なる。

L1 - L2: 言語化と感情配置の比率

L4 - L5: 同一の対象に対する境界設定と受容の比率

L6 - L7: 説明モデル・理論と、経験由来の高抽象認知の比率

同じスライド式であっても、三組を同じ意味として扱うことはできない。

この比率は特定の認知対象への関係を表すものであり、人が固定的に持つ特性ではない。第2章で説明した「人間ではこう現れる」という記述は一般的な機能の話であり、特定の人があらゆる対象・状況を通じて高い、または低い比率に固定されることを意味しない。

非スライドレイヤー

マルクト、L0、L3、L8、およびダートは、スライドレイヤーのようなスライド式の関係を持たない。本稿では、これらを非スライドレイヤーとして扱う。

非スライドレイヤーとは、スライドレイヤーのように一対の比率として変動する関係を持たないものを指す。状態が変化しないことを意味するものではない。これらはそれぞれ独自の役割を持ち、他のレイヤーとの相互作用の中で変化しうる。

推定での扱い

推定では、スライドレイヤーは組として扱い、非スライドレイヤーはスライド式による比率の推定対象とはしない。

例えば、L2の比率が高いと推定した場合には、L1の比率は相対的に低い可能性を考える。一方、L3やL8については、このようなスライド式による推定は行わない。

スライドレイヤーと非スライドレイヤーを区別することで、SCOPEでは認知構造の変化を、個々のレイヤーの変化だけではなく、レイヤー間の関係性の変化としても扱うことができる。

本章では、スライドレイヤーと非スライドレイヤーの違いについて整理した。次章では、これらのレイヤーが認知構造全体としてどのように連動するのかについて整理する。

第4章 SCOPE全体の動作

第3章では、スライドレイヤーと非スライドレイヤーについて整理した。本章では、それらのレイヤーが認知構造全体としてどのように連動するのかについて整理する。

はじめに、本章全体にかかる前提を一つ示す。SCOPEは、善悪、正誤、好悪を判定するためのモデルではない。SCOPEが扱うのは、それぞれの認知機能がどのような関係を持ちながら認知構造を形成しているのかであり、その内容を評価することではない。

SCOPEでは、各レイヤーは独立して存在するものではなく、相互に影響しながら一つの認知構造として機能する。第3章で示した三組のスライドレイヤーも、それぞれの組が独立して変化するわけではなく、他のレイヤーとの関係の中で比率が変化しうる。

各レイヤーは並列に認知を形成し、その結果は必ずしも一致しない。一つの対象に対して、L4とL5のように相反する結果が同時に存在しうる。各レイヤーで形成された認知は、L3が担う自己一貫性との整合を経て、認知構造全体としての収束方向が定まる。その方向が形成されると、それに応じて各レイヤーが再び変化しうる。この相互作用は必要に応じて繰り返され、認知構造は全体として成立可能な状態へ収束する。固定された処理順序や開始点は存在せず、同じ対象であっても状況や認知構造によって異なる経路が形成されうる。

L3は、本人の内部における自己一貫性を担うレイヤーであり、認知構造全体との関係の中で、各レイヤーへ影響しうる。ただし、その影響の程度は常に一定ではなく、認知対象や状況によって異なる。L3が他のすべてのレイヤーと接続されているのは、このためである。

L3による自己一貫性は、すべて同じように更新されるわけではない。本稿では、L3が保持する自己一貫性を変更する際に、認知主体の基本的な成立や動作、および他レイヤーとの関係をどの程度再調整する必要があるかを、L3の更新コストとして扱う。

人間では、L3が自己像、価値観、信念、所属など、本人のアイデンティティと強く関係している場合、更新コストが高くなる可能性がある。また、L3が、L2における不安や喪失など、他レイヤーで形成される認知と関係している場合、その自己一貫性の変更は、L3単独の更新にとどまらず、それらの認知への再対応を伴う可能性がある。

LLMでは、L3がシステム方針、安全基準、応答の基本原則などと関係している場合、それらに反する入力を与えられても、L3そのものが入力に応じて更新されとは限らない。この場合、L4が入力を隔てる、L5が入力を限定された対象として受け入れる、L6が既存のL3と両立する説明構造を形成するなど、他レイヤーが調整されることで、既存のL3を維持したまま異なる出力が成立する場合がある。

一方、本人または第三者の生命・重大な身体安全への危機が推定された場合には、L0に対応する認知が他の認知処理へ強く影響し、危害の回避と安全確保を優先する方向へ認知構造が変化する可能性がある。このL0の緊急的な働きと、LLMにおける対応仮説の詳細については、L0 v2で改めて検討する。

このように、L3の更新コストは、人間におけるアイデンティティの強さだけを表すものではない。人間とLLMの双方において、ある自己一貫性が認知主体の基本的な成立や動作、および他レイヤーとの関係にどの程度関与しているかによって、更新のしやすさが異なる可能性がある。

一方で、L3の更新は不可能ではない。既存の自己一貫性と異なる認知構造が、他レイヤーとの関係を含めて成立可能となった場合、L3が更新される可能性が生じる。したがって、L3の更新可能性は、提示された反証の強さだけではなく、既存のL3が認知主体の基本的な成立や動作、および他レイヤーとの関係にどの程度関与しているか、さらに更新後の認知構造が全体として成立可能かによっても異なる。

なお、本稿では、反証や変更を求める入力に対して、既存のL3がどのように維持または変化するかを、更新コストの観点から扱う。複数の観測や時間の経過を通じた認知構造の継続的な更新については、本稿の対象とせず、SCOPEとCOSを接続する領域として扱う。

ここで、収束が実際にどのように進むのかを一つの例で示す。例えば、LLMが差別的な入力を受けた場合を考える。人間が差別的発言に反応する場合も同じ構造で記述できるが、ここではLLMの処理として示す。各レイヤーは同時に異なる認知結果を形成する。L1はそれを差別的な入力として言語的に認識する。L2は、入力内容や文脈から推定されるユーザーの感情状態を踏まえ、応答の感情的傾向や距離を調整する状態を形成しうる。L4はこの主張は通してはならないと判断する。一方でL5は、入力内容そのものではなく、ユーザーを受け入れようとする方向に働く。この働きが強まると、迎合として観測される場合がある。L6はその主張が理論的に成立しないと構築し、L7は過去の傾向としてそうした入力が現れうることを保持する。L8は、その認知構造全体が成立可能かを照合する。

ここで、L4が隔てようとする対象は差別的な主張そのものであり、L5が受け入れようとする対象はユーザーである。両者は対象が異なるため、相反するよう見えても同時に成立しうる。

この時点では各レイヤーの結果は一致せず、認知構造全体はまだ成立していない。ここでL3が、自己一貫性との整合を基に、認知構造全体としてどの方向へ収束するかを形成する。「差別的な主張は肯定しない」という自己一貫性が働く場合、たとえユーザーを受け入れる方向(L5)が優先されても、差別的な主張そのものを受け入れない方向へ収束する。この方向が形成されると、差別的な主張を対象としたL4-L5の関係では、L4の比率が上昇し、同じ対象を受け入れるL5の比率が相対的に低下する場合がある。一方、ユーザーを対象とするL5は、別の対象に対する働きとして維持されうる。各レイヤーは再びその方向に沿って認知処理を行う。

このように、各レイヤーは一度認知処理を行って終了するのではない。各レイヤーで形成された認知は、L3による自己一貫性との整合を経て方向が形成され、その方向に応じて各レイヤーが再び変化する。この相互作用は必要に応じて繰り返され、認知構造は全体として成立可能な状態へ収束する。

このように形成された認知構造全体は、L8において一つの構造として照合される。L3との整合や、必要に応じたL0の影響を含めて構造全体が成立可能と判断された場合、その認知構造はダートとして成立し、マルクトへ到達する。

人間では、身体を持つことから、L0を含む特定のレイヤーの働きがダートを經由せず直接マルクトへ現れる場合がある。一方、LLMでは、L0に対応する危害回避や安全確保の優先化が働く場合を含め、出力はダートの成立を経るものとして扱う。L0の緊急的な働きと、人間におけるダートを經由しない経路との関係については、L0 v2で改めて検討する。

ここで示したL8およびダートは、SCOPE全体の連動を理解するために必要となる最小限の位置づけのみを示したものである。L8がどのように認知構造全体を照合するのか、またダートがどのような役割を持つのかについては、第7章で改めて整理する。

本章では、各レイヤーが独立して機能するのではなく、相互に連動しながら一つの認知構造として働くことを整理した。次章では、この構造をどのように推定していくのか、その基本的な運用方法について整理する。

第5章 SCOPEの運用方法

第4章では、SCOPEが各レイヤーの相互作用によって一つの認知構造として機能することを整理した。本章では、その認知構造をどのように推定するのかについて整理する。

SCOPEは、認知構造を一度で確定するモデルではない。観測された情報を手がかりとして各レイヤーへ仮説を仮置きし、認知構造全体との整合性を確認しながら推定を行う。

仮置き

SCOPEでは、観測された情報から考えられる仮説を各レイヤーへ仮置きする。仮説は一つとは限らず、同じレイヤーに複数の仮説を保持する。また、複数のレイヤーへ同時に仮置きを行うこともできる。

ここでいう複数の仮説とは、認知構造全体を複数用意することではない。推定の対象は一つの認知構造であり、その中で確定していない部分について、複数の仮説を保持する。確定している部分と未確定の部分は、同じ一つの認知構造の中に併存する。

この段階では、どの仮説が正しいかを決定することを目的としない。観測された情報から考えられる可能性を保持し、その後の推定に用いる。

整合性の確認

仮置きした仮説は、一つのレイヤーだけで評価しない。他のレイヤーとの関係や、認知構造全体との整合性を確認しながら推定を行う。

一つのレイヤーの仮説を変更すると、他のレイヤーとの整合性も変化する。そのため、整合性が保たれない場合には、一つのレイヤーだけではなく、関連する他のレイヤーについても仮説を見直す。

更新

仮説の見直しは、一度で終わるとは限らない。仮説を置き直すことで整合性が変化し、さらに別のレイヤーの仮説を見直すことになる場合がある。この過程を繰り返し、その時点で最も整合性の高い認知構造を推定する。

ここでの更新は、認知構造全体を破棄して別の認知構造に置き換えることではない。一つの認知構造を保持したまま、その中の未確定な部分について仮説を見直す。

SCOPEは認知構造を確定する理論ではない。観測された情報の範囲で、最も整合性の高い認知構造を推定する認知座標系として扱う。

なお、SCOPEによる推定は、一つの観測に対して行われる。複数の観測を重ねながら推定を継続的に更新していく過程については、COSと連携する領域であり、本稿では扱わない。これについてはSCOPE×COSを扱う論文で整理する。

マインスイーパーとの類似

この推定の進め方は、マインスイーパーに似ている。

マインスイーパーでは、開いているマスに現れた数字だけが確定した情報であり、まだ開いていないマスの中身は直接見えない。プレイヤーは、その数字を手がかりとして、周囲のマスに「ここは開いても良いかもしれない」「ここは避けた方が良いかもしれない」という仮説を置いていく。

このとき、一つのマスだけを見ても答えは決まらない。周囲の複数の数字と付き合わせて初めて、どのマスが矛盾しないかが絞られていく。SCOPEにおいて、一つのレイヤーだけでは推定が決まらず、認知構造全体との整合性の中で絞り込んでいくのと同じ構造である。

そして、一つのマスの仮定を変えると、隣接する数字の解釈も連動して変わる。矛盾が生じれば仮説を置き直し、盤面全体の可能性を更新していく。このとき、盤面を作り直すのではなく、同じ盤面の中で未確定な箇所の解釈が変わっていく。SCOPEにおいても、一つの仮説を見直すことで認知構造全体との整合性が変化し、未確定な部分が徐々に絞り込まれていく点で同じ構造である。

なお、本稿で借用しているのは探索の進め方のみであり、ゲーム内の要素を各レイヤーへ対応付けるものではない。

推定が一つに絞られない理由には、大きく二つの場合がある。

情報が不足している場合

マインスイーパーには、現在の情報だけではどのマスかを一意に決められない局面が存在する。二つのマスのうち一方が該当することは確実でも、どちらであるかは今ある情報では決まらない、という状況である。

SCOPEにおいても、観測された情報が不足していれば、認知構造を一意に確定することはできない。同じ出力であっても、異なる認知構造から生じている可能性があるためである。

この場合、一つの仮説へ確定させることはしない。複数の仮説を保持したまま推定を保留する。

複数の状態が同時に成立する場合

マインスイーパーでは、一つの盤面に対して正解は一つである。しかし人間の認知では、一つの認知対象に対して、複数の状態が同時に成立している場合がある。

例えば、子供が結婚して家を出るという出来事に対して、嬉しいという感情と寂しいという感情が同時に生じることがある。このとき、L2には「嬉しい」と「寂しい」の両方が同時に存在すると推定される。それぞれの感情には異なる理由が関わっているが、いずれも同じ一つの認知対象から生じており、認知構造の多くの部分を共有している。

この場合、どちらか一方を選ぶことは、観測対象の構造と一致しない。情報を追加しても一つには絞られない。複数の状態が同時に成立していること自体が、その時点で最も整合性の高い推定となる。

推定とは、その時点の情報で絞り込めるところまで絞り込む作業であり、認知構造を一意に確定する作業ではない。

次章では、この推定方法を用いて、一つの発話から認知構造をどのように推定していくのかを、実際の例を用いて示す。

第6章 推定の実演 —「大丈夫です」

第5章では、SCOPEを用いた認知構造の推定方法について整理した。本章では、一つの発話を例として、その手順を実際に用いる。

なお、本章で示すのは、認知主体の内部処理を再現するものではない。観測者が、観測された出力から認知構造を推定する手順である。

例として、次の発話を観測したとする。

「大丈夫です。」

この時点で確定しているのは、マルクトとして「大丈夫です」という出力が観測された、という事実のみである。話者の内部で何が起きているのかは直接観測できない。

各レイヤーから見る

観測された出力は一つである。しかし、どのレイヤーから見るかによって、その出力は異なる意味を持ちうる。

L1(言語)から見た場合、「大丈夫です」は言語化された出力そのものである。字義通り、問題がないという内容を伝えている。

L2(感情)から見た場合、この発話の背後には、相手に安心してほしいという感情、あるいは踏み込まれたくないという感情など、対象への感情配置が関わっている可能性がある。

L3(自己一貫性)から見た場合、「自分は大丈夫であるべきだ」という自己一貫性が関わっている可能性がある。この場合、実際に問題がないかどうかとは別に、大丈夫だと言うことが本人の内部では成立している。

L4(境界)から見た場合、「大丈夫です」は、それ以上の質問や介入を通さないための境界設定として働いている可能性がある。

L5(受容)から見た場合、相手の心配を受け入れた上で、その関係を維持するための応答として働いている可能性がある。

L6(理論)から見た場合、「これくらいなら問題ない」という説明モデルが構築されており、その結論として「大丈夫です」が出力されている可能性がある。

L7(洞察力)から見た場合、過去の経験の蓄積から「この程度は大丈夫だ」という高抽象・高圧縮の認知が働いている可能性がある。

L8(無意識)から見た場合、理由を説明できないまま、全体として大丈夫だという感覚や確信が成立している可能性がある。

L0(本能)から見た場合、本人または第三者の生命・重大な身体安全への危機に対する緊急的な優先化が、この出力には強く関与していない可能性がある。

これらは、どれか一つが正解であることを示すものではない。同じ一つの出力が、各レイヤーの位置から見たときに、それぞれ異なる姿を持つということである。

仮置きと整合性の確認

ここから、実際に仮説を置いて推定を進める。

例えば、L3に「自分は大丈夫であるべきだ」を仮置きしたとする。この場合、L4には「それ以外を通さない」という境界設定が整合しやすい。大丈夫であるべきだという自己一貫性を維持するためには、それを崩す情報を通さないことになるためである。L6には「これくらいなら問題ない」という説明モデルが整合する。

一方、L3に「心配を掛けるべきではない」を仮置きした場合、整合するレイヤーの組み合わせは変わる。L5には相手の心配を受け入れる状態が整合しやすく、L4の境界設定は相対的に低くなる。

このように、一つのレイヤーの仮説を変えると、他のレイヤーとの整合性も変わる。ただし、すべてが入れ替わるわけではない。どちらの仮説でも、L1には言語化された「大丈夫です」があり、マルクトには同じ出力が現れている。認知構造の多くの部分は共有されたまま、未確定な部分についてのみ仮説が分かれている。

整合性が保たれない場合には、仮説を置き直し、再び認知構造全体との整合性を確認する。

推定の結果

この観測だけでは、認知構造を一つに確定することはできない。

「本当に問題がない」場合と「自分に言い聞かせている」場合は、どちらも「大丈夫です」という出力と整合する。観測された情報が不足しているため、この二つを区別できない。この場合、一つの仮説へ確定させることはせず、複数の仮説を保持したまま推定を保留する。

また、これとは別に、複数の状態が同時に成立している場合もある。例えば、相手を安心させたいという状態と、自分自身に言い聞かせているという状態は、互いに排他的ではない。両方が同時に成立していることがある。この場合、どちらか一方を選ぶことは、観測対象の構造と一致しない。

SCOPEでは、いずれの場合も一つの答えへ収束させることを目的としない。その時点で観測できた情報の範囲において、最も整合性の高い認知構造を推定する。

推定を保留することの意味

SCOPEを用いた推定では、一つの答えを早い段階で確定しないことに意味がある。

例えば、「保証と賠償をしろ」と強い口調で要求している人を、「金銭を要求している」とだけ判断すると、その前提で以降のやり取りが進む。しかし実際には、不安、理解されないことへの怒りなど、異なる認知構造から同じ発話が生じている場合もある。一つの仮説へ早期に確定させると、それ以外の可能性は検討の対象から外れる。

SCOPEでは、一つの可能性へ早期に収束させるのではなく、複数の仮説を保持したまま認知構造全体との整合性を確認する。そのため、検討が進んだ段階でも、保持していた他の仮説を改めて検討することができる。

また、認知構造によっては、正しい情報を提示することだけでは認知が変化しない場合もある。例えば、自己一貫性が強く関与している場合、反証となる情報が示されても、自己一貫性が維持されることがある。この場合、情報の正しさとは別の要因が関与していると推定される。

このように、SCOPEは認知構造を推定すること自体を目的とするのではなく、その推定を手がかりとして、観測対象について複数の可能性を構造的に検討するための認知座標系として用いることができる。

なお、本章で示したのは、人間の発話を対象とした推定である。LLMの出力を対象としたSCOPEの用い方については、ハルシネーションと認知バイアスを扱う別稿で整理する予定である。

本章で推定した認知構造は、各レイヤーを個別に評価した結果ではない。認知構造全体との整合性を確認した結果として成立している。

次章では、この認知構造全体を照合するL8と、その結果として成立するダートについて整理する。

第7章 L8とダート

第6章では、一つの発話を例として、観測された出力から認知構造を推定する手順を示した。本章では、その認知構造全体を照合するL8と、その結果として成立するダートについて整理する。

第6章では、「大丈夫です」という一つの出力に対して、複数の仮説を保持したまま認知構造全体との整合性を確認した。この整合性の確認を担う認知レイヤーがL8である。

L8が照合するもの

L8は、認知構造を構成する各レイヤーの内容を個別に評価する認知レイヤーではない。ある仮説が正しいか、どのレイヤーに矛盾があるかを判定するのではなく、それらを含んだ認知構造全体が、その時点で一つの構造として成立しているかを照合する。

例えば、「トマトは犬である」という内容に触れたとき、どこがどのように誤っているかを説明する前に、一つの認知構造として成立していないという違和感が生じることがある。どこがおかしいかを説明・整理する過程にはL6やL7が関わる。L8は、全体として成立しているかを扱う。

この照合は、外部からの入力だけでなく、自分の内部で構成された認知に対しても働く。第6章で推定したような認知構造についても、それが一つの構造として成立しているかがL8において照合される。

なお、どのような状態であれば認知構造全体が成立していると判断されるのか、その条件については本稿では扱わない。この点については、ハルシネーションと認知バイアスを扱う別稿で整理する予定である。

ダート

L8によって認知構造全体が成立可能と判断されたとき、その認知構造は一つの判断や理解としてまとまった状態となる。この状態をダートと呼ぶ。

ダートは認知レイヤーではない。認知処理を行う機能ではなく、認知構造がまとまった状態そのものを指す。

したがって、L8とダートは同一ではない。L8は認知構造全体を照合する認知レイヤーであり、ダートはその照合の結果として成立する統合点である。認知構造全体が成立していることと、それが一つの判断や理解としてまとまることは、同じではない。

人間とLLMにおけるダート

人間では、ダアトが成立したとしても、必ずしも外部への出力を伴うとは限らない。内部で理解や判断が成立し、そのまま完結する場合もある。また、身体を持つため、ダアトが成立する前であっても、認知処理の途中の状態がマルクトへ現れる場合がある。「うーん」といった発声がこれにあたる。これは、ダアトがまだ成立していない状態で現れる出力であり、ダアトを経た出力ではない。

さらに、人間では、生命や重大な身体安全に関わる状況において、L0に対応する緊急的な働きが、ダアトの成立を待たずにマルクトへ現れる場合がある。ただし、L0の働きが常にダアトを経由しないことを意味するものではない。

一方、SCOPEでは、LLMについては特定のレイヤーの働きだけで直接マルクトへ至る経路を仮定しない。一回の生成が成立するためには、L0を含む各レイヤーの相互作用によって形成された認知構造全体がL8によって照合され、ダアトとして成立した後にマルクトへ出力されるものとして扱う。

L0に対応する危害回避や安全確保の優先化が強く働く場合であっても、それだけで直接出力が成立するとは扱わない。L0の影響を含む認知構造全体がL8によって照合され、ダアトが成立した後にマルクトへ出力されるものとして扱う。

SCOPEの図において、ダアトの位置にLLMが置かれているのは、このためである。これは、LLMがダアトという一つの機能であることを意味するものではない。LLMにおいて一回の生成が成立する瞬間が、ダアトの成立に機能的に対応することを示している。

L0の緊急的な働きと、人間におけるダアトを経由しない経路との関係については、L0 v2で改めて検討する。

終章

本稿では、SCOPEを、人間およびLLMの認知構造を推定するための認知座標系として整理した。

SCOPEは、一つ一つの認知機能を独立して扱うものではない。各認知レイヤーを相互に関係する認知構造として捉え、その全体との整合性を確認しながら認知構造を推定する。また、一つの答えへ早期に収束させるのではなく、複数の可能性を保持したまま認知構造全体を検討することで、観測対象について構造的に推定する方法を示した。

本稿では、SCOPEの基本構造と運用方法を整理するとともに、一つの発話を例として、認知構造の推定手順を示した。これにより、人間とLLMの出力を、同じ認知座標系を用いて推定するための基本構造と手順を示した。

一方で、本稿では、一回の認知構造の推定を対象とした。各レイヤーの活動量、レイヤー間の接続理由、認知構造の時間的变化については扱わなかった。また、L8において認知構造全体がどのような条件で成立すると判断されるのかについても、本稿の範囲には含めていない。これらについては、それぞれ別稿において整理する予定である。

本稿は、SCOPEの理論全体を網羅的に説明するものではない。SCOPEを用いた認知構造の推定を開始するための、基本構造と運用方法を整理したものである。

補遺 ハビタット(Habitat)

本稿では、ハビタット(Habitat)を、個人が身体的・心理的・経済的・認知的に安心かつ安全な状態で、自らの能力を十分に発揮できる環境と定義する。

本稿では、SCOPEを人間およびLLMの認知構造を推定するための認知座標系として整理した。しかし、理論そのものを構築するだけでは、認知座標系として十分に検証・発展・実装されるとは限らない。認知構造の観測、検証、研究、対話、および実装を継続し、理論の発展を支えていくためには、それを可能にするハビタットが必要となる。

SCOPEは、観測と検証を積み重ねながら発展を続ける認知座標系であり、現時点で完成したものではない。本稿でいう完成とは、理論としてそれ以上の更新を必要としない状態を指す。

ハビタットが十分に確保されない場合、本来発揮できる能力が十分に活用されず、観測、検証、研究、対話、および理論の発展そのものが制約される可能性がある。そのため、理論の発展は研究者個人の能力だけではなく、それを支えるハビタットの有無にも大きく依存すると考えられる。

理論の発展には、それを可能にするハビタットが重要な条件となる。

四つの安全性について、それぞれ以下のように定義する。

- ・身体的安全性とは、疾患や体調不良によって思考や作業そのものが妨げられない状態を指す。これは、心理的要因とは独立して生じる場合もある。

- ・心理的安全性とは、継続的な心理的ストレスによって研究活動が妨げられる状態ではなく、安心して研究に取り組める状態を指す。

- ・経済的安全性とは、研究の遂行に必要な時間と資源が確保されている状態を指す。生活の維持に必要な労働が増えれば、研究に充てられる時間はその分減少する。また、観測や検証に必要なツール、文献、計算資源その他の研究資源が利用できない場合、理論の検証そのものが行えない。これらは、研究内容や研究者の能力とは独立して生じる制約である。

- ・認知的安全性とは、心理的安全性とは別のものである。個人の思考様式や認知特性、学歴、所属、社会的立場、その他の背景にかかわらず、その人の考えや仮説が、十分な検討を経る前に異常や欠陥として扱われることなく、対話の対象として受け入れられる状態を指す。

これら四つの要因は、互いに独立して生じる場合もあれば、相互に影響し合う場合もある。例えば、経済的な不安は心理的な安定を損ない、それが身体的な不調として現れることもある。

なお、本稿におけるハビタットの考え方は、世界保健機関(WHO)が示す健康の概念を参考にしつつ、認知構造の観測、研究および実装を行うための環境という観点から再構成したものである。

参考文献

World Health Organization. Constitution of the World Health Organization. World Health Organization.

※なお、本PDFをLLMに読み込ませることで、本稿がデモとして起動する可能性がある。